量子 LLM 支援プログラミングにおける 失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真

指導教員：横山 哲郎

1 はじめに

大規模言語モデル（LLM）が生成する量子回路コードは，実行できても期待する量子状態や測定分布を返すとは限らない．Qiskit コードを対象に，実行ベース検証と自己修正を組み合わせ，どの失敗類型をどの介入が回復し，どこで退行が生じるかを調べる．目的は，適用条件と限界を明示した介入カタログの構築である．本稿では検証済み 3 モデル本実験を主分析とし，完了した 5 モデル追加実験を別の seed 集合として報告する．

2 評価の枠組みと関連研究

Self-Refine は自己フィードバックによる反復修正 [1]，Self-Debugging はコードの説明等を用いた自己デバッグ [2] を検討している．本研究の条件はハーネス内の実装であり，先行研究の完全な再現ではない．量子コードの実行可否と出力・構造への適合を分けて評価する．

現行 L0 はコードの実行・import と必須関数の存在・呼出形式，L1 は回路構築後のシミュレーションまたは状態評価，L2 は期待出力との一致とする．構造要件は `structure_match` で判定し，総合成功は

$$L3 = L0 \wedge L1 \wedge L2 \wedge \text{structure_match} \tag{1}$$

とする．旧中間発表の「L3 ＝構造」と区別する．引数なしの `build_circuit` から `QuantumCircuit` を返す形式を求める．測定分布は 8,192 shots による全変動距離，状態ベクトルは大域位相を整合した距離で評価し，0.05 未満を L2 成功とする．構造判定は量子ビット数や指定ゲート数等，タスクに定義した範囲に限る．

baseline の L2 失敗から介入後の L2 成功への変化を救出，baseline 成功から最終失敗への変化を退行とする．救出率の分母は対応する baseline 失敗数である．修正途中の評価段階低下は最終 L2 退行とは別に扱う．API 接続・timeout 障害は生成コードの評価失敗と区別する．

3 実験方法

主分析は Q4 ＝ `qwen3.5:4b`，G4 ＝ `gemma4:e4b-it-qat`，Q9 ＝ `qwen3.5:9b` の 3 モデル，10 タスク，seed 0–9，5 条件で 1,500 件．追加分析はこの 3 モデルに C7 と G3 を加え，seed 10–19 で 2,500 件とする．Ollama のタグをモデル名として用い，タグの数値を厳密なパラメータ数とはみなさない．モデル digest・量子化情報は保存済み automation report を参照する．

タスクは Bell，GHZ，Deutsch–Jozsa の constant と balanced，Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz の 10 種類．ハーネスの易・中・難分類は普遍的な難度尺度ではない．SF3 上の Ollama を SSH トンネル経由で利用し，temperature 0.7，生成上限 1 要求 1,024 tokens，`reasoning_effort=none`，timeout 600 秒，逐次要求とする．修正上限は 3 回．接続障害時は設定と seed を維持して最大 5 回再送し，回復しない障害は記録して停止する．

条件は baseline（B：初回生成），`self_refine`（R：自己見直し），`execution_feedback`（F：エラーや実行結果を提示），`self_debugging`（D：説明・原因分析・修正），`preventive_spec`（P：生成前注意事項）の 5 種類．B と R・F・D は同一モデル・タスク・base seed の初期コードと評価を共有する．初期または修正後の L3 成功で停止し，修正 round の seed は base seed に round 番号を加える．P は別プロンプトから 1 回独立生成する．1 レコードはモデル・タスク・seed・条件の最終評価と履歴で，round を別件数に数えない．

4 結果

4.1 出典と全件検証

固定集計は 2026 年 10 月 12 日 17:25:03 JST（08:25:03 UTC）の `results_snapshot.json` による．主分析は 3 モデル本実験（seed 0–9），追加分析は 5 モデル本実験（seed 10–19）とする．保存設定，実験 ID，検証レポートの対応は末尾の出典 [3] と README に記録した．両実験は設定・seed 集合が異なるため合算しない．

主分析は 1,500/1,500 件，追加分析は 2,500/2,500 件を記録した．両者とも欠落・重複・予定外記録，条件の対応欠落，共有初期評価の不一致は 0 件で，sanity check と automation report は成功した．固定集計の API 障害を含む記録，保存 CSV の timeout は 0 件，最終失敗分類の未分類は 0 件である．コードの評価失敗は実験結果として含める．L2 成功は主分析 839 件（55.9%），追加分析 1,242 件（49.7%）で，失敗はそれぞれ 661 件，1,258 件である．モデル構成が違うため，総率の差を性能の増減とは解釈しない．

4.2 既報との区別

中間発表時の 120 件は 2 モデル・10 タスク・seed 0–2・2 条件で，L2 達成時に修正を終了した既報である．Qwen2.5-Coder の L2 成功は B で 23/30，R で 24/30，Gemma3 は両条件 0/30 だった．この既報は参照原稿による値で，今回生データから再検証していない．現行 L3 終了の本実験や追加分析と合算しない．各 60 件の簡易実験 2 回は予備検証，API 障害 738 件を含む旧本実験は除外資料とし，途中値は全件集計で置き換えた．

4.3 主分析：3 モデル・seed 0–9

表 1 の各モデル・条件は 100 件であり，成功件数は百分率の数値とも一致する．表の L2 と L3 成功件数はすべて一致した．Q4 は B の 15 件から F で 56 件，D で 57 件へ増加し，G4 は 65 件から 87 件，88 件，Q9 は 59 件から 76 件，80 件となった．修正型条件の最終成功数には，初期 L3 成功により修正しなかった例を含む．

4.4 追加分析：5 モデル・seed 10–19

C7 を `qwen2.5-coder:7b`，G3 を `gemma3:4b` と略記する．表 2 も各モデル・条件 100 件で，L2 と L3 件数が一致する．Q4 で

表 1: 主分析の L2 成功件数（各セル 100 件）

モデル	B	R	F	D	P
Q4	15	33	56	57	11
G4	65	82	87	88	32
Q9	59	73	76	80	25
合計	139	188	219	225	68

表 2: 追加分析の L2 成功件数（各セル 100 件）

モデル	B	R	F	D	P
Q4	20	34	53	61	14
G4	68	85	96	88	31
Q9	57	71	81	78	33
C7	66	74	78	77	66
G3	1	1	1	1	7
合計	212	265	309	305	151

は D が 61 件，G4 では F が 96 件，Q9 では F が 81 件となった．観測最多の修正条件はモデルと seed 集合によって変わる．C7 は B の 66 件から F で 78 件，D で 77 件，G3 は B と修正型 3 条件が各 1 件だった．

4.5 失敗類型と介入効果

最終失敗は主分析では import 188 件，構文 116 件，回路構築 98 件，インターフェース 76 件，出力不一致 183 件であった．追加分析は import 580 件，構文 121 件，回路構築 202 件，インターフェース 49 件，出力不一致 304 件，量子ビット数不一致 2 件である．これらは全条件の最終失敗分類であり，表 3 の baseline 失敗分類・分母とは異なる．失敗段階と原因も別の分類軸として扱う．

主分析の baseline 失敗は 161/300 件．失敗類型別の救出件数を表 3 に示す．R は 49/161（30.4%），F は 80/161（49.7%），D は 86/161（53.4%）を救出した．import と回路構築では D，インターフェース不適合では F で救出件数が観測最多だった．構文では R と F が同数，出力不一致では D が最多だった．モデル別・難度別の層別検討が必要で，この集計だけで最適介入や因果効果を確定しない．

主分析の P は baseline 失敗から 22/161 件を救出した一方，baseline 成功 139 件中 93 件が失敗に変わった．R・F・D の最終 L2 退行は各 0 件であるが，修正過程の評価段階低下はカタログ定義で R 11 件，F 15 件，D 15 件あり，最終成功率とは区別する．P は別プロンプトの独立生成であり，同一コードの修正効果と解釈しない．

追加分析の介入カタログ CSV は baseline 失敗分母 137 件で，全件固定集計の 288/500 件と一致しない．全件を表すカタログとしては採用せず，追加分析の失敗類型別救出・退行は未確定とする．本実験の全件記録・条件別最終成功と，派生カタログの整合性を分けて報告する．今回の資料作成では元集計を変更していない．

5 考察と限界

実行結果を提示する F と原因分析を伴う D は，対象の初回失敗を回復する例を増やした．一方，修正型条件の初期コードは共有され，同じタスク・seed の条件は対応がある．1,500 件や 2,500 件をすべて独立標本とはみなせず，統計的有意差は検定していない．3 モデル主分析と 5 モデル追加分析では seed とモデル構成が異なり，成功率の単純差をモデル変更の因果効果とはみなさない．

表 3: 主分析の baseline 失敗類型別救出件数

失敗類型	分母	R	F	D
import	48	11	24	29
回路構築	28	4	16	17
インターフェース	21	8	14	13
構文	33	12	12	10
出力不一致	31	14	14	17
合計	161	49	80	86

評価は独自の 10 タスクと構造要件に限定され，Qiskit HumanEval そのもののスコアではない．ビット順序などを独立した原因として確定するには round 履歴の確認が必要であり，出力不一致をすべて量子論理の誤りとは断定しない．シミュレータ seed が固定されていないため，モデル seed のみで完全再現を保証できない．有限 shots，1,024 tokens 上限，共有サーバ負荷，モデル digest・量子化の違いも限界である．

時間・tokens は共有初期生成を各条件に含むので，条件間の単純合計は重複計上となる．金銭単価は未設定である．生成前の注意事項で成功が減る傾向は現在のプロンプトと対象タスクに限られ，生成前介入一般の無効性を示さない．追加実験の派生カタログ不整合を解決するまでは，その失敗類型別の推奨を公開用の確定結論にしない．

6 次回までのアクション

追加実験の保存設定を維持し，既存記録に基づく介入カタログの再集計・分母照合を次の作業として行う．その後，モデル・難度別の救出と退行，成功 round，追加時間・tokens を整理し，失敗類型ごとの適用条件と限界をカタログ化する．測定乱数と短い生成上限の影響は，必要性と設定を検討したうえで別途追試を計画する．今回，追加生成や追試は行っていない．

発表準備では，背景，対応付き比較，成功数と救出・退行，限界の順で説明資料を整える．WiNF 原稿の著者・共著者・正式所属と投稿要領は投稿前に確認する．本資料は共有用下書きで，学会投稿は別途の指示で行う．

参考文献

[1] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback, arXiv:2303.17651 (2023).

[2] X. Chen et al.: Teaching Large Language Models to Self-Debug, arXiv:2304.05128 (2023).

[3] 固定集計：`results_snapshot.json`（2026-10-12 08:25:03 UTC）．主分析：`shared_three_models_full_20261008T103231611899Z`．追加分析：`shared_five_models_full_20261010T041019864060Z`．設定・CSV・検証報告・hash は README 参照．