量子 LLM 支援プログラミングにおける失敗類型と介入カタログの実証研究

南山大学 理工学部 電子情報学科

2023TC011　伊藤 悠真

授業報告用 ｜ 本編 8 枚・約 6 分

失敗した後に，何を与えて生成し直すか

読込み

構文・ import ・ IF

回路構築

API ・回路の構成

出力評価

期待状態・分布との一致

実行できることと，期待出力が得られることを区別する。

自己見直しや実行診断を与える修正と，
同じ課題からの独立再生成を比較する。

研究課題は「数・対象・コスト」の三つ

RQ1　追加成功

同じ初期失敗から，どれだけ L3 へ到達するか。

RQ2　成功対象

成功数が近い条件は，同じ事例を成功させるか。

RQ3　計算コストと回数

未成功への消費も含め，何回まで生成するか。

共通の初回生成から，修正と再生成へ分岐

初回生成 B

→ **R** 課題仕様＋前回コード

→ **F** 課題仕様＋前回コード＋実行診断

→ **D** F と同じ評価方式の診断＋説明・原因分析

→ **B4** 課題仕様のみから独立再生成

初期成功を保持 ／ 初期失敗に追加最大 3 回 ／ L3 成功時停止

P ：生成前注意事項付きの独立 1 回生成（ B とは別コード）

成功は，実行・期待出力・構造要件で判定

段階	確認する内容
L0	読込み・ import ・必須インターフェース
L1	回路構築・評価処理の実行
L2	指定入力で期待出力と一致
L3	L0 ・ L1 ・ L2 と構造要件のすべて

分布： 8,192 shots ， 全変動距離 0.05 未満

状態：大域位相を整合した距離 0.05 未満

指定入力での一致を評価。任意入力に対する同値性は未検証。

5 モデル・ 10 タスク・ 20 seed を対応づける

5 × 10 × seed 0 〜 19 ＝ 1,000 初期組

qwen3.5:4b ／ gemma4:e4b-it-qat ／ qwen3.5:9b
qwen2.5-coder:7b ／ gemma3:4b

B/R/F/D/P ： 5,000 条件記録（ 2026-10-16 版）
B4 ：追加 1,000 組（ 2026-10-22 固定）

保存済み履歴＋部分追試を利用。全件の新規生成ではない。

追加成功率と最終成功率では分母が異なる

追加成功率

追加成功数 ／ 初期失敗 545 組

最終成功率

最終成功数 ／ 全 1,000 組

成功対象：共通・片側のみ・双方未成功を集計

層別比較：モデル別・介入前の失敗類型別に分母を明示

計算コスト：共有初期を除く tokens と追加要求数

設計で揃える条件と，残る比較上の制約

比較の起点を揃える

同じ初期組・初期コード・初期判定から比較する。

最大生成回数を揃える

初回込み 4 回。ただし入力情報・ tokens ・ seed ・時期は異なる。

観測結果からカタログへ

選択の根拠を整理し，方策の検証は次の課題とする。

補足　再現設定と分析範囲

生成設定

temperature 0.7 ／ max_tokens 1,024 ／ timeout 600 秒

評価と乱数

測定・変換 seed 42 。 B4 の追加生成は専用 seed 規則。

制約

有限 shots ・指定入力・独自 10 タスク。一般的優劣は断定しない。

補足　参考文献・固定出典

[1] Madaan et al. Self-Refine (2023)

[2] Chen et al. Teaching Large Language Models to Self-Debug (2023)

[3] 固定公開出典：commit b4c0ba7

[8] IBM Quantum: Construct circuits

[9] Qiskit Aer documentation

文献番号は元報告に対応。その他の関連研究は元報告 p.17 を参照。