Qiskit 量子回路コードの初期失敗に対する修正介入の救済率と救済対象の分析

2023TC011 伊藤 悠真　　指導教員：横山 哲郎

1　背景と目的

LLM による量子回路コード生成では，import や回路構築の失敗に加え，実行できても期待出力と一致しない場合がある．本研究では，Qiskit コードの初期失敗を修正介入がどれだけ救済し，どの対象を救済するかを調べる．Self-Refine [1]と Self-Debugging [2]を背景に，本ハーネスで修正条件を実装した．先行研究の完全再現ではない．

2　方法と実験設定

対象は 5 モデル・10 タスク・seed 0〜19 の 1,000 初期組，各組 5 条件，計 5,000 条件記録である．Q4 は qwen3.5:4b，G4 は gemma4:e4b-it-qat，Q9 は qwen3.5:9b，C7 は qwen2.5-coder:7b，G3 は gemma3:4b を示す．タグはモデル識別子として扱う．

タスクは Bell，GHZ，Deutsch–Jozsa の constant/balanced，Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz である．temperature は 0.7，生成上限は 1 要求 1,024 tokens，修正は最大 3 回とした．

B は初期生成，R は外部診断を与えない自己見直し，F は実行結果提示，D は同じ診断に説明・原因分析の指示を加える自己デバッグである．R/F/D は同じ初期コードと判定を共有し，成功時に停止する．P は生成前注意事項を与える独立生成である．

元 3 実験は 3 モデル seed 0〜9 の 1,500 条件記録，5 モデル seed 10〜19 の 2,500，残り 2 モデル seed 0〜9 の 1,000 である．主結果は検証済み保存 prefix と必要な新 suffix（部分追試 293 ケース）を接続した到達可能な経路で，全件新生成ではない．保存設定・実験 ID・処理差は固定出典 [3] に保持した．旧 120 件は合算しない．

3　評価と全体の救済

主 L3 は import・必須関数，回路構築と評価処理，指定入力の期待出力，所定の構造要件への適合である．分布は 8,192 shots の全変動距離，状態ベクトルは大域位相を整合した距離を用い，0.05 未満を出力一致とする．量子ビット数と測定・barrier を除く命令数範囲も確認する．全入力の同値性は保証しない．

救済率は「初期主 L3 失敗から最終主 L3 成功となった組数／初期主 L3 失敗組数」とする．失敗類型は介入前の B で固定する．evaluation_policy_v4 を採用し，5,000 条件の欠落・重複・予定外記録，共有初期不一致が 0 であることと，成功時停止・到達経路・出典 hash を検証済みである．

初期成功は 455 組，初期失敗は 545 組であった．R は 96/545 組（17.6%），F は 183/545 組（33.6%），D は 180/545 組（33.0%）を救済した．最終成功は R551，F638，D635 組で，初期成功の無修正保持を含む．退行 0 は成功時停止の設計と合わせて解釈する．

4　モデル・初期失敗類型別の結果

表 1 にモデル別の救済を示す．G4 では F，Q4 では D の救済が多く，大小が入れ替わった．全体率は 545 組の合算値であり，モデル率の単純平均ではない．

表 1　モデル別の救済組数

モデル	分母	R	F	D
Q4	162	31	78	90
G4	62	30	48	38
Q9	66	15	33	28
C7	65	15	23	23
G3	190	5	1	1

表２では import 失敗で D，回路構築失敗で F の救済が多かった．類型の構成はモデル・タスクと関連するため，この結果だけで介入選択規則を確定しない．保存分類 unknown の１組は原因確認記録を伴う生成コード側の失敗である．

表２　初期失敗類型別の救済組数

類型	分母	R	F	D
import 失敗	271	24	58	72
回路構築失敗	126	32	76	68
構文誤り	68	21	25	21
出力不一致	65	16	24	18
IF 不適合	11	1	0	1
量子ビット数	3	2	0	0
保存分類 unknown	1	0	0	0

5　救済対象の違いと追加消費

F/D の共通救済は 140 組，F のみ 43 組，D のみ 40 組，双方未救済 322 組であった．片側救済 83 組の両条件 166 履歴・398 修正遷移を全件静的確認した．import や回路構築等の変更は複数箇所が同時に現れ，静的差分だけでは救済原因を分離できない．

少なくとも一方が救済した 223/545 組（40.9%）は両条件の結果を見て選んだ集合であり，実行前の介入選択方策の成功率ではない．

共有初期生成を除き，未救済例への消費も含む追加 tokens／救済は R18,852.6，F9,333.8，D10,976.6 であった．保存 prefix の過去の記録値と部分追試 suffix の実測値を合わせた経路の計算値であり，全件新実験の実測コストや金銭費用ではない．

３回目の追加救済は R19 組，F28 組，D33 組であった．２回で区切ると３回までの救済の F15.3%，D18.3%を失う．同じ最大３修正の履歴を区切った比較であり，上限別の独立実験ではない．

P は B の初期失敗に対応する成功 124/545 組，初期成功に対応する失敗 106/455 組で，最終成功 473/1,000 組だった．独立生成の改善と悪化を含み，R/F/D と同じ修正効果とは解釈しない．

6　考察・限界と今後の課題

本対象では F と D が R より多くの初期失敗を救済した．F と D の全体差は３組だが，片側救済 83 組が示すように救済する対象は異なる．率とともに失敗類型やモデルによる適用範囲を確認する必要がある．

共有初期・タスク・seed の依存，元実験の schema・診断文差があり，5,000 条件を独立標本と扱わない．指定入力だけの主 L3，有限 shots と未固定の測定乱数，1,024 tokens 上限，モデル digest・量子化・負荷差が限界である．介入やモデルの一般的優劣，因果効果，統計的有意差を断定しない．

今後は介入選択と停止方策を事前固定し，別 seed・タスクで検証する．意味的変更の人手確認と，測定乱数・生成長・負荷への感度も課題とする．本稿作成に伴う追加実験は行っていない．

参考文献

[1] A. Madaan et al.：Self-Refine: Iterative Refinement with Self-Feedback，arXiv:2303.17651v2（2023）．https://arxiv.org/abs/2303.17651v2

[2] X. Chen，M. Lin，N. Schärli，D. Zhou：Teaching Large Language Models to Self-Debug，arXiv:2304.05128v2（2023）．https://arxiv.org/abs/2304.05128v2

[3] 伊藤悠真：現行救済経路の固定集計・保存設定・出典（2026-10-16 版）．本資料 README 記載の固定出典を参照．