修正と独立再生成を，同じ初期失敗から比較する

量子 LLM 支援プログラミングにおける
失敗類型と介入カタログの実証研究

南山大学 理工学部 電子情報学科

発表者： 2023TC011 伊藤 悠真

指導教員：横山 哲郎

追加成功数・成功対象・計算コストから介入を検討する

失敗の段階によって，次に与える情報が異なる

読込み
import の失敗

回路構築
API ・構築時の失敗

出力評価
期待出力と不一致

RQ1　修正と再生成で，追加成功数はどう違うか

RQ2　成功する対象は同じか

RQ3　追加計算コストと停止回数はどう関係するか

背景： Self-Refine [1] ・ Self-Debugging [2] （完全再現実験ではない）

初回を共有し，修正 R/F/D と再生成 B4 に分岐

5 モデル × 10 タスク × seed 0 〜 19 ＝ 1,000 初期組

初回生成 B

→ **R** 課題仕様＋前回コード（外部診断なし）

→ **F** 課題仕様＋前回コード＋実行診断

→ **D** F と同じ評価方式の診断＋説明・原因分析

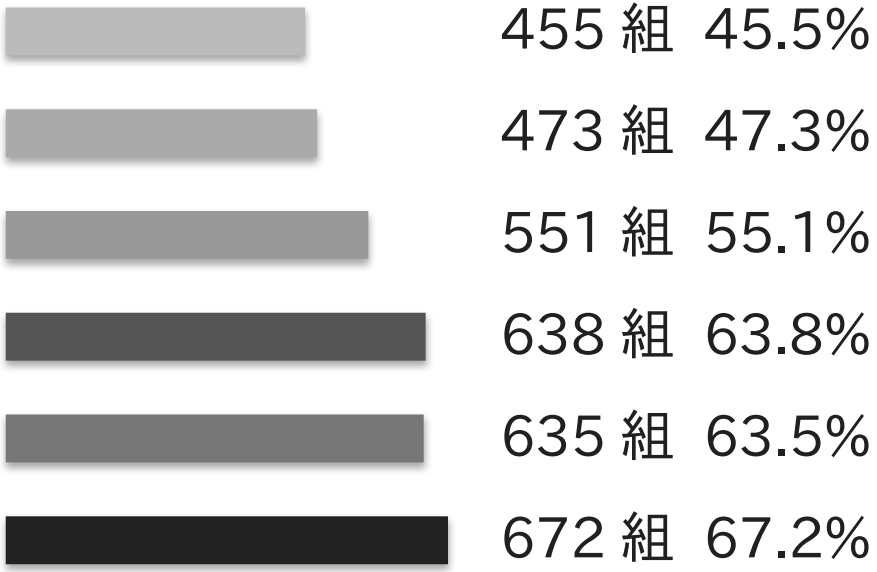
→ **B4** 同じ課題から独立再生成（前回コード・診断なし）

追加最大 3 回・ L3 成功時停止 ／ P は注意事項付きの独立 1 回生成

B/R/F/D/P ： 5,000 条件記録 ＋ B4 ：追加 1,000 組
L3 は指定入力の出力と構造要件への適合。全入力での正しさは保証しない。

B4 は 217 組で追加成功し，最終成功は 672 組

最終 L3 成功率：全 1,000 初期組



追加成功率：初期失敗 545 組

R	96 組	17.6%
F	183 組	33.6%
D	180 組	33.0%
B4	217 組	39.8%

分母を区別する。 B4 は今回の対象で最多。
最大生成回数が同じでも，入力情報や tokens 予算は等しくない。

F と D の成功数は近いが，成功対象は一致しない

43 組	140 組	40 組
F のみ	F/D 共通	D のみ

F のみ 43 組＋ D のみ 40 組＝片側救済 83 組

両条件 166 履歴・ 398 修正遷移を静的に確認。双方未救済 322 組。
同時に複数箇所が変わるため，成功原因は分離できない。
和集合 223 組は，実行前に選べる方策の成績ではない。

失敗類型により，追加成功率が最大の条件は変わる

介入カタログ：異なる失敗段階を比較する 3 類型（卒論 表 11 ）

初期失敗類型	分母	F 救済率	D 救済率	B4 追加成功率
import 失敗	271	21.4%	26.6%	24.7%
回路構築失敗	126	60.3%	54.0%	61.1%
出力不一致	65	36.9%	27.7%	70.8%

CSV は 3 行 ×9 列。類型別の件数と観測率を整理したもの。
自動選択方策による性能改善は未検証。

追加成功と計算コストを併せて比較する

共有初期生成を除く入力＋出力 tokens 。未成功例への消費も含む。

条件	追加 tokens	tokens ／追加成功
R	1,809,845	18,852.6
F	1,708,086	9,333.8
D	1,975,782	10,976.6
B4	995,815	4,589.0

3 回目の修正による救済

F ： 28 組　D ： 33 組

同じ履歴を回数で区切った比較。
上限別の独立実験ではない。

R/F/D は再構成した履歴の計算値。実行条件が異なり，資源効率は一般化しない。

全体成績・成功対象・失敗の特徴を合わせて見る

1　今回の追加成功数は B4 が最多： 217/545 組

2　F/D は成功対象が異なる：片側救済 83 組

3　モデル・初期失敗類型によって最多条件が変わる

観測結果を介入カタログに整理。自動選択の有効性は未検証。
今後：選択・停止規則を事前固定し，別 seed ・タスクで検証する。

補足 A　モデル別の追加成功数

分母は各モデルの初期失敗数。全体の 545 組を各行の分母にしない。

モデル	分母	R	F	D	B4
Q4	162	31	78	90	66
G4	62	30	48	38	51
Q9	66	15	33	28	37
C7	65	15	23	23	47
G3	190	5	1	1	16

Q4=qwen3.5:4b　G4=gemma4:e4b-it-qat　Q9=qwen3.5:9b
C7=qwen2.5-coder:7b　G3=gemma3:4b

補足 B　評価と比較の範囲

L3 ： L0 ・ L1 ・ L2 ・構造要件のすべてを満たす
分布評価： 8,192 shots ・全変動距離 0.05 未満
R/F/D ：検証済みの保存履歴＋部分追試 293 ケース
B4 ：同じ初期 1,000 組からの追加条件として別に集計
P ：独立 1 回生成，最終成功 473/1,000 組
旧 120 件は合算しない。全入力のアルゴリズム同値性は保証しない。
最大 4 回でも，入力情報・実要求数・ tokens ・ seed 規則・実行時期は異なる。

補足 C　参考文献 [1]–[5]（卒論と同じ番号）

[1] A. Madaan et al.
Self-Refine: Iterative Refinement with Self-Feedback
arXiv:2303.17651v2 (2023)
[2] X. Chen, M. Lin, N. Schärli, D. Zhou
Teaching Large Language Models to Self-Debug
arXiv:2304.05128v2 (2023)
[3] 伊藤悠真
現行救済経路の固定発表出典（ 2026-10-16 版）／ B4 追加実験（ 2026-10-22 固定）
公開固定版（b4c0ba7）
[4] M. Chen et al.
Evaluating Large Language Models Trained on Code
arXiv:2107.03374v2 (2021)
[5] J. Austin et al.
Program Synthesis with Large Language Models
arXiv:2108.07732 (2021)

補足 D　参考文献 [6]–[9] ・固定資料への入口

[6] J. Huang et al.
Large Language Models Cannot Self-Correct Reasoning Yet
arXiv:2310.01798v2 (2024)
[7] S. Vishwakarma et al.
Qiskit HumanEval: An Evaluation Benchmark For Quantum Code Generative Models
arXiv:2406.14712 (2024)
[8] IBM Quantum
Construct circuits, IBM Quantum Documentation
公式資料（2026年10月29日参照）
[9] Qiskit Development Team
Qiskit Aer documentation
公式資料（2026年10月29日参照）

文献 [3] の固定 commit ： b4c0ba79b308e7b12ab88413714746a5620424b5

10月16日：R/F/D固定出典　　10月22日：B4固定出典