卒　業　論　文

Qiskit 量子回路コードの初期失敗に対する修正介入の救済率と救済対象の分析

2023TC011 伊藤 悠真

指導教員　横山 哲郎

2027 年 1 月

南山大学 理工学部 電子情報学科

要約

LLM による量子回路コード生成では，API の誤用や回路構築の失敗に加え，実行できても期待した出力を返さない失敗が生じる．本研究では，Qiskit を用いたコードの初期失敗を修正介入がどの程度救済し，どの対象を救済するかを分析した．自己見直し R，実行結果提示 F，説明・原因分析を促す自己デバッグ D を，同じ初期コードから比較した．生成前注意事項 P は独立生成として扱った．
対象は 5 モデル，10 タスク，seed 0〜19 の 1,000 初期組，5,000 条件記録である．検証済み保存 prefix と必要な部分追試 suffix を組み合わせた到達可能な経路を採用した．成功は指定入力の出力一致と所定の構造要件を含む主 L3 で判定した．初期失敗 545 組の救済は R96 組（17.6%），F183 組（33.6%），D180 組（33.0%）であった．F と D の共通救済は 140 組，F のみ 43 組，D のみ 40 組であり，救済数が近くても対象は異なった．片側救済 83 組の両条件 166 履歴・398 修正遷移を静的に確認した．
未救済例への消費を含む追加 tokens／救済は R18,852.6，F9,333.8，D10,976.6 であった．3 回目の修正は F で 28 組，D で 33 組を追加救済した．これらは保存記録と部分追試を組み合わせた計算値であり，全件新実験の実測コストではない．結果は今回のモデル・タスクと指定入力での評価に限られ，介入の一般的優劣，因果効果，統計的有意差を主張しない．今後は介入選択・停止方策を事前固定し，別 seed・タスクで検証する必要がある．

目次

1 はじめに 5
1.1 研究背景 5
1.2 研究目的と研究課題 5
1.3 論文の構成と対象範囲 5
2 関連研究 6
2.1 自己フィードバックによる修正 6
2.2 実行結果と自己デバッグ 6
2.3 量子回路コードで確認する対象 6
3 提案手法 7
3.1 介入条件と評価指標 7
3.1.1 共有初期と五つの条件 7
3.1.2 主 L3 と出力一致 7
3.1.3 救済・保持・独立生成の比較 7
3.2 実装と記録の検証 7
3.2.1 ハーネスの構成 7
3.2.2 失敗分類とモデル接続障害 8
3.2.3 到達可能な履歴の再構成 8
3.2.4 集計の整合性と静的履歴分析 8
3.3 実験設定と出典 8
3.3.1 対象モデルと課題 8
3.3.2 生成条件と元実験の区別 9
3.3.3 追加コストと修正回数の集計方針 9
4 結果 10
4.1 全体の救済率 10
4.2 モデル別・初期失敗類型別の結果 10
4.3 タスク・難度別の結果 10
4.4 F と D の救済対象の重なり 11
4.5 追加消費と 3 回目の修正 11
4.6 P の独立生成としての比較 12
5 考察 13
5.1 介入で何が変わったか 13
5.2 介入カタログへ向けた解釈 13
5.3 内的妥当性と再構成経路 13
5.4 評価範囲・一般化・静的分析の限界 13
6 おわりに 14
6.1 研究成果 14
6.2 今後の課題 14
6.3 提出に向けた確認 14
7 参考文献 15
8 付録 16
8.1 出典と再現性 16
8.1.1 元実験の保存設定 16
8.1.2 元実験の保存設定 16
8.1.3 元実験の保存設定 16
8.1.4 固定集計と公開範囲 16
8.2 指標の読み方と提出前確認 17
8.2.1 集計単位 17
8.2.2 退行 0 の意味 17
8.2.3 静的変更の意味 17
8.2.4 コストの意味 17
8.2.5 提出前の確認 17

1 はじめに

1.1 研究背景

量子回路をプログラムとして構築する際には，量子状態や測定分布に関する理解と，ソフトウェア API の正しい使用の両方が必要になる．LLM の生成コードを利用する場合も，構文上の正しさだけで有用性を判断できない．import が成功しても回路構築に失敗する場合があり，実行が完了しても期待した出力と一致しない場合がある．
生成を一度で終えず，前回コードを見直させたり，実行結果を提示したりする方法が考えられる．自己フィードバックによる反復改善の Self-Refine [1]と，コードの説明や実行結果を用いた Self-Debugging [2]は，こうした修正の背景となる．ただし，一般的なコード生成での知見が，量子回路コードの各種失敗に同じ形で当てはまるとは限らない．
実行結果には，存在しない API の使用を知らせる診断と，期待出力との不一致を知らせる診断が含まれる．両者では修正に必要な情報が異なる可能性がある．全体の最終成功率だけを比較すると，初期成功をそのまま保持した分と，修正によって救済した分が混在する．そこで本研究では，初期失敗を分母に固定して介入を比較する．

1.2 研究目的と研究課題

目的は，Qiskit 量子回路コードの初期失敗に対する修正介入の適用範囲を明らかにし，介入を選ぶための根拠を整理することである．第一の問いは，同じ初期失敗のうち各介入がどれだけを救済するかである．第二の問いは，救済数が近い介入が同じ失敗を救済しているかである．第三の問いは，未救済例も含む追加消費と修正回数が救済にどう対応するかである．
本研究の貢献は，共有初期コードを用いた救済率の比較，初期失敗類型・モデル・タスク別の分母を伴う分析，F と D の片側救済全 83 組の履歴整理，および追加修正コストと 3 回目の寄与の記述である．介入の最適な選択方策を既に実証したとは主張しない．

1.3 論文の構成と対象範囲

第 2 章で関連研究を整理し，第 3 章で提案手法として介入条件・評価指標・実装・実験設定を述べる．第 4 章で結果，第 5 章で考察，第 6 章で結論と今後の課題を述べる．第 7 章に参考文献，第 8 章に出典と指標の付録を置く．本稿は 2026-10-16 版の固定出典 [3] に基づく草稿であり，今回の執筆では追加生成・生成コード実行を行っていない．

2 関連研究

2.1 自己フィードバックによる修正

Self-Refine [1] は，同じ LLM による生成，フィードバック，修正の反復を扱う．本研究の R は，前回コードと課題仕様を与えて自己点検を求める条件であり，外部評価の診断内容を与えない．自己点検だけで救済できる範囲を確認する比較条件として用いる．
原論文と本実装ではプロンプト構成，対象課題，出力制約，モデルが異なる．したがって本研究の R の結果を，原論文の手法全体の性能と同一視しない．先行研究は設計の背景であり，完全再現実験として扱わない．

2.2 実行結果と自己デバッグ

Self-Debugging [2] は，生成コードの説明や実行結果の検討を用いた自己デバッグを扱う．本研究では F を実行ベースの診断を用いる条件，D を同じ診断に加えて説明・原因分析・修正の順序を促す条件として実装した．D の追加指示と出力長の違いを含めて観測する．
D は説明と原因分析を修正版コード先頭のコメントに残す実装である．モデルが内部でどのように推論したかは測定していない．D で救済されたという事実だけから，説明が正しかった，あるいは説明そのものが成功原因だったとは判断できない．

2.3 量子回路コードで確認する対象

本研究は，回路を返す関数の存在，回路の構築と評価処理，指定入力の期待状態または分布，所定の構造要件を区別する．量子回路では，実行可能性と期待出力への適合は別の性質である．測定分布が一致しても，全入力で同じアルゴリズムを実装している保証にはならない．
本研究の位置づけは，選定した量子回路課題の中で介入の救済対象と消費を記述する実験的分析である．一般の量子プログラム全体への網羅的評価や，形式的な同値性証明は対象に含めない．その範囲を明確にしたうえで，成功例と失敗例を同じ分母で扱う．

3 提案手法

3.1 介入条件と評価指標

3.1.1 共有初期と五つの条件

モデル・タスク・seed の組を初期組と呼ぶ．B は初期生成のみの条件である．R/F/D は B と同じ初期コードと判定を共有し，初期失敗に対して最大 3 回の修正を行う．成功した時点で停止し，以降の修正は行わない．この対応により，初期生成の違いを介入差と混同しにくくする．
R は自己見直し，F は実行結果提示，D は説明・原因分析を促す自己デバッグである．P は初回プロンプトに注意事項を追加して独立に生成する条件であり，同じコードを修正する条件ではない．P の対応比較は，B の初期失敗に対応して成功した場合と，B の初期成功に対応して失敗した場合を分ける．

表1 条件と修正時に与える情報

条件	入力・特徴	生成・停止
B	課題仕様から初期生成	1 回
R	前回コードと自己点検の指示	最大 3 修正・成功時停止
F	前回コードと実行ベースの診断	最大 3 修正・成功時停止
D	F の診断＋説明・原因分析の指示	最大 3 修正・成功時停止
P	課題仕様＋生成前注意事項	独立生成 1 回

3.1.2 主 L3 と出力一致

L0 は生成コードの読込み・import 等と必須インターフェースの要件，L1 は回路構築と評価処理の実行，L2 は指定入力に対する期待出力との一致を表す．主 L3 は L0，L1，L2 および structure_match がすべて真であることと定義する．構造要件には量子ビット数と測定・barrier を除く回路命令数の範囲を用いる．
測定分布の距離は全変動距離 $\mathrm{TVD}(p,q) = (1/2)\Sigma_x |p(x)-q(x)|$ とし，8,192 shots で得た分布と期待分布を比較する．状態ベクトルは大域位相を整合したユークリッド距離を用いる．各タスクで距離 0.05 未満を出力一致とする．有限 shots と未固定の測定乱数の影響は残る．
本稿で用いる evaluation_policy_v4 は，測定先から量子ビット順への対応を反映する．タスクに構造制約が明示されていない項目を，一律の制約として追加しない．主 L3 は所定の検査を通過したことを意味し，全入力でのアルゴリズム同値性やプロンプトの全自然言語条件の充足を保証しない．

3.1.3 救済・保持・独立生成の比較

初期主 L3 失敗から最終主 L3 成功に変化した初期組を救済と呼ぶ．救済率 = 救済組数／初期主 L3 失敗組数 とする．初期失敗類型は介入前の B の分類に固定する．修正後の分類で分母を選別すると対象が変わるため，その方法は採用しない．
R/F/D の最終成功には初期成功の無修正保持が含まれる．成功時停止により退行 0 となる設計であり，退行 0 をモデルが常に正しさを維持できる証拠と解釈しない．P では独立生成による改善と悪化の両方を報告する．

3.2 実装と記録の検証

3.2.1 ハーネスの構成

実装は Python を中心とし，tasks/ が課題仕様・期待値・構造条件を，harness/interventions/prompts.py が条件別の修正指示を保持する．harness/llm_clients.py がモデル要求を扱い，harness/experiment.py 等が初期共有と反復を管理する．harness/evaluator.py と harness/readout.py が回路と出力を検証する．これらの責務を分け，生成の失敗と評価の不具合を区別して追跡する．
評価対象コードは build_circuit()を定義し，QuantumCircuit を返すインターフェースを前提とする．測定分布と状態ベクトルのどちらを検査するかはタスク仕様で定める．実装環境の依存範囲は

requirements.txt に保持し，過去の実験の実行環境を現在の環境から推定して埋めない．保存設定・ハーネス版・モデル digest は元実験 manifest を参照する．

3.2.2 失敗分類とモデル接続障害

構文，import，必須インターフェース，回路構築，出力不一致，量子ビット数などの分類を記録する．コード側の import_error や build_error は介入の対象となる実験結果である．一方，モデル API の接続エラーやタイムアウトは生成されたコードの品質と分けて検証する．
保存分類 unknown の 1 組は原因確認記録を伴う生成コード側の失敗として現行集計に含まれる．unknown というラベルだけで API 障害とは判断しない．固定出典の検証状態を参照し，未解決の実行・評価問題を確定結果のように扱わない．

3.2.3 到達可能な履歴の再構成

評価方針の修正は，停止する時点や次に与える診断文を変えることがある．保存コードを新しい評価で再採点するだけでは，新診断を受けて生成されるはずの後続コードを再現できない．そこで，検証済みの保存済み前半履歴（prefix）と，必要な部分追試の後半履歴（suffix）を接続した現在の到達経路を主結果とする．
部分追試は 293 ケースで，新 suffix は 647 round である．分岐後に到達できない旧保存 suffix を現在の経路に流用しない．初期生成から全件を新評価で生成し直した実験とは区別する．現行の到達 round は 9,249 であり，5,000 条件記録とは集計単位が異なる．

3.2.4 集計の整合性と静的履歴分析

固定集計では全 5,000 条件の対応，欠落・重複・予定外記録，共有初期の一致，成功時停止，層別分母の合計，出典と到達コードの hash を検査した．固定 sanity report は成功しており，欠落・重複・予定外記録・共有初期不一致は 0 である．本稿の表は公開 CSV から取得し，旧値を転記して混在させない．
片側救済 83 組については両条件 166 履歴，398 修正遷移をコード文字列として静的確認した．import/API，回路構築・インターフェース，量子ゲート等のテキスト，測定・出力取得を複数該当可で注記した．生成コードを実行しない分析であり，変更の意味や因果的寄与は別の検証を要する．

3.3 実験設定と出典

3.3.1 対象モデルと課題

対象は Q4，G4，Q9，C7，G3 の 5 モデルである．正式なモデルタグは表 2 に示す．タグ中の数値を厳密なパラメータ数とみなさず，モデル識別子として扱う．各モデル 200 初期組であり，10 タスクと seed 0〜19 を含む．
タスクは Bell，GHZ，Deutsch–Jozsa constant/balanced，Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz の 10 種類である．各タスクは指定入力・期待値を持つ．タスク名が同じでも任意入力を網羅する評価ではない．ハーネスの難度分類を利用するが，普遍的な難しさを表す尺度として解釈しない．

表2 モデルの略号と識別子

略号	モデルタグ	初期組数
Q4	qwen3.5:4b	200
G4	gemma4:e4b-it-qat	200
Q9	qwen3.5:9b	200
C7	qwen2.5-coder:7b	200
G3	gemma3:4b	200

3.3.2 生成条件と元実験の区別

temperature は 0.7，1 要求の生成上限は 1,024 tokens，最大修正回数は 3 回である．保存設定では reasoning_effort は none，timeout_sec は 600，parallel_requests は 1 である．実際に生成された長さは可変であり，上限の同一性は消費量の同一性を意味しない．
元実験は，3 モデル seed 0〜9 の 1,500 条件記録，5 モデル seed 10〜19 の 2,500 条件記録，残り 2 モデル seed 0〜9 の 1,000 条件記録に分かれる．schema や診断文処理の差を保持したうえで，初期組と条件を対応づける．元実験 ID と保存設定の参照先は付録（8.1 節）に示す．
旧 120 件は 2 モデル，seed 0〜2，2 条件，L2 終了の既報であり，現行の主 L3 による 5,000 条件記録へ合算しない．旧評価，保存コードの再採点，部分追試を三つの独立した主結果として並べない．本稿は 2026-10-16 版の固定スナップショット [3] を唯一の主集計とする．

3.3.3 追加コストと修正回数の集計方針

追加修正コストは共有初期生成を除き，失敗した修正への消費を含めた入力＋出力 tokens の合計である．tokens／救済は総追加 tokens を救済組数で割る．要求時間は保存された elapsed_sec の合計であり，評価時間や全工程の所要時間ではない．
保存 prefix の過去の記録値と，新 suffix の部分追試時の実測値を分離して保持する．合計は再構成した経路に対する計算値である．金銭単価を測定していないため，金銭費用の削減とは呼ばない．修正上限別の集計も同じ最大 3 修正の観測履歴を区切ったものであり，上限ごとに独立実験した結果ではない．

4 結果

4.1 全体の救済率

1,000 初期組中，初期成功 455 組，初期失敗 545 組であった．表 3 に条件別の救済を示す．R は 96 組（17.6%），F は 183 組（33.6%），D は 180 組（33.0%）を救済した．F と D は本対象の初期失敗のおよそ 3 分の 1 を救済し，R を上回った．全体率は 545 組を分母とする合算値であり，モデル率の単純平均ではない．
R/F/D の最終成功は 551，638，635 組で，初期成功 455 組の無修正保持を含む．F と D の最終成功差は 3 組だが，これは同じ対象を救済したことを意味しない．集計単位と分母をそろえ，件数と率を併記して解釈する．

表3 初期失敗 545 組に対する救済

条件	救済組数	救済率	最終成功／1,000
R	96	17.6%	551
F	183	33.6%	638
D	180	33.0%	635

4.2 モデル別・初期失敗類型別の結果

表 4 のモデル別集計では，G4 で F48/62 組，D38/62 組に対し，Q4 では F78/162 組，D90/162 組と大小が入れ替わる．C7 は両条件 23/65 組，G3 は両条件 1/190 組であった．モデルごとの初期失敗数は異なるため，救済数だけを比較しない．G3 の 190 失敗組も全体分母に含める．
表 5 では import 失敗に対して F58/271 組（21.4%），D72/271 組（26.6%），回路構築失敗に対して F76/126 組（60.3%），D68/126 組（54.0%）であった．出力不一致は F24/65 組，D18/65 組である．初期分類とモデル・タスクの関連があるため，この表だけから最適な介入選択を決めない．少数分母の率は参考値として扱う．

表4 モデル別の救済組数（括弧内は率）

モデル	失敗分母	R	F	D
Q4	162	31 (19.1%)	78 (48.1%)	90 (55.6%)
G4	62	30 (48.4%)	48 (77.4%)	38 (61.3%)
Q9	66	15 (22.7%)	33 (50.0%)	28 (42.4%)
C7	65	15 (23.1%)	23 (35.4%)	23 (35.4%)
G3	190	5 (2.6%)	1 (0.5%)	1 (0.5%)

表5 初期失敗類型別の救済組数

初期失敗	分母	R	F	D
import 失敗	271	24	58	72
回路構築失敗	126	32	76	68
構文誤り	68	21	25	21
出力不一致	65	16	24	18
IF 不適合	11	1	0	1
量子ビット数	3	2	0	0
保存分類 unknown	1	0	0	0

4.3 タスク・難度別の結果

表 6 に全 10 タスクの分母と件数を示す． Bell は F10/34 組・D12/34 組，GHZ は 12/35 組・13/35 組，QFT は 34/67 組・34/67 組，QPE は 13/94 組・11/94 組であった．同じ救済数でも分母が異なる場合がある．また同じタスク内にモデルと seed の違いが含まれる．

ハーネス難度別では易が F22/69 組・D25/69 組，中が 79/225 組・79/225 組，難が 82/251 組・76/251 組であった．難度間の差にはタスク構成の違いが含まれる．モデル×タスクや元実験別・seed ブロック別の分母は固定 CSV に保持しており，集約値だけを根拠に一般化しない．

表6 タスク別の救済組数

タスク	失敗分母	R	F	D
Bell	34	2	10	12
GHZ	35	9	12	13
DJ constant	42	6	12	16
DJ balanced	48	7	25	24
BV	62	13	19	24
Grover	73	14	23	15
QFT	67	21	34	34
IQFT	50	3	17	15
QPE	94	10	13	11
Ansatz	40	11	18	16

4.4 F と D の救済対象の重なり

表 7 のとおり，F と D の共通救済は 140 組，F のみ 43 組，D のみ 40 組，双方未救済 322 組であった．片側だけで救済された組は合計 83 組である．少なくとも一方が救済した 223/545 組（40.9%）は，両条件の結果を見て作った集合である．実行前の選択方策の成功率として扱わない．

全 83 組の両履歴を確認したところ，初期 import 失敗は F のみ 8 組・D のみ 22 組，回路構築失敗は 19 組・11 組であった．救済側の履歴で import/API 関係の変更が F のみ 28/83 組・D のみ 34/83 組，回路構築・インターフェース関係が 24/83 組・32/83 組，量子ゲート等のテキスト変更が 38/83 組・32/83 組，測定・出力関係が 11/83 組・16/83 組に認められた．重複を許す全 83 組に対する注記である．

静的変更は失敗側にも現れ得る．同じ遷移で複数箇所が変わるため，特定の変更を成功原因と断定しない．全例を除外なく記録し，該当なしや最後まで失敗した履歴も CSV に含めた．

表7 F/D の救済対象の分割（分母 545 組）

共通	F のみ	D のみ	双方未救済
140	43	40	322

4.5 追加消費と 3 回目の修正

表 8 の追加 tokens／救済は R18,852.6，F9,333.8，D10,976.6 であった．総追加 tokens は R1,809,845，F1,708,086，D1,975,782 である．そのうち最終的な未救済例への消費は R1,618,684，F1,374,240，D1,605,388 tokens を占める．成功例だけに消費が発生するわけではない．

round 別救済は R が 57，20，19 組，F が 112，43，28 組，D が 108，39，33 組であった．表 9 に 3 回目の分母と消費を示す．F は 2 回後未救済 390 組から 28 組（7.2%），D は 398 組から 33 組（8.3%）を追加救済した．2 回で区切ると，3 回までに救済できたうち F15.3%，D18.3%を失う．

3 回目の消費は F491,676，D588,970 tokens であり，最後まで失敗した例への消費も含む．救済を失う割合と追加消費を併記することで，対象範囲で停止方策を検討する材料になる．一般的に 2 回か 3 回のどちらが最適かは，この結果だけでは決められない．

表8 初期生成を除く追加消費（未救済を含む）

条件	保存 tokens	新 tokens	tokens／救済	秒／救済
R	1,809,845	0	18,852.6	911.1
F	1,213,947	494,139	9,333.8	444.2
D	1,408,702	567,080	10,976.6	553.6

表9 3 回目の追加救済と消費

条件	追加／未救済	追加 tokens	要求秒	2 回で失う割合
R	19/468	559,141	24,812.3	19.8%
F	28/390	491,676	21,765.5	15.3%
D	33/398	588,970	28,117.5	18.3%

4.6 P の独立生成としての比較

P は B の初期失敗に対応する成功 124/545 組（22.8%）と，初期成功に対応する失敗 106/455 組（23.3%）を生じ，最終成功は 473/1,000 組であった．B との差 18 組には改善と悪化の双方が含まれる．R/F/D と異なり，同じ初期コードの修正効果を表す指標ではない．

P の 1,000 独立生成の記録消費は 764,083 tokens である．これは修正型の共有初期を除く追加消費と集計範囲が異なる．P の結果を修正型の救済率に単純に並べて，費用効率の優劣を結論づけない．

5 考察

5.1 介入で何が変わったか

本対象では，実行結果を使う F と D が，外部診断を与えない R より多くの初期失敗を救済した．これは，課題仕様だけでなく実行に基づく診断を使う条件が有用だったという観測である．ただし F と D にはプロンプト構成や出力消費の違いもあり，情報の各要素の寄与を分離した実験ではない．
F と D の全体差 3 組に対し片側救済は 83 組であった．全体率の近さは，救済する対象の同一性を意味しない．G4 と Q4 で大小が入れ替わり，import 失敗と回路構築失敗でも傾向が異なる．介入を選ぶには，全体率に加え，対象の失敗構成と適用範囲を確認する必要がある．

5.2 介入カタログへ向けた解釈

初期失敗類型別の結果は，介入カタログの候補を作る根拠になる．例えば import 失敗と回路構築失敗では F/D の観測された救済率が異なる．しかし，同じ類型でもモデルやタスクの構成が異なり，類型だけを入力にした選択規則の有効性は未検証である．
F/D の和集合 223 組は事後的に得られる上限的な参照集合である．実行時に正解の介入を事前に選べるわけではない．両方を実行する方策を検討する場合も，追加消費や停止条件を含めた独立の評価が必要になる．

5.3 内的妥当性と再構成経路

共有初期コードによって初期生成の違いを抑えている一方，同一タスク・seed の依存が残る．5,000 条件記録を独立な 5,000 標本として扱わない．元実験には schema や診断文処理の差もあるため，差を消して単一の同条件実験だったと表現しない．
現行経路は検証済み保存 prefix と必要な新 suffix の組合せである．停止やフィードバックの影響を受ける部分は追試しているが，全件の新生成とは異なる．古い要求ログが完全には残らない出典もあり，負荷・待機・再送の影響を完全には分離できない．コストはこの再構成経路の記録に限った計算値である．

5.4 評価範囲・一般化・静的分析の限界

主 L3 は指定入力の出力と所定の構造要件に限定される．全入力の正しさ，すべての自然言語指示，等価なアルゴリズム実装を保証するものではない．有限 shots と未固定の測定乱数による判定変動，1,024 tokens 上限による出力制約，モデル digest・量子化・サーバ負荷の影響も考慮する必要がある．
片側救済 83 組を全件確認しても，静的差分だけで変更の意味的寄与は特定できない．ゲート名の増減は量子論理の訂正の証拠にはならず，複数同時変更がある．さらに，今回の 5 モデルと 10 タスクから，モデルの一般的優劣や介入の普遍的優位を断定しない．本研究では因果効果や統計的有意差を主張しない．

6 おわりに

6.1 研究成果

本研究では，LLM が生成した Qiskit 量子回路コードの初期失敗を，修正介入がどれだけ，どの対象で救済するかを分析した．1,000 初期組のうち失敗 545 組に対し，R96 組，F183 組，D180 組を救済した．今回の対象では F と D が R より多くを救済した．
F と D の救済数は近かったが，共通 140 組，F のみ 43 組，D のみ 40 組であり，片側救済 83 組を認めた．全 83 組の 166 履歴と 398 遷移を静的に整理した．追加消費は未救済例も含め，3 回目の追加救済と停止回数を減らした際の損失を明示した．

6.2 今後の課題

第一に，介入の選び方と停止条件を事前固定し，別 seed・タスクで検証する．その際，事後的に最も良い結果を選ぶ評価と区別し，追加要求数と消費を含めて報告する必要がある．第二に，静的変更の意味を人手で確認し，複数同時変更の寄与を分ける検証方法を設計する．
第三に，測定乱数，生成長の上限，モデル digest や実行負荷への感度を調べる．主 L3 を拡張する場合は，過去の成功時停止とフィードバックへの影響を監査する．同じ保存設定と出典を保持し，必要な追試を明示的に計画する．これらの追加実験は今回の資料作成では行っていない．

6.3 提出に向けた確認

本稿は検証済みの固定集計に基づく卒業論文草稿である．題目の正式承認，指導教員による内容・参考文献書式の確認を残す．要旨の審査用と最終版の提出時には，学部の指示に従って剽窃チェックと類似レポートの作成を行う．本稿の作成をもって剽窃チェック完了とはしない．

7 参考文献

[1] A. Madaan et al. : Self-Refine: Iterative Refinement with Self-Feedback，arXiv:2303.17651v2（2023）. https://arxiv.org/abs/2303.17651v2
[2] X. Chen , M. Lin , N. Schärli , D. Zhou : Teaching Large Language Models to Self-Debug，arXiv:2304.05128v2（2023）. https://arxiv.org/abs/2304.05128v2
[3] 伊藤悠真：現行救済経路の固定発表出典（2026-10-16 版）. 本リポジトリ docs/presentation_sources/20261016T_reachable_rescues/，results_snapshot.json，source_manifest.json および対応 CSV.
文献[1]，[2]は著者・題名・版を原論文の公開ページで照合した．引用番号は本文の初出順である．文献[3]は本研究の一次資料で，集計時点・保存設定・検証記録を固定している．

8 付録

8.1 出典と再現性

8.1.1 元実験の保存設定

results/shared_five_models_full_20261010T041019864060Z/experiment_config.json
設定 SHA-256：5c9232f76cc6758b52983fe90ec0757ba2ffe2c4972884a25736f09edd45f22a
保存 schema：2.1．ハーネス commit：9c1833eba6020369247358c04e462e0dc1982705．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.2 元実験の保存設定

results/shared_three_models_full_20261008T103231611899Z/experiment_config.json
設定 SHA-256：a4cd6ab1126e8927aa3a76c4fcf7392026007215d0388d8b6f73c3bba84691ec
保存 schema：2.0．ハーネス commit：9c6f952b41ac661bb42bb1ffe4d3f37282260658．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.3 元実験の保存設定

results/shared_two_models_seed0_9_full_20261012T100658266051Z/experiment_config.json
設定 SHA-256：dd6b694be0b0c03b3bc33ecc13c69872104a5dba2b66706389b8163a618b0a9b
保存 schema：2.1．ハーネス commit：7ccef09db9bff16785b08f2e7f1ff542cf64b849．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.4 固定集計と公開範囲

固定集計時点（UTC）：2026-10-15T15:20:18.335286+00:00
主出典：docs/presentation_sources/20261016T_reachable_rescues/results_snapshot.json
全分母：docs/analysis/reachable_rescues_20261016/core/repair_summary.csv
追加消費：同ディレクトリの cost_by_cap_and_stratum.csv と third_round_summary.csv
片側救済全履歴：discordant_cases.csv と discordant_transitions.csv
検証：core/sanity_report.json，sanity_report.json，validation_report.json
公開資料には生成コード・prompt・API 応答・生例外文・raw.jsonl・秘密情報を含めない．今回の資料作成は固定公開集計の読み取りと文書化であり，追加のモデル要求や生成コード再実行は行わない．

8.2 指標の読み方と提出前確認

8.2.1 集計単位

初期組はモデル×タスク×seed の 1,000 組，条件記録は各組 5 条件の 5,000 記録，到達 round は現在の経路上の 9,249 round である．単位を混ぜて成功率の分母にしない．

8.2.2 退行 0 の意味

R/F/D は初期成功を保持し，修正中も成功時に停止する．退行 0 はこの設計を反映しており，自由な修正を続けても正しさが保たれる保証ではない．

8.2.3 静的変更の意味

import/API やゲート名の変更は観察された文字列上の事実であり，その変更単独の因果的効果や意味的正しさを認定したものではない．

8.2.4 コストの意味

共有初期を除く入力＋出力 tokens と生成要求時間を集計した．再構成経路の計算値で，評価時間・全工程時間・金銭費用とは異なる．

8.2.5 提出前の確認

原本の書式と題目の正式承認，指導教員による内容・参考文献書式，Word での再ページ割付，剽窃チェックと類似レポート，WebClass 提出要領を確認する．卒業論文 PDF は 10MB 以下を目安とし，超過時は指定された Proself 経由で提出する．