卒　業　論　文

量子 LLM 支援プログラミングにおける
失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真

指導教員　横山 哲郎

2027 年 1 月

南山大学 理工学部 電子情報学科

要約

LLM による量子回路コード生成では，API の誤用や回路構築の失敗に加え，実行できても期待した出力を返さない失敗が生じる．本研究では，Qiskit を用いたコードの初期失敗を修正介入がどの程度救済し，どの対象を救済するかを分析した．自己見直し R，実行結果提示 F，説明・原因分析を促す自己デバッグ D を，同じ初期コードから比較した．生成前注意事項 P は独立生成として扱った．
対象は 5 モデル，10 タスク，seed 0〜19 の 1,000 初期組，5,000 条件記録である．検証済み保存 prefix と必要な部分追試 suffix を組み合わせた到達可能な経路を採用した．成功は指定入力の出力一致と所定の構造要件を含む主 L3 で判定した．初期失敗 545 組の救済は R96 組（17.6%），F183 組（33.6%），D180 組（33.0%）であった．F と D の共通救済は 140 組，F のみ 43 組，D のみ 40 組であり，救済数が近くても対象は異なった．片側救済 83 組の両条件 166 履歴・398 修正遷移を静的に確認した．
同じ初期コードを保持する独立再生成 B4 を追加し，初期失敗に対して最大 3 回，前回コードや診断を与えず再生成した．B4 は 217/545 組（39.8%）で成功し，最終成功は 672/1,000 組（67.2%）であった．追加 1,342 要求，995,815 tokens，追加 tokens／追加成功は 4,589.0 であった．最大生成回数が同じでも入力情報・seed 規則・実行時期が異なり，因果効果は断定しない．
未救済例への消費を含む追加 tokens／救済は R18,852.6，F9,333.8，D10,976.6 であった．3 回目の修正は F で 28 組，D で 33 組を追加救済した．これらは保存記録と部分追試を組み合わせた計算値であり，全件新実験の実測コストではない．結果は今回のモデル・タスクと指定入力での評価に限られ，介入の一般的優劣，因果効果，統計的有意差を主張しない．今後は介入選択・停止方策を事前固定し，別 seed・タスクで検証する必要がある．

目次

1 はじめに 6
1.1 研究背景 6
1.2 研究目的と研究課題 6
1.3 論文の構成と対象範囲 6
1.4 コード生成支援から失敗後の意思決定へ 6
1.5 初期失敗を基準とする研究の意義 7
1.6 用語と主張の範囲 7
2 関連研究 8
2.1 自己フィードバックによる修正 8
2.2 実行結果と自己デバッグ 8
2.3 量子回路コードで確認する対象 8
2.4 自己修正を評価する際の外部情報の役割 8
2.5 量子コード生成ベンチマークとの相違 8
2.6 反復生成と再生成対照の位置づけ 9
3 提案手法 10
3.1 介入条件と評価指標 10
3.1.1 共有初期と五つの条件 10
3.1.2 独立再生成対照 B4 10
3.1.3 主 L3 と出力一致 10
3.1.4 救済・保持・独立生成の比較 10
3.1.5 量子状態・測定分布とコードの正しさ 11
3.1.6 段階評価を用いる理由と診断の情報量 11
3.1.7 出力距離・測定順序・構造要件の詳細 11
3.1.8 対応集合による指標の定義 12
3.2 実装と記録の検証 12
3.2.1 ハーネスの構成 12
3.2.2 失敗分類とモデル接続障害 13
3.2.3 到達可能な履歴の再構成 13
3.2.4 集計の整合性と静的履歴分析 13
3.2.5 生成・評価・停止を結ぶ処理の流れ 13
3.2.6 履歴再構成における分岐と到達性 14
3.2.7 記録の検証と失敗の切り分け 14
3.2.8 静的履歴分析の観察単位 14
3.3 実験設定と出典 15
3.3.1 対象モデルと課題 15
3.3.2 生成条件と元実験の区別 15
3.3.3 追加コストと修正回数の集計方針 15
3.3.4 課題集合の役割と被覆範囲 16
3.3.5 生成設定を揃える意味と限界 16
3.3.6 固定出典と執筆時点の切り分け 16
4 結果 17
4.1 全体の救済率 17
4.2 モデル別・初期失敗類型別の結果 17
4.3 タスク・難度別の結果 17
4.4 F と D の救済対象の重なり 18
4.5 追加消費と 3 回目の修正 18
4.6 P の独立生成としての比較 19
4.7 独立再生成 B4 との比較 19
4.8 全体成績と分母の関係の詳解 20
4.9 モデル別結果の読み解き 20
4.10 初期失敗類型別結果の読み解き 21
4.11 全 10 タスクの結果と難度の読み方 22
4.12 救済集合の重なりの詳細 23
4.13 追加消費の総量と未成功例の負担 23
4.14 追加生成の順序と停止による損失 23
4.15 B4 を加えた成功集合の交差 24
5 考察 25
5.1 再生成対照を含む解釈 25
5.2 介入で何が変わったか 25

5.3 介入カタログへ向けた解釈 25
5.4 内的妥当性と再構成経路 25
5.5 評価範囲・一般化・静的分析の限界 25
5.6 修正と再生成を比較したときに分かること 25
5.7 介入カタログの記載項目と利用単位 26
5.8 カタログ項目案：import 失敗 26
5.9 カタログ項目案：回路構築失敗 27
5.10 カタログ項目案：出力不一致と少数類型 27
5.11 カタログ項目案：独立再生成と停止条件 27
5.12 内的妥当性：共有初期と交絡 28
5.13 構成概念妥当性：主 L3 と実用上の正しさ 28
5.14 外的妥当性：モデル・課題・環境の範囲 28
5.15 統計的解釈と探索的分析の位置づけ 29
5.16 今後の比較実験の設計案 29
5.17 再現可能な資料作成と変更管理 30
6 おわりに 31
6.1 研究成果 31
6.2 今後の課題 31
6.3 研究課題への回答 31
6.4 介入カタログを実証研究として育てる方向 31
6.5 本研究の到達点と利用者への含意 32
6.6 提出に向けた確認 32
7 参考文献 33
8 付録 34
8.1 出典と再現性 34
8.1.1 元実験の保存設定 34
8.1.2 元実験の保存設定 34
8.1.3 元実験の保存設定 34
8.1.4 固定集計と公開範囲 34
8.2 指標の読み方と提出前確認 35
8.2.1 集計単位 35
8.2.2 退行 0 の意味 35
8.2.3 静的変更の意味 35
8.2.4 コストの意味 35
8.2.5 提出前の確認 35

1 はじめに

1.1 研究背景

量子回路をプログラムとして構築する際には，量子状態や測定分布に関する理解と，ソフトウェア API の正しい使用の両方が必要になる．LLM の生成コードを利用する場合も，構文上の正しさだけで有用性を判断できない．import が成功しても回路構築に失敗する場合があり，実行が完了しても期待した出力と一致しない場合がある．
生成を一度で終えず，前回コードを見直させたり，実行結果を提示したりする方法が考えられる．自己フィードバックによる反復改善の Self-Refine [1]と，コードの説明や実行結果を用いた Self-Debugging [2]は，こうした修正の背景となる．ただし，一般的なコード生成での知見が，量子回路コードの各種失敗に同じ形で当てはまるとは限らない．
実行結果には，存在しない API の使用を知らせる診断と，期待出力との不一致を知らせる診断が含まれる．両者では修正に必要な情報が異なる可能性がある．全体の最終成功率だけを比較すると，初期成功をそのまま保持した分と，修正によって救済した分が混在する．そこで本研究では，初期失敗を分母に固定して介入を比較する．

1.2 研究目的と研究課題

目的は，Qiskit 量子回路コードの初期失敗に対する修正介入の適用範囲を明らかにし，介入を選ぶための根拠を整理することである．第一の問いは，同じ初期失敗のうち各介入がどれだけを救済するかである．第二の問いは，救済数が近い介入が同じ失敗を救済しているかである．第三の問いは，未救済例も含む追加消費と修正回数が救済にどう対応するかである．
本研究の貢献は，共有初期コードを用いた救済率の比較，初期失敗類型・モデル・タスク別の分母を伴う分析，F と D の片側救済全 83 組の履歴整理，および追加修正コストと 3 回目の寄与の記述である．介入の最適な選択方策を既に実証したとは主張しない．

1.3 論文の構成と対象範囲

第 2 章で関連研究を整理し，第 3 章で提案手法として介入条件・評価指標・実装・実験設定を述べる．第 4 章で結果，第 5 章で考察，第 6 章で結論と今後の課題を述べる．第 7 章に参考文献，第 8 章に出典と指標の付録を置く．本稿は 2026-10-16 版の到達経路と 2026-10-22 固定の B4 追加実験 [3] に基づく草稿であり，今回の執筆では追加生成・生成コード実行を行っていない．

1.4 コード生成支援から失敗後の意思決定へ

自然言語からプログラムを生成できることと，そのプログラムを目的に沿って利用できることは同じではない．利用者は生成されたコードを読み，実行環境に接続し，結果を確認し，問題があれば次の操作を選ばなければならない．コード生成支援の実際の作業では，最初の出力の品質だけでなく，失敗を確認した後に何を入力し，どこで生成を止めるかが作業量を左右する．本研究はこの失敗後の意思決定に対象を絞る．
コード生成の機能的正しさを評価する HumanEval [4]や，自然言語から短い Python プログラムを生成する MBPP [5]は，生成したコードを実行し，機能を確認する評価の背景となる．ただし，本研究はこれらの課題をそのまま利用したベンチマークではない．対象を独自に定義した量子回路課題に限定し，初期失敗の後に行う修正と再生成を対応づけて調べる．課題集合や評価基準が異なるため，他のベンチマークにおける成功率との直接比較は行わない．
例えば，存在しない関数名を import して失敗した場合には，実行診断から変更箇所の候補を狭められる可能性がある．一方，コードは実行できるが量子状態が異なる場合には，単に例外が出ないように書き換えるだけでは不十分である．必要な情報や修正箇所が異なる以上，すべての失敗へ一つの指示を一律に適用することが適切かは実証的に確認すべき問題になる．この二つの例は介入の役割を説明するための想定例であり，特定の保存事例を新たに再現した結果ではない．
失敗後の操作には，既存コードを残して直す方法と，既存コードを捨てて生成し直す方法がある．修正には，前回の出力を再利用できる利点がある一方，誤った構造を引き継ぐ可能性もある．再生成には，既存の誤りから離れられる可能性がある一方，既に正しかった部分を再び作り直すことになる．

これらは設計上考えられる性質であり，本研究が個別の心理過程やモデル内部の挙動を直接測定したという意味ではない．実際の比較では成功数と追加消費を観測して判断する．
本研究でいう介入は，生成されたコードに対し，次の要求で与える情報や指示を変更する操作である．モデルの重みを更新する学習ではなく，同じ課題を解く過程での入力の構成に着目する．したがって，結果の解釈にはモデル識別子だけでなく，プロンプト，評価器，停止条件，生成機会上限を含める必要がある．介入名だけを取り出して一般的な効力を論じることは避ける．

1.5 初期失敗を基準とする研究の意義

最終成功率のみを用いると，初期から正しかったコードの割合と，初期に誤っていたコードを修正できた割合が混在する．初期性能が高いモデルは修正対象が少なく，初期性能が低いモデルは修正対象が多い．この違いを考慮せずに最終成功数を比べると，介入が働いた範囲を読み取りにくい．本研究は各組の初期判定を保存し，その初期失敗集合に対して修正後の成功を数えることで，修正が必要だった対象に対する成績を明示する．
初期コードの共有は，比較の出発点を揃えるためにも必要である．別々の初期生成から R と F を始めた場合，R 側の初期失敗が軽く，F 側の初期失敗が重い可能性を排除できない．本研究ではモデル・タスク・seed で識別される初期組を基準に，R/F/D の最初のコードと判定を一致させる．この対応づけは比較の解釈を助けるが，後続生成の乱数や入力長，実行時期まで等しくするものではない．共有初期は比較の必要な条件の一つであり，単独で因果推論を成立させる条件ではない．
また，同じ数の失敗を救済したとしても，その集合が一致するとは限らない．二つの条件がそれぞれ多くを救済しても，片方だけが救済できる対象があれば，実行前にどちらを選ぶかという問題が残る．反対に，成功対象がほぼ重なるのであれば，追加消費や実装の簡単さを重視できる可能性がある．本研究では数と集合の両面を扱い，単一の順位表では捉えにくい介入間の関係を記述する．
本研究の実証的貢献は，選択方策の完成ではなく，選択方策を設計する前に必要な観測単位を整えた点にある．初期失敗，修正履歴，最終成功，追加消費を初期組へ結び付けることで，後から条件の選び方を検討するための根拠を残す．この段階の知見を，そのまま実運用における最適な規則へ置き換えない．記述的な結果を整理する段階と，方策を新しい対象で検証する段階を区別すること自体が，結果を過大解釈しないための研究設計である．

1.6 用語と主張の範囲

本稿の「成功」は主 L3 を満たすという操作的な意味で使用する．利用者のあらゆる意図を満たすことや，任意の量子入力に対して同じ算法を実装することを表す用語ではない．「失敗」はこの評価基準への未達を表し，モデルの一般的能力の欠如を意味しない．評価基準と用語を対応づけることにより，どの判断を機械的に検査し，どの判断を今後の検討に残しているかを区別する．
「救済」は，同じ初期失敗コードを R/F/D で修正し，最終的に主 L3 へ到達した場合に用いる．B4 の成功は，初期組を共有するものの失敗コード自体を修正しないため，「独立再生成による追加成功」とする．P では初期コードを共有しない独立 1 回生成の成績を，B との対応で記述する．これらは最終成功という同じ判定を利用していても，出力を得る手続きが異なる．
「コスト」は，ここでは主にモデル要求に記録された tokens と生成要求時間を指す．利用者の読解時間，電力，実行装置の償却，金銭単価は測定していない．追加 tokens が少ないという観測を，人間の総作業量が同じ割合だけ減ったという主張に置き換えない．同様に，「介入効果」という表現を用いる箇所でも，原則として対応づけた観測上の変化を指し，無作為化比較によって特定された因果効果とは区別する．

2 関連研究

2.1 自己フィードバックによる修正

Self-Refine [1] は，同じ LLM による生成，フィードバック，修正の反復を扱う．本研究の R は，前回コードと課題仕様を与えて自己点検を求める条件であり，外部評価の診断内容を与えない．自己点検だけで救済できる範囲を確認する比較条件として用いる．
原論文と本実装ではプロンプト構成，対象課題，出力制約，モデルが異なる．したがって本研究の R の結果を，原論文の手法全体の性能と同一視しない．先行研究は設計の背景であり，完全再現実験として扱わない．

2.2 実行結果と自己デバッグ

Self-Debugging [2] は，生成コードの説明や実行結果の検討を用いた自己デバッグを扱う．本研究では F を実行ベースの診断を用いる条件，D を同じ診断に加えて説明・原因分析・修正の順序を促す条件として実装した．D の追加指示と出力長の違いを含めて観測する．
D は説明と原因分析を修正版コード先頭のコメントに残す実装である．モデルが内部でどのように推論したかは測定していない．D で救済されたという事実だけから，説明が正しかった，あるいは説明そのものが成功原因だったとは判断できない．

2.3 量子回路コードで確認する対象

本研究は，回路を返す関数の存在，回路の構築と評価処理，指定入力の期待状態または分布，所定の構造要件を区別する．量子回路では，実行可能性と期待出力への適合は別の性質である．測定分布が一致しても，全入力で同じアルゴリズムを実装している保証にはならない．
本研究の位置づけは，選定した量子回路課題の中で介入の救済対象と消費を記述する実験的分析である．一般の量子プログラム全体への網羅的評価や，形式的な同値性証明は対象に含めない．その範囲を明確にしたうえで，成功例と失敗例を同じ分母で扱う．

2.4 自己修正を評価する際の外部情報の役割

自己修正という呼び方には，モデル自身の出力だけを見直す場合と，実行や採点から得た外部情報を使う場合が含まれ得る．本研究では両者を混ぜないため，R と F/D を分けた．R は課題仕様と前回コードに基づく自己点検であり，F/D では検証器が出力した情報が次の要求に入る．同じモデルを使っていても，入力として利用できる情報が変わるので，これらを同じ意味での自己修正と扱うことは適切でない．
Huang ら [6] は推論課題において，外部フィードバックのない自己修正の困難さを論じている．本研究では，自己点検により常に改善すると仮定しないための背景として参照する．同論文が本研究の量子コードや選定モデルで同じ結果を示したと主張するものではない．対象課題，モデル，評価指標の相違を残したまま，外部情報の有無を比較設計で明示するという問題意識に接続する．
外部情報がある場合にも，提示した情報が正しく対象の失敗を指していることが前提となる．評価器のビット順処理や判定条件が誤っていれば，正しい回路に不適切な修正を促す可能性がある．したがって，診断を利用する手法の評価では，診断の有無だけでなく，その診断を作った評価器の仕様と検証履歴を記録しなければならない．本研究が評価方針の修正と到達可能な履歴の再構成を方法へ含めるのは，評価器を単なる受動的な採点装置と扱えないためである．
F と D の相違は説明・原因分析の指示にあるが，この差は入力文の長さや出力コメントにも関係する．そのため，最終成功数の差を説明行の存在だけへ帰属できない．説明が誤っていても偶然にコードが改善する場合や，説明が妥当でも実装が失敗する場合は概念的に区別できる．本研究が直接観測するのは要求と出力と評価の系列であり，内部推論の内容や説明の忠実性を測定する実験ではない．

2.5 量子コード生成ベンチマークとの相違

Qiskit HumanEval [7] は，Qiskit コード生成を評価するための課題群を提示している．量子 SDK を対象としたコード生成でも，生成物の実行と正しさを検証する専用の課題設計が必要になることを示す関連研究として位置づける．本研究の 10 タスクはこのベンチマークからの抽出と位置づけておら

ず，独自の課題仕様，期待出力，構造要件に基づく．名称が近い評価であっても，課題の出典と採点の定義を分離して記述する．
本研究では広範な量子 API の被覆率を最大化するのではなく，同じ初期失敗に複数の介入を適用し，その救済対象を対応づけることを優先した．そのため，課題数を増やした一般的なモデルランキングとは目的が異なる．課題の種類が少ないことは一般化の制約である一方，個々のタスク仕様や履歴を追いやすいという分析上の特徴がある．この特徴を利点だけとして述べず，被覆範囲の限定と合わせて示す．
量子 SDK のコードには，Python の文法と API 利用に関する正しさに加え，構築した回路が目的の状態や分布を生成するという正しさがある．SDK 上での実行可能性だけを検査した場合と，指定出力まで検査した場合では，成功集合が異なり得る．したがって，本研究の主 L3 成功率を他研究の実行成功率と同じものとして比較しない．比較に必要なのは，判定対象，入力範囲，測定方式，失敗時の扱いを明らかにすることである．

2.6 反復生成と再生成対照の位置づけ

同じ課題から複数候補を生成する方法は，単一候補では得られなかった成功を得るための比較対象になる．ただし，複数候補の中から成功したものを選ぶには，候補を評価する手続きも必要である．本研究の B4 は，生成回数だけを増やして採点を無視する条件ではなく，各候補を主 L3 で検査し，成功時に停止する対照である．比較対象は，評価を受ける機会を持った反復的なコード生成手順になる．
本研究の B4 は，既存の初期生成を共通に保持し，失敗した組だけ追加生成する．このため，課題ごとに初めから 4 個の独立候補を一括生成した一般的な設定と完全には一致しない．初期コードの出典，追加生成用の seed 規則，成功時停止という手続きが成績へ関係する．本稿では B4 という操作条件の名前で報告し，別の推定量や他研究の指標と無条件に同一視しない．
修正条件が単回生成より高い成績を得ても，それだけでは診断や前回コードの再利用が役立ったことの証拠にはならない．単に生成要求を追加したことによる機会の増加が含まれるためである．そこで，本研究では初回込み最大 4 回という上限を B4 と R/F/D で対応づける．これは比較を改善する一歩だが，同じ上限にしただけでは入力情報量や消費 tokens を揃えられない．比較で何を揃え，何を揃えていないかを明示する．

3 提案手法

3.1 介入条件と評価指標

3.1.1 共有初期と五つの条件

モデル・タスク・seed の組を初期組と呼ぶ．B は初期生成のみの条件である．R/F/D は B と同じ初期コードと判定を共有し，初期失敗に対して最大 3 回の修正を行う．成功した時点で停止し，以降の修正は行わない．この対応により，初期生成の違いを介入差と混同しにくくする．
R は自己見直し，F は実行結果提示，D は説明・原因分析を促す自己デバッグである．P は初回プロンプトに注意事項を追加して独立に生成する条件であり，同じコードを修正する条件ではない．P の対応比較は，B の初期失敗に対応して成功した場合と，B の初期成功に対応して失敗した場合を分ける．

表1 条件と修正時に与える情報

条件	入力・特徴	生成・停止
B	課題仕様から初期生成	1 回
R	前回コードと自己点検の指示	最大 3 修正・成功時停止
F	前回コードと実行ベースの診断	最大 3 修正・成功時停止
D	F の診断＋説明・原因分析の指示	最大 3 修正・成功時停止
P	課題仕様＋生成前注意事項	独立生成 1 回

3.1.2 独立再生成対照 B4

B4 は初期 1 回を含む最大 4 回生成である．B と同じ初期コード・主 L3 判定を用い，初期成功 455 組は保持する．初期失敗 545 組のみ，前回コードと診断を与えず課題仕様から最大 3 回独立再生成し，主 L3 成功時に停止する．初期失敗からの成功は修正介入による救済と区別する．
5 モデル・10 タスク・base seed 0〜19 は従来と対応するが，追加生成は independent_4_v1 の専用 seed 規則を用いる．temperature 0.7，max_tokens 1,024，timeout 600 秒，並列 1，reasoning_effort none で実行した．上限が同じでも入力情報・実要求数・tokens・実行時期・診断文・出典 schema は等しくない．

3.1.3 主 L3 と出力一致

L0 は生成コードの読込み・import 等と必須インターフェースの要件，L1 は回路構築と評価処理の実行，L2 は指定入力に対する期待出力との一致を表す．主 L3 は L0，L1，L2 および structure_match がすべて真であることと定義する．構造要件には量子ビット数と測定・barrier を除く回路命令数の範囲を用いる．
測定分布の距離は全変動距離 $\mathrm{TVD}(p,q) = (1/2)\Sigma_x |p(x)-q(x)|$ とし，8,192 shots で得た分布と期待分布を比較する．状態ベクトルは大域位相を整合したユークリッド距離を用いる．各タスクで距離 0.05 未満を出力一致とする．測定・変換 seed は 42 に固定したが，有限 shots と指定入力に限られる．
本稿で用いる evaluation_policy_v4 は，測定先から量子ビット順への対応を反映する．タスクに構造制約が明示されていない項目を，一律の制約として追加しない．主 L3 は所定の検査を通過したことを意味し，全入力でのアルゴリズム同値性やプロンプトの全自然言語条件の充足を保証しない．

3.1.4 救済・保持・独立生成の比較

初期主 L3 失敗から最終主 L3 成功に変化した初期組を救済と呼ぶ．救済率 = 救済組数／初期主 L3 失敗組数 とする．初期失敗類型は介入前の B の分類に固定する．修正後の分類で分母を選別すると対象が変わるため，その方法は採用しない．
R/F/D の最終成功には初期成功の無修正保持が含まれる．成功時停止により退行 0 となる設計であり，退行 0 をモデルが常に正しさを維持できる証拠と解釈しない．P では独立生成による改善と悪化の両方を報告する．

3.1.5 量子状態・測定分布とコードの正しさ

本研究の出力評価を理解するには，回路が表す処理と，回路を実行して得られる観測結果を区別する必要がある．量子状態は基底状態に対する複素振幅の組として表され，計算基底での測定確率はその振幅の絶対値の二乗に対応する．したがって，同じ測定確率を持つ状態であっても，相対位相が異なる可能性がある．このことから，分布を検査するタスクと状態ベクトルを検査するタスクでは，確認できる正しさの範囲が異なる．
説明用の例として，二つの基底状態の振幅の符号だけが異なる状態を考える．計算基底で直ちに測定した分布は同じでも，後続の干渉を伴う処理では異なる結果になり得る．この例は評価原理を説明するためのもので，保存コードを新たに実行して得た観測ではない．分布の一致だけから位相まで含めた状態の同一性を結論しないことが，本研究の評価範囲を正しく読むために必要となる．
一方，状態ベクトルの比較では，すべての振幅へ同じ位相を掛ける大域位相を区別しないようにする．本評価器では，実際の状態と期待状態の内積から位相差を求め，その差を整合した後の距離を計算する．単純な複素ベクトルの成分比較では，物理的に区別しない大域位相によって距離が大きくなる場合があるためである．ただし，相対位相の違いを大域位相の整合で打ち消すことはできない．
さらに，指定入力で出力状態が一致していても，回路全体が任意入力で同じ変換を行うとは限らない．ある一つの入力に対して同じ出力を返す二つの回路が，別の入力では異なる出力を返すことはあり得る．本研究の状態評価はタスクに指定された入力に対する評価であり，ユニタリ行列全体の同値性を証明する検査ではない．この区別は，QFT や IQFT など算法名を持つ課題を評価する際にとくに重要である．
構造条件は，出力検査だけでは捉えない課題上の制約を補うために用いる．例えば量子ビット数が仕様と異なる場合には，指定された実装要件を満たしていない．ただし，回路の命令数が範囲に収まることを検査しても，算法の意味を十分に特徴づけたことにはならない．構造検査は指定した必要条件の確認であり，出力検査と合わせて主 L3 を構成する．構造要件へ合格したことを形式検証の完了と表現しない．

3.1.6 段階評価を用いる理由と診断の情報量

段階評価では，どこで検査が止まったかにより，確認済みの性質が異なる．構文や import で止まったコードに対しては，回路の量子出力が正しいかどうかを観測できない．逆に，出力不一致まで進んだコードでは，少なくともコード読込みと回路の構築・評価処理が通過している．すべてを失敗の一語へまとめると，介入が利用できる手掛かりや，修正の到達点を区別しにくくなる．
L0 は構文・import などの読込みと，必須関数を利用できるインターフェースを確認する．関数名が書かれているだけでなく，呼び出し可能であることや，要求された呼出方法に適合することが必要になる．この段階では，回路を実際に構築できることまでは確定しない．L0 を通過したことを，量子コードとして正しいことと同一視しない．
L1 は回路構築と評価処理を実行できる段階である．build_circuit()が回路を返すことや，未束縛パラメータなど評価を妨げる条件がないことも，実装上の確認に関係する．ただし，評価処理を実行できることと，その結果が期待どおりであることは別である．L1 成功から L2 失敗へ進んだ場合には，単に例外を取り除く修正では不十分だった可能性がある．本稿では可能性の説明と個別の原因認定を区別する．
L2 は指定入力に対する期待出力と実測または計算された出力の距離を比較する．主 L3 はこの出力適合性に，所定の構造条件を加える．一つの最終判定へまとめる場合でも，各段階の情報を保持することで，実行不能から実行可能へ変わったが出力はまだ誤っているという途中の改善を記録できる．ただし，本研究の主要指標である救済では最終主 L3 成功を要求するため，途中段階の改善を成功数に加算しない．
診断の情報量は失敗段階によって異なる．構文の位置や import 名は変更候補を直接示す場合がある一方，期待分布との不一致は多くのゲート操作や測定の取り方に関係し得る．この違いから診断が常に同じ難しさで利用できるとは仮定しない．また，失敗分類は最初に露見した問題を表す場合があり，コード内のすべての欠陥を一つずつ列挙したものではない．初期分類を因果的な根本原因の完全な記述として扱わない．

3.1.7 出力距離・測定順序・構造要件の詳細

測定分布の比較では，期待分布と観測分布のキーの和集合を取り，各ビット列の確率差の絶対値を合計して半分にする．出現しなかったビット列の観測確率は 0 として扱う．この定義により，期待して

いなかった出力へ確率が流れた場合も距離へ反映される．本評価では距離が 0.05 未満であることを出力一致とし，ちょうど境界値となる場合は成功へ含めない．
8,192 shots の観測分布には標本変動が含まれる．同じ理想回路でも有限回の測定から得た頻度は期待確率と完全には一致しないため，閾値を設けて比較する．測定 seed の固定は再実行時の変動を抑えるための設定であり，別の seed でも同じ合否になることを証明するものではない．本研究では複数の測定 seed に対する合否の安定性を新たに測定しておらず，閾値近傍の感度分析は今後の課題とする．
測定結果の文字列表現を比較する際には，量子ビットと古典ビットの対応を確認する必要がある．コードがどの量子ビットをどの古典ビットへ測定したかに応じて，結果キーを課題の量子ビット順へ戻さなければ，単なる表現上の並びの違いを量子出力の失敗と誤判定する可能性がある．evaluation_policy_v4 はこの対応を反映する評価方針であり，文字列を無条件に反転すればよいという規則ではない．
状態ベクトルを扱う場合には，測定によって一つの観測結果へ落とし込むのではなく，指定入力から得る複素振幅全体を比較する．現行評価器は対応する純粋状態評価の範囲を定め，非ユニタリ処理や古典操作を含む回路を無条件に同じ評価へ通すことを避けている．この実装上の制限を，量子プログラム一般に対してそのような操作が誤りであるという主張へ広げない．課題仕様と評価方式への適合の問題として扱う．
構造要件のうち回路命令数は，測定と barrier を除いて数える．評価用の読出し操作を追加したことだけで算法本体の命令数が増えたと判定しないためである．量子ビット数や命令数の範囲に加え，測定や古典ビットについて明示的なタスクメタデータがある場合に限り，その要件を適用する．未指定の条件を後から一律に導入すると，課題仕様を満たしていたコードを新たな理由で失敗にする可能性がある．

3.1.8 対応集合による指標の定義

初期組の集合を G とし，そのうち B の主 L3 判定が失敗だった部分集合を U とする．本研究では G の大きさが 1,000，U の大きさが 545 である．条件 c により U の中から最終成功へ到達した集合を S(c)と書けば，修正条件の救済率は S(c)の要素数を 545 で割った値となる．この表記は，条件間で同じ初期対象を比較することと，最終成功集合の全体を混同しないために導入する．
R/F/D では初期成功集合を無修正で保持するため，最終成功数は 455 と救済数の和である．例えば F の最終成功 638 組は，初期成功 455 組と救済 183 組を合わせた数になる．638 を 545 で割ると初期成功を分子へ含めた不適切な率になり，183 を 1,000 で割ると初期失敗に対する救済率ではなく全初期組に対する追加成功割合になる．同じ件数から複数の割合を計算できるため，指標名だけでなく分母を明示する．
F と D の比較では，S(F)と S(D)の共通部分，F 側だけ，D 側だけ，どちらにも含まれない部分へ U を分割する．この四分割は互いに排他的で，合計は 545 になる．両条件が同じ初期組に適用されているため，周辺の成功率だけでなく，個々の対象が一致しているかを調べられる．全体差が小さくても片側の成功が多数あるという結果を，この四分割が捉える．
P では B のコードを修正しないので，B で失敗だった対象に対応する P の成功と，B で成功だった対象に対応する P の失敗を別に数える．B4 では初期成功を保持し，初期失敗への追加候補を評価するため，失敗対象からの追加成功集合を S(B4)として対応づけられる．ただし，集合の記法が同じでも操作内容は同じではない．記号上の比較の便利さを理由に，修正と独立生成の違いを消さない．
層別分析では，モデル，タスク，初期失敗類型などで U を分割し，各層の分母と成功数を示す．全体率は層別成功数の合計を層別分母の合計で割った値であり，各層の率の単純平均とは一般に一致しない．少数の失敗しかない層で高い率が得られても，全体に同じ比率で寄与するとは限らない．本研究のカタログでは，率の大小だけで判断せず，対象数も一緒に読める形を基本とする．

3.2 実装と記録の検証

3.2.1 ハーネスの構成

実装は Python を中心とし，tasks/が課題仕様・期待値・構造条件を，harness/interventions/prompts.py が条件別の修正指示を保持する．harness/llm_clients.py がモデル要求を扱い，harness/experiment.py 等が初期共有と反復を管理する．harness/evaluator.py と harness/readout.py が回路と出力を検証する．これらの責務を分け，生成の失敗と評価の不具合を区別して追跡する．

評価対象コードは build_circuit()を定義し，QuantumCircuit を返すインターフェースを前提とする．測定分布と状態ベクトルのどちらを検査するかはタスク仕様で定める．実装環境の依存範囲は requirements.txt に保持し，過去の実験の実行環境を現在の環境から推定して埋めない．保存設定・ハーネス版・モデル digest は元実験 manifest を参照する．

3.2.2 失敗分類とモデル接続障害

構文，import，必須インターフェース，回路構築，出力不一致，量子ビット数などの分類を記録する．コード側の import_error や build_error は介入の対象となる実験結果である．一方，モデル API の接続エラーやタイムアウトは生成されたコードの品質と分けて検証する．
保存分類 unknown の 1 組は原因確認記録を伴う生成コード側の失敗として現行集計に含まれる．unknown というラベルだけで API 障害とは判断しない．固定出典の検証状態を参照し，未解決の実行・評価問題を確定結果のように扱わない．

3.2.3 到達可能な履歴の再構成

評価方針の修正は，停止する時点や次に与える診断文を変えることがある．保存コードを新しい評価で再採点するだけでは，新診断を受けて生成されるはずの後続コードを再現できない．そこで，検証済みの保存済み前半履歴（prefix）と，必要な部分追試の後半履歴（suffix）を接続した現在の到達経路を主結果とする．
部分追試は 293 ケースで，新 suffix は 647 round である．分岐後に到達できない旧保存 suffix を現在の経路に流用しない．初期生成から全件を新評価で生成し直した実験とは区別する．現行の到達 round は 9,249 であり，5,000 条件記録とは集計単位が異なる．

3.2.4 集計の整合性と静的履歴分析

固定集計では全 5,000 条件の対応，欠落・重複・予定外記録，共有初期の一致，成功時停止，層別分母の合計，出典と到達コードの hash を検査した．固定 sanity report は成功しており，欠落・重複・予定外記録・共有初期不一致は 0 である．本稿の表は公開 CSV から取得し，旧値を転記して混在させない．
片側救済 83 組については両条件 166 履歴，398 修正遷移をコード文字列として静的確認した．import/API，回路構築・インターフェース，量子ゲート等のテキスト，測定・出力取得を複数該当可で注記した．生成コードを実行しない分析であり，変更の意味や因果的寄与は別の検証を要する．

3.2.5 生成・評価・停止を結ぶ処理の流れ

処理は，課題仕様とモデル設定の読込み，初期コードの生成，コードの抽出と評価，条件別の次要求の作成，停止判定，記録の保存という流れで構成する．重要なのは，生成要求を送った回数と，保存された条件記録数が同じではない点である．一つの条件記録は初期コードと複数の修正 round を含み得る．条件の最終結果だけを取り出しても，そこへ到達するためにどれだけの生成を行ったかは分からない．
共有初期コードは，B と R/F/D の出発点を揃えるための記録である．同じモデル・タスク・seed の組で初期コードが一致することに加え，初期判定や参照先が整合しているかを確認する．コード文字列が同じでも評価方針が異なれば停止判断が変わる可能性があるため，コードの hash だけでは十分でない．評価プロファイルと初期判定を合わせて確認する．
初期失敗だった場合，R/F/D では前回コードを条件別の指示へ組み込み，必要に応じて実行診断を追加する．修正コードを評価した後，主 L3 へ到達していれば停止する．失敗が続き，最大 3 回の修正へ達していなければ，その round のコードと判定から次の要求を作る．したがって，後続の要求は初期失敗分類だけではなく，途中の出力と評価へ依存する逐次的な手続きである．
この逐次性により，最終 round だけを比較すると，どの情報が与えられていたかや，どの失敗段階を経由したかを見落とす．本研究は round の順序，コード hash，評価分類，出典 prefix/suffix を保持して追跡する．最終成功率と履歴分析は代替関係ではなく，異なる粒度で同じ経路を説明するための分析となる．履歴の途中で失敗分類が変わった場合にも，初期類型別の分母は変更しない．

3.2.6 履歴再構成における分岐と到達性

評価器の修正を考える説明用の例として，保存時に失敗と判断されたコードが，新評価では成功になる場合を考える．この場合，新評価を使う手続きではその時点で停止するため，保存されていた次 round のコードは現在の手続きでは生成されない．後続コードを残して都合のよい最終判定を採用すると，成功時停止という設計と矛盾する．再採点後に成功へ変わることは，後続履歴をそのまま保持してよいことを意味しない．
逆に，保存時の成功が新評価では失敗になる場合，現行手続きならさらに修正すべきところで保存履歴が終了している可能性がある．その後のコードは保存されていないため，再採点だけでは補えない．また，成功・失敗の別が変わらなくても，診断文が変われば F/D の次の要求が変わる．診断が後続生成へ入る条件では，採点変更の影響を最終フラグだけに局限できない．
本研究の現在の主経路は，そのような分岐の影響を受けない保存 prefix を利用し，必要な範囲に新しい suffix を接続したものである．suffix を接続する際には，直前のコードや判定，出典が対応することを確認する．接続先の根拠を失うと，異なる履歴の一部を寄せ集めて一つの条件が実際に辿り得たように見せる危険がある．到達可能性の確認は，保存データを多く残すことより優先される．
部分追試 293 ケースという数と，接続された新 suffix647 round という数は単位が異なる．一つの追試ケースに複数 round が生じるため，両者の大小を記録の欠落や重複と解釈しない．同様に，現在の到達 round9,249 は，本体の 5,000 条件記録と対応するが同じ母数ではない．本研究ではどの単位の件数なのかをラベルと manifest へ残し，論文の率の分母に誤用しない．
この方法は，すべての過去生成を一つの条件へ完全に揃え直す操作ではない．保存 prefix の生成時期や要求ログの完全性，元 schema の違いは残る．したがって，再構成経路の比較は現在採用した経路に関する記述として報告する．保存資産を利用して評価の整合性を回復したことと，全条件を同一時期に新生成した比較実験を行ったことを分けて扱う．

3.2.7 記録の検証と失敗の切り分け

記録検証では，予定されたモデル・タスク・seed・条件の組合せを先に定め，実際の記録と照合する．記録総数が予定件数と同じでも，一部が重複し別の一部が欠けている可能性がある．そのため，件数の一致に加えてキーの集合差と重複を検査する．予定外記録も別に数え，単に総件数へ足して完了率を高く見せない．
共有初期の検証では，同じ初期組に属する B と R/F/D の初期コードや評価が一致していることを確認する．成功時停止の検証では，成功した後に追加生成を行っていないか，最大修正回数を超えていないかを確認する．また，最終評価が実際の到達 round と一致するかを照合する．これらはモデルの成績とは独立したハーネスの整合性検査であり，失敗率が高いこと自体を検証不合格とするものではない．
生成コードのエラーと API 接続障害は異なる集計対象である．生成したコードの import が失敗した場合は，モデル出力が実行環境に適合しなかった結果として含める．一方，要求を送れなかった場合や応答が得られなかった場合には，その対象についてコード品質を観測できていない．両者を同じ失敗として合算すると，生成の可用性とコードの正しさを混同する．
保存分類 unknown_error がある場合にも，ラベルだけで接続障害やモデルの能力を判断しない．本研究の初期分類に含まれる 1 組は，原因確認により未定義変数 sim に関係する NameError と整理された．B4 追加 round の unknown_error2 件もコード側の未定義変数によるものである．このように，分類ラベル，例外の由来，最終集計へ含める根拠を分けることで，不明なものを都合よく成功または障害へ振り分けることを避ける．
公開用の検証資料には，出典ファイル名，保存設定，検証状態，hash，集計表を残す一方，生成コード全文や生の API 応答を無条件に含めない．再現性はすべての内部記録を公開することと同義ではない．どの公開集計から論文表を生成できるかを明確にし，詳細記録を参照する際の粒度を区別する．本稿に記載する hash は内容の同一性を確認するための識別子であり，コードの意味的な正しさを保証するものではない．

3.2.8 静的履歴分析の観察単位

片側救済集合を選ぶ際には，まず F/D の最終主 L3 判定から集合を定義し，その集合に属する全 83 組を対象とした．都合のよい数例だけを抜き出すと，説明しやすい変更を過大に強調するおそれがある

ため，片側集合全体の両条件を追う．ただし，この選択は F/D の不一致に焦点を当てる分析であり，共通成功や双方失敗を含む全 545 組の変更頻度を推定するための標本抽出ではない．
静的変更分類では，import/API，回路構築・インターフェース，量子ゲート等のテキスト，測定・出力取得を注記する．一つの遷移や履歴で複数領域に該当し得るため，カテゴリ件数の合計が対象組数を超えても矛盾ではない．互いに排他的な失敗類型の表と，重複可能な変更領域の表では，合計の読み方が異なることを明示する．
例えば，ある修正で import 文と回路の測定処理が同時に変わり，その後に成功したとしても，どちらの変更が必要だったかを静的差分だけでは分離できない．さらに，ゲート名の出現数が変わったことは，作用順序や引数の変化を十分に表すものではない．同じゲート名の数でも異なる回路になり得るため，文字列特徴を量子回路の意味そのものと解釈しない．
この分析の役割は，救済対象の不一致がどの初期類型に現れ，どのような文字列上の修正領域と同じ履歴に存在したかを，追跡可能な形で残すことである．意味的寄与を確かめるには，個別変更を分離した検証や，回路の作用に基づく別の分析が必要になる．本稿ではその作業を今後の課題とし，今回の静的確認だけで機構の解明が完了したとは主張しない．

3.3 実験設定と出典

3.3.1 対象モデルと課題

対象は Q4，G4，Q9，C7，G3 の 5 モデルである．正式なモデルタグは表 2 に示す．タグ中の数値を厳密なパラメータ数とみなさず，モデル識別子として扱う．各モデル 200 初期組であり，10 タスクと seed 0〜19 を含む．
タスクは Bell，GHZ，Deutsch–Jozsa constant/balanced，Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz の 10 種類である．各タスクは指定入力・期待値を持つ．タスク名が同じでも任意入力を網羅する評価ではない．ハーネスの難度分類を利用するが，普遍的な難しさを表す尺度として解釈しない．

表2 モデルの略号と識別子

略号	モデルタグ	初期組数
Q4	qwen3.5:4b	200
G4	gemma4:e4b-it-qat	200
Q9	qwen3.5:9b	200
C7	qwen2.5-coder:7b	200
G3	gemma3:4b	200

3.3.2 生成条件と元実験の区別

temperature は 0.7，1 要求の生成上限は 1,024 tokens，最大修正回数は 3 回である．保存設定では reasoning_effort は none，timeout_sec は 600，parallel_requests は 1 である．実際に生成された長さは可変であり，上限の同一性は消費量の同一性を意味しない．
元実験は，3 モデル seed 0〜9 の 1,500 条件記録，5 モデル seed 10〜19 の 2,500 条件記録，残り 2 モデル seed 0〜9 の 1,000 条件記録に分かれる．schema や診断文処理の差を保持したうえで，初期組と条件を対応づける．元実験 ID と保存設定の参照先は付録（8.1 節）に示す．
旧 120 件は 2 モデル，seed 0〜2，2 条件，L2 終了の既報であり，現行の主 L3 による 5,000 条件記録へ合算しない．旧評価，保存コードの再採点，部分追試を三つの独立した主結果として並べない．本稿は 2026-10-16 版の固定スナップショット [3] を唯一の主集計とする．

3.3.3 追加コストと修正回数の集計方針

追加修正コストは共有初期生成を除き，失敗した修正への消費を含めた入力＋出力 tokens の合計である．tokens／救済は総追加 tokens を救済組数で割る．要求時間は保存された elapsed_sec の合計であり，評価時間や全工程の所要時間ではない．
保存 prefix の過去の記録値と，新 suffix の部分追試時の実測値を分離して保持する．合計は再構成した経路に対する計算値である．金銭単価を測定していないため，金銭費用の削減とは呼ばない．修正上限別の集計も同じ最大 3 修正の観測履歴を区切ったものであり，上限ごとに独立実験した結果ではない．

3.3.4 課題集合の役割と被覆範囲

Bell と GHZ は，多量子ビット間の相関を持つ状態の生成と測定を扱う課題として含める．これらが本ハーネスで易に分類されていても，生成コードが常に正しいとは限らない．API や測定方法の誤りがあれば，算法自体の説明が短い課題でも実行や出力の失敗が起こり得る．難度ラベルは人間にとっての普遍的な難しさやモデルにとっての実際の難しさを測定した尺度ではない．
Deutsch–Jozsa の constant と balanced は，課題条件に応じた期待出力を区別する二つのタスクとして数える．同じ算法名の下でも，条件が異なれば生成コードや評価対象が異なる．したがって，10 タスクという集計では二つを別タスクとして扱う．Bernstein–Vazirani と Grover もそれぞれ指定された対象に対する課題であり，任意の秘密列や任意の探索空間へ一般化した評価ではない．
QFT と IQFT は状態ベクトルを比較する課題として含まれる．分布評価だけでは見えにくい位相の違いを指定入力に対して確認するが，変換全体の同値性検査ではない．QPE は指定した位相推定設定に対する測定分布を確認する．Ansatz も指定された構成と出力を持つ課題であり，任意の変分回路を設計する能力を網羅的に評価しているわけではない．算法名の広い意味と本課題の狭い実装仕様を区別する．
課題集合には，分布と状態の評価方式，量子ビット数，構造制約，使用する回路要素の違いが含まれる．そのため，タスク別成績は単一の難度順へ還元できない．成功率の差には，初期生成でどの種類の誤りが多かったか，出力検査が何を要求するか，修正プロンプトがどの情報を与えるかなど複数の要素が重なる．この分解を十分に行わない段階では，低い救済率を特定の量子算法への理解不足だけで説明しない．

3.3.5 生成設定を揃える意味と限界

同じ temperature を使うことは，各要求のサンプリング設定を揃えるための条件である．しかし，異なるモデルで同じ数値を指定しても，出力の多様性や正解確率が等しくなるとは限らない．モデルの学習内容，語彙，量子化，推論実装などが異なるからである．本研究では temperature の値を設定情報として報告し，モデル間の確率的な挙動が同一であるとは仮定しない．
1,024 tokens という生成上限は，要求ごとの最大出力量を揃える．ただし，実際の出力長は条件と対象に応じて変わる．D では説明・原因分析をコメントとして出力するため，同じ上限内でコード以外の記述が占める割合も変わり得る．このことは比較の条件に含まれるが，今回の集計だけから，出力が長いことが成功を妨げたか，説明が有効だったかを分離して断定することはできない．
timeout と並列要求数は，要求をどのように実行するかの運用条件である．逐次実行であっても，サーバの他の負荷やモデルのロード状態が常に等しいとは限らない．要求時間の比較にはその影響が入り得るため，tokens と時間を同じ意味のコストとして扱わない．時間は保存された要求の経過値であり，評価や待機のすべてを含む工程時間として再解釈しない．
seed の指定は，どの生成をどの初期組へ対応づけるかを再現するための設定として保持する．同じ seed 番号で異なるモデルを呼び出しても，同じ意味の出力候補が得られるわけではない．B4 の追加生成には専用規則があるため，R/F/D と同じ番号を使った同一乱数条件の比較とも呼ばない．本研究の対応は，モデル・タスク・base seed で識別した同じ初期問題を起点とする対応である．

3.3.6 固定出典と執筆時点の切り分け

実験レポートが継続更新されている環境では，執筆日が新しいことと，本文で採用する結果が新しく生成されたことは区別しなければならない．本稿の主結果は 2026-10-16 版の固定到達経路に基づき，B4 は 2026-10-22 固定の完了集計を加える．今回の本文拡充により，新しいモデル要求や生成コード評価を実行したわけではない．既存結果を説明する文章を増やしても，データの実験時点は変わらない．
固定出典を採用する理由は，本文，表，図，考察が同じ集合と判定から導かれるようにするためである．執筆途中で自動更新レポートの数値だけを転記すると，過去の評価値と現在の到達経路が混ざる可能性がある．本研究では結果表の出典と hash を記録し，本文の数値をそこへ照合する．集計処理を変更した場合には，元の固定ファイルを上書きするのではなく，変更理由と別の出典を明示する．
公開集計には，実験 ID，保存設定，記録の完備性，集計上の単位を残す．一方，モデルの生出力や例外の全文を本文へ大量に掲載することが，本研究の説明力を直接高めるとは限らない．本文では検証した性質と残る制約を言語化し，詳細な追跡は manifest と CSV へ接続する．数値の根拠を追えることと，読者が分析上の意味を理解できることを両立させる構成とする．

4 結果

4.1 全体の救済率

1,000 初期組中，初期成功 455 組，初期失敗 545 組であった．表 3 に条件別の救済を示す．R は 96 組（17.6%），F は 183 組（33.6%），D は 180 組（33.0%）を救済した．F と D は本対象の初期失敗のおよそ 3 分の 1 を救済し，R を上回った．全体率は 545 組を分母とする合算値であり，モデル率の単純平均ではない．
R/F/D の最終成功は 551，638，635 組で，初期成功 455 組の無修正保持を含む．F と D の最終成功差は 3 組だが，これは同じ対象を救済したことを意味しない．集計単位と分母をそろえ，件数と率を併記して解釈する．

表3 初期失敗 545 組に対する救済

条件	救済組数	救済率	最終成功／1,000
R	96	17.6%	551
F	183	33.6%	638
D	180	33.0%	635

4.2 モデル別・初期失敗類型別の結果

表 4 のモデル別集計では，G4 で F48/62 組，D38/62 組に対し，Q4 では F78/162 組，D90/162 組と大小が入れ替わる．C7 は両条件 23/65 組，G3 は両条件 1/190 組であった．モデルごとの初期失敗数は異なるため，救済数だけを比較しない．G3 の 190 失敗組も全体分母に含める．
表 5 では import 失敗に対して F58/271 組（21.4%），D72/271 組（26.6%），回路構築失敗に対して F76/126 組（60.3%），D68/126 組（54.0%）であった．出力不一致は F24/65 組，D18/65 組である．初期分類とモデル・タスクの関連があるため，この表だけから最適な介入選択を決めない．少数分母の率は参考値として扱う．

表4 モデル別の救済組数（括弧内は率）

モデル	失敗分母	R	F	D
Q4	162	31 (19.1%)	78 (48.1%)	90 (55.6%)
G4	62	30 (48.4%)	48 (77.4%)	38 (61.3%)
Q9	66	15 (22.7%)	33 (50.0%)	28 (42.4%)
C7	65	15 (23.1%)	23 (35.4%)	23 (35.4%)
G3	190	5 (2.6%)	1 (0.5%)	1 (0.5%)

表5 初期失敗類型別の救済組数

初期失敗	分母	R	F	D
import 失敗	271	24	58	72
回路構築失敗	126	32	76	68
構文誤り	68	21	25	21
出力不一致	65	16	24	18
IF 不適合	11	1	0	1
量子ビット数	3	2	0	0
保存分類 unknown	1	0	0	0

4.3 タスク・難度別の結果

表 6 に全 10 タスクの分母と件数を示す． Bell は F10/34 組・D12/34 組，GHZ は 12/35 組・13/35 組，QFT は 34/67 組・34/67 組，QPE は 13/94 組・11/94 組であった．同じ救済数でも分母が異なる場合がある．また同じタスク内にモデルと seed の違いが含まれる．

ハーネス難度別では易が F22/69 組・D25/69 組，中が 79/225 組・79/225 組，難が 82/251 組・76/251 組であった．難度間の差にはタスク構成の違いが含まれる．モデル×タスクや元実験別・seed ブロック別の分母は固定 CSV に保持しており，集約値だけを根拠に一般化しない．

表6 タスク別の救済組数

タスク	失敗分母	R	F	D
Bell	34	2	10	12
GHZ	35	9	12	13
DJ constant	42	6	12	16
DJ balanced	48	7	25	24
BV	62	13	19	24
Grover	73	14	23	15
QFT	67	21	34	34
IQFT	50	3	17	15
QPE	94	10	13	11
Ansatz	40	11	18	16

4.4 F と D の救済対象の重なり

表 7 のとおり，F と D の共通救済は 140 組，F のみ 43 組，D のみ 40 組，双方未救済 322 組であった．片側だけで救済された組は合計 83 組である．少なくとも一方が救済した 223/545 組（40.9%）は，両条件の結果を見て作った集合である．実行前の選択方策の成功率として扱わない．

全 83 組の両履歴を確認したところ，初期 import 失敗は F のみ 8 組・D のみ 22 組，回路構築失敗は 19 組・11 組であった．救済側の履歴で import/API 関係の変更が F のみ 28/83 組・D のみ 34/83 組，回路構築・インターフェース関係が 24/83 組・32/83 組，量子ゲート等のテキスト変更が 38/83 組・32/83 組，測定・出力関係が 11/83 組・16/83 組に認められた．重複を許す全 83 組に対する注記である．

静的変更は失敗側にも現れ得る．同じ遷移で複数箇所が変わるため，特定の変更を成功原因と断定しない．全例を除外なく記録し，該当なしや最後まで失敗した履歴も CSV に含めた．

表7 F/D の救済対象の分割（分母 545 組）

共通	F のみ	D のみ	双方未救済
140	43	40	322

4.5 追加消費と 3 回目の修正

表 8 の追加 tokens／救済は R18,852.6，F9,333.8，D10,976.6 であった．総追加 tokens は R1,809,845，F1,708,086，D1,975,782 である．そのうち最終的な未救済例への消費は R1,618,684，F1,374,240，D1,605,388 tokens を占める．成功例だけに消費が発生するわけではない．

round 別救済は R が 57，20，19 組，F が 112，43，28 組，D が 108，39，33 組であった．表 9 に 3 回目の分母と消費を示す．F は 2 回後未救済 390 組から 28 組（7.2%），D は 398 組から 33 組（8.3%）を追加救済した．2 回で区切ると，3 回までに救済できたうち F15.3%，D18.3%を失う．

3 回目の消費は F491,676，D588,970 tokens であり，最後まで失敗した例への消費も含む．救済を失う割合と追加消費を併記することで，対象範囲で停止方策を検討する材料になる．一般的に 2 回か 3 回のどちらが最適かは，この結果だけでは決められない．

表8 初期生成を除く追加消費（未救済を含む）

条件	保存 tokens	新 tokens	tokens／救済	秒／救済
R	1,809,845	0	18,852.6	911.1
F	1,213,947	494,139	9,333.8	444.2
D	1,408,702	567,080	10,976.6	553.6

表9 3 回目の追加救済と消費

条件	追加／未救済	追加 tokens	要求秒	2 回で失う割合
R	19/468	559,141	24,812.3	19.8%
F	28/390	491,676	21,765.5	15.3%
D	33/398	588,970	28,117.5	18.3%

4.6 P の独立生成としての比較

P は B の初期失敗に対応する成功 124/545 組（22.8%）と，初期成功に対応する失敗 106/455 組（23.3%）を生じ，最終成功は 473/1,000 組であった．B との差 18 組には改善と悪化の双方が含まれる．R/F/D と異なり，同じ初期コードの修正効果を表す指標ではない．
P の 1,000 独立生成の記録消費は 764,083 tokens である．これは修正型の共有初期を除く追加消費と集計範囲が異なる．P の結果を修正型の救済率に単純に並べて，費用効率の優劣を結論づけない．

4.7 独立再生成 B4 との比較

B4 実験 independent_4_full_20261020T185811381595Z は 2026 年 10 月 21 日に全 1,000 組を完了した．欠落・重複・予定外記録はいずれも 0 で，sanity 検証は成功した．追加 round の保存分類 unknown_error 2 件は生成コード内の未定義変数による NameError であり，API 接続障害ではない．
執筆時に追加生成・生成コード実行は行っていない．
B4 は初期失敗 545 組中 217 組（39.8%）で成功し，最終成功は 672/1,000 組（67.2%）であった．表 10，表 11，表 12 に全体・モデル・初期失敗類型別の比較を示す．R96 組（17.6%），F183 組（33.6%），D180 組（33.0%）に対し，B4 の成功数は F より 34 組，D より 37 組多かった．この観測により，修正条件と単回生成だけの比較から介入自体の効果を論じることはできない．
B4 と F の共通成功は 131 組，B4 のみ 86 組，F のみ 52 組，双方未成功 276 組であった．B4 と D では共通 120 組，B4 のみ 97 組，D のみ 60 組，双方未成功 268 組であった．独立再生成が多く成功しても，修正介入だけが成功する対象も残る．事後的な和集合を事前の選択成功率とは扱わない．
B4 の追加要求は 1,342 回，追加 tokens は 995,815，追加 tokens／追加成功は 4,589.0 であった．共有初期は一度だけ数え，追加消費から除外し，最後まで未成功の例への消費を含めた．R/F/D は過去の保存 prefix と必要な suffix の再構成値であり，B4 との要求時間・tokens 差を同時期の同一入力条件の実測費用差とは解釈しない．

表10 最大 4 回生成での比較（初期失敗 545 組）

条件	追加成功	率	最終成功	追加 tokens
B4	217	39.8%	672	995,815
D	180	33.0%	635	1,975,782
F	183	33.6%	638	1,708,086
R	96	17.6%	551	1,809,845

表11 モデル別の初期失敗からの成功

対象	失敗分母	B4	R	F	D
Q4	162	66	31	78	90
G4	62	51	30	48	38
Q9	66	37	15	33	28
C7	65	47	15	23	23
G3	190	16	5	1	1

表12 初期失敗類型別の初期失敗からの成功

対象	失敗分母	B4	R	F	D
import 失敗	271	67	24	58	72
回路構築失敗	126	77	32	76	68
構文誤り	68	24	21	25	21
出力不一致	65	46	16	24	18
IF 不適合	11	2	1	0	1
量子ビット数	3	0	2	0	0
保存分類 unknown	1	1	0	0	0

4.8 全体成績と分母の関係の詳解

F の救済率 33.6%と最終成功率 63.8%は，同じ条件の結果を異なる分母と分子で表した指標である．前者は初期失敗 545 組のうち 183 組が修正で成功したことを表し，後者は初期成功 455 組の保持を含めて 1,000 組中 638 組が成功したことを表す．両者を並べることで，初期生成が担った部分と，修正が追加した部分を区別できる．

D では初期成功 455 組に救済 180 組を加えた 635 組が最終成功であり，R では 455 組に 96 組を加えた 551 組となる．この構造のため，R/F/D の最終成功数の差は救済数の差と一致する．一方で，P は初期成功を保持する条件ではないので，同じ分解をそのまま適用できない．初期成功側に対応する悪化も数える必要がある．

F と D の救済数の差は 3 組であるが，これは両条件の成功集合が 3 組だけ異なることを意味しない．F だけが成功した 43 組と D だけが成功した 40 組があり，差し引きが 3 組となる．同じ全体差でも，両条件がほぼ同じ対象を成功させる場合と，多くの対象で入れ替わる場合は運用上の意味が異なる．本研究の結果は後者の違いを無視できないことを示す記述である．

初期失敗 545 組のうち，F でも D でも救済しなかった 322 組が残る．これは，二つの診断利用条件を比較しても，対象失敗のすべてを解決できていないことを表す．成功集合の説明だけでなく，未救済集合の大きさを併記することで，次の手法を検討すべき範囲を明確にする．ただし，この 322 組が他の介入でも必ず失敗するという意味ではない．

4.9 モデル別結果の読み解き

Q4（qwen3.5:4b）は 200 初期組のうち初期成功 38 組，初期失敗 162 組であった．修正による救済は R31/162 組（19.1%），F78/162 組（48.1%），D90/162 組（55.6%）である．B4 による追加成功は 66/162 組（40.7%）であった．同じモデルの中では分母が共通なので件数と率が対応する一方，別のモデルとの比較では初期失敗集合の大きさと構成が異なる．

G4（gemma4:e4b-it-qat）は 200 初期組のうち初期成功 138 組，初期失敗 62 組であった．修正による救済は R30/62 組（48.4%），F48/62 組（77.4%），D38/62 組（61.3%）である．B4 による追加成功は 51/62 組（82.3%）であった．同じモデルの中では分母が共通なので件数と率が対応する一方，別のモデルとの比較では初期失敗集合の大きさと構成が異なる．

Q9（qwen3.5:9b）は 200 初期組のうち初期成功 134 組，初期失敗 66 組であった．修正による救済は R15/66 組（22.7%），F33/66 組（50.0%），D28/66 組（42.4%）である．B4 による追加成功は 37/66 組（56.1%）であった．同じモデルの中では分母が共通なので件数と率が対応する一方，別のモデルとの比較では初期失敗集合の大きさと構成が異なる．

C7（qwen2.5-coder:7b）は 200 初期組のうち初期成功 135 組，初期失敗 65 組であった．修正による救済は R15/65 組（23.1%），F23/65 組（35.4%），D23/65 組（35.4%）である．B4 による追加成功は 47/65 組（72.3%）であった．同じモデルの中では分母が共通なので件数と率が対応する一方，別のモデルとの比較では初期失敗集合の大きさと構成が異なる．

G3（gemma3:4b）は 200 初期組のうち初期成功 10 組，初期失敗 190 組であった．修正による救済は R5/190 組（2.6%），F1/190 組（0.5%），D1/190 組（0.5%）である．B4 による追加成功は 16/190 組（8.4%）であった．同じモデルの中では分母が共通なので件数と率が対応する一方，別のモデルとの比較では初期失敗集合の大きさと構成が異なる．

G4 と Q4 では F と D の救済件数の大小が入れ替わる．全体で F が 3 組多いという結果を，すべてのモデルで F が多いという規則へ拡張できない．また，C7 の F/D の救済件数が同じでも，その成功集合まで同じであるとは限らない．件数の一致と集合の一致は別の検査を要するため，必要に応じて対応する初期組を調べる．
G3 の初期失敗 190 組は，全体の失敗 545 組の一部を大きく占める．このモデルの分母を除いて率を高く見せたり，別の分母の比較を全体率として報告したりしない．一方で，G3 の低い救済件数を，あらゆる課題やプロンプトにおけるモデル能力の普遍的な結論へ置き換えない．生成上限，選定タスク，実行環境，出力形式の制約を含んだ観測として解釈する．
モデルごとの率を平均する方法では，初期失敗が 62 組の G4 と 190 組の G3 へ同じ重みを与えることになる．本研究の全体率はそれとは異なり，全初期失敗を一つの集合として数える．集計方法によって強調される比較の単位が違うため，合算率とモデル平均率を互換的に使わない．本稿では合算率を主指標とし，モデル表で層別の違いを補う．

4.10 初期失敗類型別結果の読み解き

初期の import 失敗は 271 組であった．R/F/D の救済件数はそれぞれ 24 組，58 組，72 組であり，B4 の追加成功は 67 組である．これらは修正後に当該類型へ変わった組を加えた数ではなく，最初にこの類型だった同じ集合に対する結果である．F と D の救済率は 21.4%と 26.6%であり，初期失敗全体に対する率とは分母が異なる．
初期の回路構築失敗は 126 組であった．R/F/D の救済件数はそれぞれ 32 組，76 組，68 組であり，B4 の追加成功は 77 組である．これらは修正後に当該類型へ変わった組を加えた数ではなく，最初にこの類型だった同じ集合に対する結果である．F と D の救済率は 60.3%と 54.0%であり，初期失敗全体に対する率とは分母が異なる．
初期の構文誤りは 68 組であった．R/F/D の救済件数はそれぞれ 21 組，25 組，21 組であり，B4 の追加成功は 24 組である．これらは修正後に当該類型へ変わった組を加えた数ではなく，最初にこの類型だった同じ集合に対する結果である．F と D の救済率は 36.8%と 30.9%であり，初期失敗全体に対する率とは分母が異なる．
初期の出力不一致は 65 組であった．R/F/D の救済件数はそれぞれ 16 組，24 組，18 組であり，B4 の追加成功は 46 組である．これらは修正後に当該類型へ変わった組を加えた数ではなく，最初にこの類型だった同じ集合に対する結果である．F と D の救済率は 36.9%と 27.7%であり，初期失敗全体に対する率とは分母が異なる．
初期のインターフェース不適合は 11 組であった．R/F/D の救済件数はそれぞれ 1 組，0 組，1 組であり，B4 の追加成功は 2 組である．これらは修正後に当該類型へ変わった組を加えた数ではなく，最初にこの類型だった同じ集合に対する結果である．少数の対象に基づくため，件数を伴わない率だけの比較を避ける．
初期の量子ビット数不適合は 3 組であった．R/F/D の救済件数はそれぞれ 2 組，0 組，0 組であり，B4 の追加成功は 0 組である．これらは修正後に当該類型へ変わった組を加えた数ではなく，最初にこの類型だった同じ集合に対する結果である．少数の対象に基づくため，件数を伴わない率だけの比較を避ける．
初期の実行時失敗（保存分類 unknown）は 1 組であった．R/F/D の救済件数はそれぞれ 0 組，0 組，0 組であり，B4 の追加成功は 1 組である．これらは修正後に当該類型へ変わった組を加えた数ではなく，最初にこの類型だった同じ集合に対する結果である．少数の対象に基づくため，件数を伴わない率だけの比較を避ける．
import 失敗と回路構築失敗では，F/D の救済数の関係が異なった．このことは，実行診断があるかどうかという一つの特徴だけでは結果の違いを十分に記述できないことを示す．ただし，モデルやタスクの構成が類型ごとに異なるため，類型そのものが F/D の相対的成績を生じさせたという因果解釈はしない．どの組がその類型へ入ったのかを含めた対象の違いとして読む．
出力不一致の初期失敗では，コードは少なくとも出力を評価できる段階まで進んでいる．その後の成功は単なる構文修正だけでは説明しにくいが，測定処理や戻り値の修正と回路操作の修正を今回の集計だけから分離することもできない．「意味的な失敗」という広い呼び方を用いる場合にも，算法の論理が必ず誤っていたと決めつけず，実際の検査段階に沿って解釈する．
少数類型では，一組の変化が率を大きく動かす．初期失敗 1 組の類型で B4 が成功しても，それだけで未知の同類型へ高い成功確率を期待する根拠にはならない．本稿はその一組を除外せず件数として残

すが，選択規則を立てるための十分な標本数があるとも扱わない．対象をすべて含めることと，一般化できる強さの主張を行うことは別の問題である．

4.11 全 10 タスクの結果と難度の読み方

Bell の 100 初期組では，初期失敗 34 組に対して R は 2 組，F は 10 組，D は 12 組を救済した．B4 は同じ失敗集合のうち 13 組が追加成功した．F/D の率は 29.4%／35.3%，B4 の追加成功率は 38.2%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
GHZ の 100 初期組では，初期失敗 35 組に対して R は 9 組，F は 12 組，D は 13 組を救済した．B4 は同じ失敗集合のうち 14 組が追加成功した．F/D の率は 34.3%／37.1%，B4 の追加成功率は 40.0%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
DJ constant の 100 初期組では，初期失敗 42 組に対して R は 6 組，F は 12 組，D は 16 組を救済した．B4 は同じ失敗集合のうち 16 組が追加成功した．F/D の率は 28.6%／38.1%，B4 の追加成功率は 38.1%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
DJ balanced の 100 初期組では，初期失敗 48 組に対して R は 7 組，F は 25 組，D は 24 組を救済した．B4 は同じ失敗集合のうち 19 組が追加成功した．F/D の率は 52.1%／50.0%，B4 の追加成功率は 39.6%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
BV の 100 初期組では，初期失敗 62 組に対して R は 13 組，F は 19 組，D は 24 組を救済した．B4 は同じ失敗集合のうち 31 組が追加成功した．F/D の率は 30.6%／38.7%，B4 の追加成功率は 50.0%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
Grover の 100 初期組では，初期失敗 73 組に対して R は 14 組，F は 23 組，D は 15 組を救済した．B4 は同じ失敗集合のうち 36 組が追加成功した．F/D の率は 31.5%／20.5%，B4 の追加成功率は 49.3%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
QFT の 100 初期組では，初期失敗 67 組に対して R は 21 組，F は 34 組，D は 34 組を救済した．B4 は同じ失敗集合のうち 30 組が追加成功した．F/D の率は 50.7%／50.7%，B4 の追加成功率は 44.8%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
IQFT の 100 初期組では，初期失敗 50 組に対して R は 3 組，F は 17 組，D は 15 組を救済した．B4 は同じ失敗集合のうち 22 組が追加成功した．F/D の率は 34.0%／30.0%，B4 の追加成功率は 44.0%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
QPE の 100 初期組では，初期失敗 94 組に対して R は 10 組，F は 13 組，D は 11 組を救済した．B4 は同じ失敗集合のうち 12 組が追加成功した．F/D の率は 13.8%／11.7%，B4 の追加成功率は 12.8%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
Ansatz の 100 初期組では，初期失敗 40 組に対して R は 11 組，F は 18 組，D は 16 組を救済した．B4 は同じ失敗集合のうち 24 組が追加成功した．F/D の率は 45.0%／40.0%，B4 の追加成功率は 60.0%である．タスク別の結果は 5 モデルを合わせた集計であり，特定モデルだけの成績を示すものではない．
QFT の F/D の救済数が一致していても，個々の成功対象の一致を意味しない．また，QPE の初期失敗が多いことと，修正による追加成功がどれだけ得られるかも別の性質である．初期性能が低いタスクには修正対象が多く残るが，その対象が容易に直せるとは限らない．初期失敗数，救済数，最終未救済数を一緒に読むことで，初期生成と修正を混同しない比較ができる．
難度別の集計はハーネスが事前に付与した易・中・難の区分を使う．その区分はタスク名から普遍的な難度を証明したものではない．とくに，難の中には異なる出力評価方式を持つタスクが含まれるため，区分ごとの成績の差を単一の認知的難しさに帰属できない．本研究では補助的な層別記述として用い，タスクごとの内訳を残す．
各タスクの初期組数は同じでも，初期失敗数は異なる．そのため，全体の救済率はタスク成功率の単純平均ではなく，失敗数の多いタスクに大きい重みを持つ．特定の運用先でタスク頻度が本研究の集合と異なる場合，本研究の全体率をそのまま期待値に用いることはできない．適用先のタスク構成を確認することがカタログ利用の前提になる．

4.12 救済集合の重なりの詳細

import 失敗の初期失敗 271 組を F/D の対応で分けると，共通救済 50 組，F のみ 8 組，D のみ 22 組，双方未救済 191 組となる．この内訳は，類型別の周辺成功数だけでは分からない成功対象の重なりを示す．ある条件の成功数が大きいことと，他条件が成功した対象をすべて含むことは同じではない．
回路構築失敗の初期失敗 126 組を F/D の対応で分けると，共通救済 57 組，F のみ 19 組，D のみ 11 組，双方未救済 39 組となる．この内訳は，類型別の周辺成功数だけでは分からない成功対象の重なりを示す．ある条件の成功数が大きいことと，他条件が成功した対象をすべて含むことは同じではない．
出力不一致の初期失敗 65 組を F/D の対応で分けると，共通救済 14 組，F のみ 10 組，D のみ 4 組，双方未救済 37 組となる．この内訳は，類型別の周辺成功数だけでは分からない成功対象の重なりを示す．ある条件の成功数が大きいことと，他条件が成功した対象をすべて含むことは同じではない．
構文誤りの初期失敗 68 組を F/D の対応で分けると，共通救済 19 組，F のみ 6 組，D のみ 2 組，双方未救済 41 組となる．この内訳は，類型別の周辺成功数だけでは分からない成功対象の重なりを示す．ある条件の成功数が大きいことと，他条件が成功した対象をすべて含むことは同じではない．
全体では F/D 共通 140 組と片側 83 組から，少なくとも一方で成功した対象は 223 組になる．この 223 組を最大限利用するには，どちらが成功するかを事前に知るか，両方を実行して選ぶ必要がある．前者は今回の観測結果だけでは実現できず，後者には別の追加消費が発生する．したがって，和集合の率 40.9%を単独の実行可能な介入の性能として報告しない．
片側 83 組を全件確認したことは，その集合内で説明に使う事例を恣意的に選ばなかったことを意味する．しかし，片側集合自体が成功判定に基づく選択であり，全失敗集合の無作為標本ではない．変更領域の頻度を全 545 組の一般的傾向と同一視しない．対象選択の条件を固定した上で履歴を追えることが，本分析の範囲になる．

4.13 追加消費の総量と未成功例の負担

修正の消費を評価する際に，成功した履歴だけを選んで平均すると，失敗し続けた履歴で使った生成が見えなくなる．実際にある介入を適用する場合，どの対象が成功するかは実行前には分からないため，失敗する対象への消費も負担しなければならない．本研究はその負担を含めた総追加 tokens を救済数で割り，対象集合に介入を適用したときの記録上の消費を示す．
F の総追加 tokens は 1,708,086 であり，そのうち未救済例への消費は 1,374,240 であった．D では総追加 1,975,782 に対し未救済 1,605,388，R では総追加 1,809,845 に対し未救済 1,618,684 である．これらの数値は，成功を得るまでの短い履歴だけを見て追加消費を評価することの限界を示す．未救済へ多くを使ったからといって，実行前にその対象を無料で判別できるとは限らない．
tokens／救済は，総追加消費と得られた救済数を一つの値へまとめる指標である．同じ値でも，多くの対象を安く救済する場合と，少数の対象に集中して成功する場合では，利用上の意味が違い得る．また，未救済への消費が含まれるため，一件の成功した履歴が平均してその tokens を使ったという意味でもない．指標の名称に「一救済あたり」とあっても，個別履歴の長さと同一視しない．
B4 の追加 tokens／追加成功 4,589.0 は，同じ初期失敗 545 組への追加要求を合計して 217 組で割った値である．F の 9,333.8 や D の 10,976.6 と数値上比較できるが，前回コードや診断を入力するかどうかで入力長が異なり，出典時期も違う．この比較から，本研究の記録における計算資源の使い方の違いを記述できる一方，同条件で診断を削除すれば同じ割合だけ tokens が減るという因果的な予測はできない．
生成要求時間についても，保存 prefix と新 suffix の時期が異なり，サーバ負荷や再送処理の違いが残る．要求時間の合計を，利用者が最初から最後まで待った時間へ換算しない．本研究では金銭単価，評価を含む全工程時間，電力を測定していないため，実務上の費用対効果の全体を示したとは主張しない．

4.14 追加生成の順序と停止による損失

R の初回後の追加成功は，順に 57 組，20 組，19 組であった．最初の追加生成だけでは 57/545 組，二つ目までには 77/545 組，三つ目までには 96/545 組が追加成功する．各 round の対象はそれ以前に未救済だった組であり，回を重ねるごとに残る対象が変わる．

F の初回後の追加成功は，順に 112 組，43 組，28 組であった．最初の追加生成だけでは 112/545 組，二つ目までででは 155/545 組，三つ目までででは 183/545 組が追加成功する．各 round の対象はそれ以前に未救済だった組であり，回を重ねるごとに残る対象が変わる．
D の初回後の追加成功は，順に 108 組，39 組，33 組であった．最初の追加生成だけでは 108/545 組，二つ目までででは 147/545 組，三つ目までででは 180/545 組が追加成功する．各 round の対象はそれ以前に未救済だった組であり，回を重ねるごとに残る対象が変わる．
B4 の初回後の追加成功は，順に 119 組，55 組，43 組であった．最初の追加生成だけでは 119/545 組，二つ目までででは 174/545 組，三つ目までででは 217/545 組が追加成功する．B4 は独立再生成の順序であり，R/F/D の修正 round とは手続きが異なる．
後半 round の成功数が減ることは，その round が無意味であることを表さない．先の round で成功した対象は既に停止しており，後半にはそれまで成功しなかった対象が残る．各 round を初期の同じ対象集合へ独立に適用した実験ではないため，単純な成功件数の減少を，追加要求の効力が回数に比例して低下する法則と解釈しない．
F の 3 回目の 28 組は，2 回後に未救済だった 390 組から得られた追加救済である．D の 33 組は 398 組から得られた．一方で，2 回で止めたときに失う 15.3%と 18.3%は，最終救済 183 組と 180 組を分母にした割合である．同じ 3 回目の寄与を表す場合でも，残存対象に対する追加成功率と，得られるはずだった救済の損失率では分母が異なる．
本結果は，すべての対象に最大 3 回修正した観測履歴を，途中で区切って計算したものである．上限 2 回と最初から指示した別の実験では，モデルの出力や利用者の行動が変わる可能性がある．したがって，今回の打切り集計から上限 2 回という運用方策の性能が直接確定するとは考えない．停止方策の検証では，事前に停止条件を固定した独立の評価が必要になる．

4.15 B4 を加えた成功集合の交差

B4 と F の共通成功 131 組，B4 のみ 86 組，F のみ 52 組という内訳から，B4 の成功数が F より多くても，F で得られる成功がすべて B4 へ含まれるわけではないことが分かる．同様に，B4 と D の共通 120 組，B4 のみ 97 組，D のみ 60 組から，D だけが追加成功へ導いた対象が残る．総件数で最大だった条件を選んでも，他条件でのみ得られた成功を無条件に回収できるわけではない．
三条件の交差集計では，B4/F/D のすべてで成功した対象は 101 組，B4 のみ成功は 67 組，F のみ成功は 13 組，D のみ成功は 21 組であった．B4 と F だけが成功した 30 組，B4 と D だけが成功した 19 組，F と D だけが成功した 39 組もある．どの条件でも成功しなかった対象は 255 組である．これら八つの集合は互いに排他的で，合計 545 組になる．
三条件の少なくとも一つで成功した対象は 545 組から 255 組を除いた 290 組となる．この 290 組も事後的な集合であり，単一方策の成功数ではない．三条件すべてを実行すれば得られる可能性のある集合を示す参照ではあるが，実行順序，停止，共有できる情報，消費の計算を別に定めなければ運用上の成績へ変換できない．
B4 を加えても 255 組が残ることは，本研究で試した条件の被覆範囲を示している．その原因が必ず量子論理の難しさにあるとも，生成機会を増やせば解決するとも，今回の結果からは決められない．より長い出力上限，別の入力説明，別モデル，追加の検査などは候補として考えられるが，それらを行った結果を本稿は持たない．未成功集合を将来の検証対象として明示する段階に留める．

5 考察

5.1 再生成対照を含む解釈

本対象では B4 の初期失敗からの成功率 39.8%が F33.6%，D33.0%を上回った．したがって，実行結果を与える修正が独立再生成より常に有用であるとは結論づけられない．一方で F のみ 52 組，D のみ 60 組があり，再生成だけで全介入の成功を包含しない．介入カタログには独立再生成，対象分母，入力情報，追加消費も記載する．
B4 は初回込み最大 4 回という生成機会の上限を合わせた比較である．成功時停止による実要求数，入力 tokens，専用 seed 規則，実行時期，保存・追試経路の違いが残る．診断情報の因果効果や統計的有意差をこの集計から認定しない．次は同時期・同一評価設定で方策を事前固定し，別 seed・タスクで比較する必要がある．

5.2 介入で何が変わったか

本対象では，実行結果を使う F と D が，外部診断を与えない R より多くの初期失敗を救済した．これは，課題仕様だけでなく実行に基づく診断を使う条件が有用だったという観測である．ただし F と D にはプロンプト構成や出力消費の違いもあり，情報の各要素の寄与を分離した実験ではない．
F と D の全体差 3 組に対し片側救済は 83 組であった．全体率の近さは，救済する対象の同一性を意味しない．G4 と Q4 で大小が入れ替わり，import 失敗と回路構築失敗でも傾向が異なる．介入を選ぶには，全体率に加え，対象の失敗構成と適用範囲を確認する必要がある．

5.3 介入カタログへ向けた解釈

初期失敗類型別の結果は，介入カタログの候補を作る根拠になる．例えば import 失敗と回路構築失敗では F/D の観測された救済率が異なる．しかし，同じ類型でもモデルやタスクの構成が異なり，類型だけを入力にした選択規則の有効性は未検証である．
F/D の和集合 223 組は事後的に得られる上限的な参照集合である．実行時に正解の介入を事前に選べるわけではない．両方を実行する方策を検討する場合も，追加消費や停止条件を含めた独立の評価が必要になる．

5.4 内的妥当性と再構成経路

共有初期コードによって初期生成の違いを抑えている一方，同一タスク・ seed の依存が残る．5,000 条件記録を独立な 5,000 標本として扱わない．元実験には schema や診断文処理の差もあるため，差を消して単一の同条件実験だったと表現しない．
現行経路は検証済み保存 prefix と必要な新 suffix の組合せである．停止やフィードバックの影響を受ける部分は追試しているが，全件の新生成とは異なる．古い要求ログが完全には残らない出典もあり，負荷・待機・再送の影響を完全には分離できない．コストはこの再構成経路の記録に限った計算値である .

5.5 評価範囲・一般化・静的分析の限界

主 L3 は指定入力の出力と所定の構造要件に限定される．全入力の正しさ，すべての自然言語指示，等価なアルゴリズム実装を保証するものではない．有限 shots・指定入力による評価範囲の制約，生成長上限による出力制約，モデル digest・量子化・サーバ負荷の影響も考慮する必要がある．
片側救済 83 組を全件確認しても，静的差分だけで変更の意味的寄与は特定できない．ゲート名の増減は量子論理の訂正の証拠にはならず，複数同時変更がある．さらに，今回の 5 モデルと 10 タスクから，モデルの一般的優劣や介入の普遍的優位を断定しない．本研究では因果効果や統計的有意差を主張しない．

5.6 修正と再生成を比較したときに分かること

B4 の追加成功が 217 組で F/D を上回ったことは，初期失敗後にコードを直すことを当然の第一選択とみなす設計を再検討する材料になる．本研究の対象と設定では，課題仕様から新しく候補を作る方法にも，多くの追加成功があった．ただし，この結果だけで過去コードの利用が有害だったと結論する

ことはできない．入力情報と生成の手続き，seed 規則，記録の出典が同時に異なっているからである．
修正で前回コードを利用することには，正しかった部分を保存しながら変更するという設計上の意図がある．しかし，前回の構造を保持し過ぎる場合や，長い入力へ診断を加える場合など，独立再生成と異なる条件が生じる．これらは結果を説明し得る仮説であり，今回の実験が直接分離して検証した機構ではない．考察では，観測した差と，その差を説明する候補を明確に分ける．
また，B4 は修正と同じ上限回数を持つが，入力 tokens の予算を揃えた比較ではない．同じ数の要求を許す設計と，同じ tokens 予算を許す設計では，比較の対象となる効率の意味が変わる．前者は生成機会の上限に関する比較であり，後者は利用資源を一定にした比較になる．どちらが実運用に適切かは，要求単位の制限や待機時間，入力長など，利用する環境の目的に応じて決める必要がある．
成功時停止の有無も重要である．B4 と R/F/D はいずれも成功後に生成を続けないので，実際の要求数は対象ごとの成功時点に依存する．同じ最大回数という表現から，すべての組で 4 回ずつモデルを呼び出したと読み取るのは誤りである．本研究の費用表が上限回数だけでなく追加要求数を残すのは，成功と消費の関係をこの粒度で理解するためである．
B4 で成功数が多い一方，F のみ 52 組，D のみ 60 組が残ったことから，単純に一つの条件へ置き換えることで全成功を維持できるわけではない．カタログでは，最大の全体率を持つ条件だけを残すのではなく，対象の違いを候補の適用範囲として記述する．その上で，実行前に利用可能な特徴から選べるかどうかを，別の評価問題として設定する．

5.7 介入カタログの記載項目と利用単位

本研究における介入カタログは，失敗名と推奨条件を一対一で結ぶ早見表だけを意味しない．一つの項目には，適用対象の条件，初期失敗の定義，試した介入の入力情報，生成と停止の上限，成功数と分母，追加消費，検証状態，出典をまとめることを想定する．この記述形式は本研究の観測結果を利用しやすくするための提案であり，カタログを使った方策の成績を今回実証したという主張ではない．
適用対象には，モデル識別子，課題種類，出力評価方式，API 環境，初期失敗分類を含める．例えば import 失敗の項目を参照する場合でも，対象 SDK や利用可能な API が異なれば，本研究の修正成績をそのまま当てはめられない．モデルタグのみでなく，可能な範囲でモデル digest や量子化，評価プロファイルを出典へ結び付ける．同じ呼び名のモデルが異なる保存設定で利用された場合も，その違いを消さない．
観測欄には成功率とともに，成功数と対象数を必ず残す．少数例の高率と，多数例の中程度の率を区別できるようにするためである．また，初期分類を固定していること，成功時停止による初期成功保持を含むかどうか，P や B4 が修正と異なる操作であることも書く．利用者が指標の分母を再解釈しなくても読める形が望ましい．
資源欄には，未成功消費を含む総追加 tokens，追加要求数，成功あたりの比率を分けて置く．生成要求時間を掲載する場合は，評価時間や全工程時間ではないことを併記する．保存 prefix と新 suffix の再構成値である場合には，その由来を残す．これにより，異なる時期や負荷の記録を精密な実測速度の順位として誤用することを防ぐ．
判断欄には，観測から直接言えることと，次の検証が必要なことを分ける．例えば「この集合では D の救済数が F より多かった」は観測である．「今後の import 失敗には必ず D を使う」は方策の提案であり，別の検証を要する．カタログの有用性は断定的な推奨の数で決まるのではなく，利用者が根拠と適用範囲を確認できることにある．

5.8 カタログ項目案：import 失敗

import 失敗の項目では，対象を初期分類 import_error の 271 組と明記する．R24 組，F58 組，D72 組が救済し，B4 は 67 組が追加成功した．F/D の片側内訳は F のみ 8 組，D のみ 22 組であり，この集合では D 側の救済件数が多かった．この記述は，初期類型とモデル・タスクの構成を含んだ観測である．
介入の候補としては，実行診断から API 名や読み込み箇所を見直す F，説明・原因分析を促す D，課題から作り直す B4 を残す．ただし，本研究の診断文が SDK 文書の正しい修正例を網羅的に提供したわけではない．診断が示した名前をどう変更すべきかをモデルが必ず判断できるという保証もない．存在しない API を別の存在しない API へ置き換えた場合など，失敗の形が変わっても救済に至らない可能性がある．

運用時の確認項目として，実行環境で利用できる SDK の版，import 対象，関数呼出しの位置，前回コードをどこまで保持するかを記載する．これらは今後の適用前に確認すべき項目であり，本研究が各要因の因果的影響を測定したわけではない．カタログは失敗の原因を自動的に確定する装置ではなく，適用条件を整理する文書として位置づける．
この類型で D が多かったことを理由に，他類型へ D を一律に推奨しない．また，B4 の 67 組と D の 72 組の差は成功対象の一致を意味せず，双方が成功する集合と片側だけの集合を必要に応じて調べる余地がある．今回の表から直接得られる件数と，追加分析で初めて得られる情報を区別して記録する．

5.9 カタログ項目案: 回路構築失敗

回路構築失敗の対象は 126 組であり，R32 組，F76 組，D68 組が救済し，B4 は 77 組が追加成功した．F/D の対応では共通 57 組，F のみ 19 組，D のみ 11 組，双方未救済 39 組であった．この集合では F の救済数が D より多いが，D だけが救済した 11 組も存在する．F と B4 の件数が近いことも，処理内容や成功対象まで同じという意味にはならない．
回路構築の失敗には，回路オブジェクトの操作，関数呼出し，戻り値，未束縛パラメータなど，実装段階で起こる複数の問題が関係し得る．本分類は検査の実行段階に基づくラベルであり，根本原因が単一であると仮定しない．診断を使う条件の比較では，エラー内容の粒度や，前回コードのどの部分が入力へ残るかを同時に確認する必要がある．
カタログ上は，回路を作れる段階への到達と，最終主 L3 成功を区別して記載する．構築エラーを解消して出力不一致へ進んだ場合，評価は先へ進んでいるが主要指標の救済はまだ達成していない．途中段階の改善を記述する欄を設けても，それを最終成功数へ合算しないことが重要である．進捗と完了の区別を失うと，介入の実用性を過大評価し得る．
候補の選択では，診断をそのまま使う F の簡潔さと，D による明示的な分析，B4 による作り直しを比較対象として残す．今回の結果だけで説明が余分だった，あるいは自己分析が構築を妨げたと結論しない．違いを説明する仮説を立てる場合には，入力長と出力コメントなど他の変化を揃えた検証計画を併記する．

5.10 カタログ項目案: 出力不一致と少数類型

出力不一致の 65 組では R16 組，F24 組，D18 組が救済し，B4 は 46 組が追加成功した．この集合では独立再生成の追加成功が修正条件より多かったが，その差を量子論理の修正ができなかったことだけで説明しない．出力取得や測定順序の処理も期待出力への適合に関係し，保存分類はすべての潜在原因を分解したものではないためである．
この項目の適用条件には，分布評価か状態ベクトル評価か，指定入力は何か，距離閾値は何か，構造要件が何かを含める．別の入力や別の評価方式へ変えたときに成功集合が維持されるとは限らない．指定出力の不一致というラベルだけで，すべての量子算法の誤りを同じ種類として扱わない．評価の適用範囲を明確にすることが修正対象を選ぶ前提になる．
構文誤りは 68 組あり，R21 組，F25 組，D21 組，B4 の追加成功 24 組であった．構文の問題は表面的な書式だけに見える場合があるが，生成上限やコード抽出，出力の切れ方など複数の要因を確認する余地がある．ただし，本研究がすべての構文エラーの原因を出力打切りと認定したわけではない．分類から原因へ短絡しない書き方をカタログでも維持する．
インターフェース不適合 11 組，量子ビット数不適合 3 組，保存分類 unknown の実行時失敗 1 組は，分母が小さい．記録から削除するのではなく件数をそのまま示すが，単一の高率・低率から選択規則を確定しない．実行時失敗の原因確認と API 障害の区別も注記する．対象数の不足は，結果を曖昧に隠す理由ではなく，主張の強さを調整する根拠になる．

5.11 カタログ項目案: 独立再生成と停止条件

B4 は修正条件とは別の操作候補としてカタログへ登録する．対象は初期失敗集合，入力は課題仕様であり，前回コードや診断を渡さない．初回込み最大 4 回，成功時停止，専用 seed 規則という手順を併記する．217 組の追加成功と 995,815 tokens という総消費を示すことで，単に「再生成が良い」という一般論ではなく，どの手順をどの集合で観測したかを残す．
停止条件は，介入の名前と独立に扱うべき設計要素である．同じ F でも，常に最大 3 回まで続ける場合と，特定の分類で打ち切る場合では成功と消費が変わる可能性がある．本研究の 3 回目の寄与は，

より短く止めたときに失う成功を示す材料である．しかし，失敗分類の変化に応じた適応的停止の成績を観測したわけではないため，その方策を実証済みと記載しない．
カタログ項目の利用者が選ぶ目的も明確にする必要がある．追加要求数を抑えたいのか，tokens を抑えたいのか，成功する対象を増やしたいのかで，許容する操作は変わる．これらは必ずしも同じ条件を最良にしない．本稿では一つの効用関数を恣意的に導入して順位を確定せず，成功，対象，消費の複数指標を並べて判断材料とする．
将来の方策案として，最初に独立再生成を行い，未成功なら診断を使う方法や，初期分類から F/D を選ぶ方法などが考えられる．ただし，保存履歴を後から組み合わせるだけでは，その方策で実際に与えられるコードや診断を再現できない場合がある．提案段階では手順を明示し，成績を確かめる段階では実際に到達可能な逐次経路を評価する必要がある．

5.12 内的妥当性：共有初期と交絡

本研究の共有初期は，介入の比較を同じコードから始めるための設計である．これにより，初回生成の偶然の違いをそのまま介入差として数える問題を抑えられる．しかし，F/D の入力の違いには診断の構成や指示文の長さが含まれ，B4 では前回コードを渡さないという大きな違いがある．比較で一つの要素だけを変えたとみなせないため，観測差から特定要因の因果的寄与を抜き出さない．
初期失敗集合への条件づけも結果の読み方に影響する．初期性能が高いモデルで残る失敗は，少数ながら修正しにくいものに偏っているかもしれない．初期性能が低いモデルでは，API 利用など別の問題が多いかもしれない．これは考えられる対象選択の問題であり，今回の結果がどちらかを直接証明したわけではない．初期失敗だけを比較する研究では，モデルごとの分母と構成を報告する必要がある．
実行時期と保存経路の違いも交絡し得る．R/F/D には過去の保存 prefix と必要な追試 suffix が含まれ，B4 は別時期の追加生成である．同じモデルタグを使っていても，利用環境や負荷，完全には残っていない要求ログの違いを排除できない．本研究は出典を隠して一つの同時実験と表現するのではなく，それらを保持した比較として報告する．
成功時停止により，成功後の品質変化は観測していない．そのため，修正型の退行 0 という結果から，正しいコードを再度修正しても壊さないと結論できない．この設計は成功したコードを利用する運用として自然であっても，モデルの編集安定性を測定する別の実験とは区別される．保持された初期成功を介入の積極的な成果として過大計上しない．

5.13 構成概念妥当性：主 L3 と実用上の正しさ

主 L3 は，対象コードを一貫した手続きで評価するための操作的な定義である．しかし，利用者が実用上求める正しさには，任意入力への動作，数値安定性，読みやすさ，保守性，実機制約など，今回の検査に含まれない性質もある．したがって，主 L3 成功をそのまま本番利用可能性の保証へ置き換えない．本研究は指定された課題仕様と検査範囲に対する比較である．
構造条件の命令数の範囲は，明示された実装要件へ近づけるための検査だが，意味的に正しい回路を完全に特徴づけるものではない．同じ命令数で異なる作用を持つ回路はあり得るし，等価な処理を別の分解で書いた場合に命令数が変わる可能性もある．このため，構造要件は出力検査と合わせて解釈し，命令数の一致だけで算法を実装したと認定しない．
指定入力での出力一致も，入力集合が限られた評価である．別入力を追加すると成功集合が変わり，その変更が成功時停止とフィードバックを変える可能性がある．評価範囲を広げる将来実験では，保存コードの再採点で得られる情報と，新しい診断の下で必要になる後続生成を区別しなければならない．評価を強くしたこと自体を新しい介入の改善と混同しない．
静的変更分析が捉えるのはコード文字列の変化であり，実際の量子変換の意味的な差ではない．この構成概念の差を明示しないと，ゲート名が変わったという観察から，量子論理を正しく修正したという強い結論へ飛躍する．本稿では静的特徴を履歴を整理する注記として用い，意味的な修正分類を完成させたと主張しない．

5.14 外的妥当性：モデル・課題・環境の範囲

本研究は 5 モデルと 10 タスクを対象としているが，量子プログラミングのすべての利用場面を代表するものではない．複数ファイルのプロジェクト，長い会話履歴，外部ツールの検索，大規模回路の最

適化などは本設計へ含まれていない．独立した build_circuit()を生成する課題で得た結果を，より複雑な開発工程の生産性へ直接一般化しない．
モデル識別子にはタグを使うが，モデルの能力をタグ中の数値だけで説明しない．学習内容，コードへの適応，量子化，推論実装などが同時に異なるためである．今回の結果が特定のパラメータ数の効果や量子化方式の効果を分離した実験ではないことを明確にする．モデル間の大小は，保存設定の下での観測として示す．
タスクの出現頻度も実環境と一致するとは限らない．本研究では各モデルと各タスクへ同じ数の base seed を割り当てたが，運用先で多いのが import 失敗なのか，複雑な出力不一致なのかによって，カタログのどの項目が重要になるかは変わる．合算率を他環境の期待成功率として使う前に，対象分布の相違を確認する必要がある．
測定はシミュレーション上の所定の方法で行っており，実機のノイズや接続制約を含めた実行品質を評価したわけではない．本研究の成功は量子回路コードが定義した検査を満たすことであって，実機上で同じ分布が得られる保証ではない．実機向けのカタログを構築する場合には，ノイズ，回路変換，実行費用など別の条件を設計へ加える必要がある．

5.15 統計的解釈と探索的分析の位置づけ

同じ初期組へ複数条件を適用した記録は対応を持ち，異なる条件の 5,000 件を独立な 5,000 標本として扱うことはできない．さらに，同じタスクを異なる seed やモデルで繰り返しているため，依存の単位は初期コードだけに限定されない．標本数を大きく見せるために条件や round を独立例として数えると，推定の不確かさを過小評価するおそれがある．
本稿は件数と率，集合の重なり，追加消費を記述する探索的分析であり，統計的有意差を主張しない．例えば F と D の差が 3 組であることを，有意な差がないという検定結果と同じ意味で述べない．有意差を検定していないことと，差が存在しないと証明したことは異なる．同様に，モデル別の率の差が大きく見えても，今回の設計だけで普遍的な順位を認定しない．
将来統計的な推定を行う場合には，どの母集団へ一般化するかを先に定める必要がある．同じ 10 タスクの別 seed へ適用する推定と，未知の量子算法タスクへ適用する推定では，考慮すべき変動の単位が異なる．初期組の対応を保ち，タスク単位や出典単位の依存も考慮した設計を検討する．本稿はその方法を実施済みの解析として数値付きで報告するものではない．
多くの層別集計を調べると，偶然に大きい差を持つ組合せを見つける可能性がある．その差を見てから最も良い条件を選び，同じデータで選択の有効性を報告すれば，評価が楽観的になる．本研究がカタログの候補整理と実行前の方策検証を分けるのは，この探索と評価の混同を避けるためでもある．

5.16 今後の比較実験の設計案

第一の計画は，介入選択を事前固定する比較である．選択に使う特徴を，初期失敗分類，モデル，タスクの評価方式など実行前に観測可能な情報へ限定する．過去データから候補規則を作る場合でも，規則の決定に使った集合と検証する集合を分ける．その後，固定した規則の下で実際に生成・評価を行い，成功数と総追加消費を報告する．
第二の計画は，要求数上限を揃える比較に加え，tokens 予算を揃えた比較を設計することである．前回コードや診断を含める条件では入力が長くなるため，同じ要求数でも資源配分が異なる．予算の定義には入力と出力の両方を含めるか，失敗要求や再送をどう扱うか，評価時間を含めるかを明示する．複数の予算設定を試す場合にも，結果を見て最も有利な設定だけを主結果に選ばない計画が必要である．
第三の計画は，F と D の差をより限定して調べる比較である．診断の内容を合わせた上で，説明・原因分析を求める指示と出力制約を整理し，入力長や生成上限の違いを記録する．説明の有無だけが変化したと呼べる範囲を明確にする．必要なら説明の妥当性を別の基準で注記するが，成功したから説明も正しいという循環した採点は避ける．
第四の計画は，停止方策の検証である．固定回数での停止，失敗分類が変わらない場合の停止，残り予算に応じた停止などの候補を，実行前に定義する．停止方策は次に与える情報や候補数も変えるため，過去の履歴を機械的に貼り合わせて成績を確定しない．実際にその方策で到達可能な経路を生成し，停止により失った成功と節約した消費を同じ分母で測定する．
第五の計画は，主 L3 の感度確認である．測定 seed，距離閾値，入力集合，生成上限を変えた場合に，成功集合と条件間の対応がどれだけ変わるかを調べる．その際，評価の変更が停止や診断へ及ぶ部分

を明示する．保存コードを再採点する感度分析と，変更後の評価の下で生成する実験を，異なる結果として報告する．これらは今後の設計案であり，本稿の執筆で新たに実施したものではない．

5.17 再現可能な資料作成と変更管理

実験データから論文へ数値を移す工程でも誤りは生じ得る．例えば，旧評価の表と新しい到達経路の考察を組み合わせたり，分母が違う率を同じ表へ入れたり，独立再生成の成功を修正による救済と呼んだりする問題である．本稿では公開 CSV と固定 snapshot を生成元へ結び付け，表と本文を照合する．文書作成の再現性は実験の再現性と別の層として検査する．

本文の拡充では，説明の文章を増やしても固定結果の件数を変更しない．新たに記述した比率や差は，既存件数から行う記述的な計算に限る．原因の説明や運用上の提案は考察として区別し，それを支える新しい実験を行ったように書かない．この区別により，文章量の増加が根拠のない主張の増加にならないようにする．

Word の見出し番号，表番号，参照，目次は，ページ数の増加に合わせて再生成する．本文の内容が変わらなくても，表の分割やフォント置換でページが移動するため，PDF の実際の見出し位置と目次を照合する．元の原稿を保持し，更新前後の文字数とページ数を記録することで，どの資料が今回の拡充に対応するかを追跡できるようにする．

公開用の出典には，固定集計の hash，生成元，検証状態を残す．内部の raw 出力や秘密情報を新しく本文へ含めることはしない．読者が論文の数値と公開集計の一致を確認できること，生成器を再実行して同じ内容を作れること，体裁の制約と未確認事項が明らかなことを，文書作成の品質として扱う．

6 おわりに

6.1 研究成果

本研究では，LLM が生成した Qiskit 量子回路コードの初期失敗を，修正介入がどれだけ，どの対象で救済するかを分析した．1,000 初期組のうち失敗 545 組に対し，R96 組，F183 組，D180 組を救済した．今回の対象では F と D が R より多くを救済した．
F と D の救済数は近かったが，共通 140 組，F のみ 43 組，D のみ 40 組であり，片側救済 83 組を認めた．全 83 組の 166 履歴と 398 遷移を静的に整理した．追加消費は未救済例も含め，3 回目の追加救済と停止回数を減らした際の損失を明示した．
独立再生成 B4 は同じ初期失敗 545 組中 217 組（39.8%）で成功し，最終成功は 672 組となった．F/D のみが成功する組も残り，独立再生成を含む選択・停止方策の検証を今後の課題とする．

6.2 今後の課題

第一に，介入の選び方と停止条件を事前固定し，別 seed・タスクで検証する．その際，事後的に最も良い結果を選ぶ評価と区別し，追加要求数と消費を含めて報告する必要がある．第二に，静的変更の意味を人手で確認し，複数同時変更の寄与を分ける検証方法を設計する．
第三に，測定乱数，生成長の上限，モデル digest や実行負荷への感度を調べる．主 L3 を拡張する場合は，過去の成功時停止とフィードバックへの影響を監査する．同じ保存設定と出典を保持し，必要な追試を明示的に計画する．これらの追加実験は今回の資料作成では行っていない．

6.3 研究課題への回答

第一の問いである救済の量について，本対象の初期失敗 545 組に対し，自己見直し R は 96 組，実行結果提示 F は 183 組，自己デバッグ D は 180 組を救済した．救済率はそれぞれ 17.6%，33.6%，33.0% である．この結果は，初期成功の保持を除いた修正の追加的な到達範囲を表す．指定したモデル・タスク・生成条件・評価基準の下での観測として報告する．
第二の問いである救済対象の違いについて，F/D の共通救済 140 組に対し，F のみ 43 組，D のみ 40 組があり，合計 83 組で最終結果が異なった．全体差が 3 組であっても，個々の成功対象は同一でなかった．片側 83 組の両条件 166 履歴・398 修正遷移を静的に確認し，初期失敗類型や変更領域との対応を整理した．意味的な成功原因の分離は今後の課題として残る．
第三の問いである追加消費と修正回数について，共有初期を除き未救済への消費を含めた tokens／救済は，R18,852.6，F9,333.8，D10,976.6 であった．3 回目の修正は F28 組，D33 組を追加救済し，2 回で止めると最終救済の 15.3%，18.3%を失う打切り結果となった．消費と救済を併記する必要性を示したが，一般的な最適回数は確定していない．
追加対照 B4 について，同じ初期失敗から 217 組が追加成功し，最終成功 672 組，追加 tokens／追加成功 4,589.0 であった．F/D だけが成功する対象も残るため，全体率が最大の条件が他条件の成功をすべて含むとはいえない．この観測から，介入カタログへ独立再生成も候補として加え，失敗類型と成功対象，生成機会と消費の両面から比較するという研究課題を得た．

6.4 介入カタログを実証研究として育てる方向

本研究で整理したカタログ項目は，完成済みの自動選択器ではなく，観測を積み重ねるための形式である．失敗類型とモデル，対象数，入力情報，停止条件，結果，追加消費，出典と限界を一緒に記載することで，今後異なる実験を追加した際にも比較可能な単位を保てる．新しい条件を追加した場合には，過去の全体率を上書きするだけではなく，どの対象と設定が増えたかを説明する必要がある．
将来，カタログに基づく選択が実際に有用かを評価する段階では，結果を見てから最も良い条件を選んだ参照集合と，事前に決めた方策を区別する．成功を多く得るだけでなく，未成功への消費，停止により失う成功，別タスクへの適用範囲を測定する．その検証を経て初めて，今回の記述的分析を運用上の推奨へ近づけられる．
量子 LLM 支援プログラミングでは，モデルの出力だけでなく，評価器が作る診断と人間が定める手順も結果へ関わる．本研究はその相互作用を見える形へ分解し，初期失敗からの救済，対象の不一致，再生成対照，追加消費を同じ初期組で結び付けた．今後は，この観測基盤を維持しながら，事前固定した方策を別の seed・タスクで検証することが必要である．

6.5 本研究の到達点と利用者への含意

本研究の結果を利用するときには，まず何を成功と呼ぶかを確認する必要がある．回路を構築できるだけでよいのか，指定入力の分布まで一致する必要があるのか，実装の構造も守る必要があるのかによって，採用すべき検査は変わる．本稿が主 L3 を明示したのは，すべての利用場面に同じ検査を押し付けるためではなく，今回得られた件数がどの基準に依存するかを読者が確認できるようにするためである．

次に，修正を選ぶ際には，生成済みコードのどの情報を再利用でき，どの情報が検証済みかを区別する必要がある．実行診断が得られていても，その診断がコードの潜在的な欠陥をすべて示しているとは限らない．また，コードが主 L3 へ到達した後に，人間が理解しやすいか，別の入力へ適用できるかなどは別の確認事項である．本研究の救済率は，こうした後続の作業を不要にする指標ではない．

再生成を含む複数の選択肢を比較することは，特定の介入名に期待を固定しないためにも有用である．同じ失敗に対して何を与え，何回要求し，どこで止めたかを記録すれば，成功した事例だけを印象的に紹介するのではなく，未成功への負担も含めて手順を検討できる．本研究が集計に未救済例を残し，B4 対照を加えたのは，この比較を具体化するためである．

利用者がカタログを参照する場合には，対象の失敗構成が本研究とどの程度近いか，入力や評価の条件が一致するか，限られた予算で何を優先するかを判断することになる．本稿の項目案はその判断の根拠を記録する形式を提示した段階であり，人間の判断を不要にした成果ではない．今後の検証で方策が有効と確認された場合も，適用範囲と未成功集合を残した形で更新する必要がある．

以上より，本研究は「修正すればよい」という一つの答えを与えるものではなく，失敗の種類，救済対象，資源消費，評価範囲を対応づけて比較するための実証的な基盤を示した．初期コードを共有した分析と固定出典に基づく記録を保ち，独立再生成を含む方策を新しい対象で検証することが，量子 LLM 支援プログラミングの介入カタログを発展させる次の段階となる．

6.6 提出に向けた確認

本稿は検証済みの固定集計に基づく卒業論文草稿である．題目の正式承認，指導教員による内容・参考文献書式の確認を残す．要旨の審査用と最終版の提出時には，学部の指示に従って剽窃チェックと類似レポートの作成を行う．本稿の作成をもって剽窃チェック完了とはしない．

7 参考文献

[1] A. Madaan et al. : Self-Refine: Iterative Refinement with Self-Feedback，arXiv:2303.17651v2（2023）. https://arxiv.org/abs/2303.17651v2
[2] X. Chen , M. Lin , N. Schärli , D. Zhou : Teaching Large Language Models to Self-Debug，arXiv:2304.05128v2（2023）. https://arxiv.org/abs/2304.05128v2
[3] 伊藤悠真：現行救済経路の固定発表出典（2026-10-16 版）. 本リポジトリ docs/presentation_sources/20261016T_reachable_rescues/，results_snapshot.json，source_manifest.json および対応 CSV . B4 追加実験（2026-10-22 固定）：docs/analysis/independent_4_completed_20261022/の保存設定・manifest・sanity・集計 CSV.
[4] M. Chen et al. : Evaluating Large Language Models Trained on Code，arXiv:2107.03374v2（2021）. https://arxiv.org/abs/2107.03374v2
[5] J. Austin et al. : Program Synthesis with Large Language Models，arXiv:2108.07732（2021）. https://arxiv.org/abs/2108.07732
[6] J. Huang et al. : Large Language Models Cannot Self-Correct Reasoning Yet，arXiv:2310.01798（初版 2023，v2 は 2024）. https://arxiv.org/abs/2310.01798
[7] S. Vishwakarma et al. : Qiskit HumanEval: An Evaluation Benchmark For Quantum Code Generative Models，arXiv:2406.14712（2024）. https://arxiv.org/abs/2406.14712
文献[1]，[2]，[4]〜[7]の書誌情報と本文で参照した主張の範囲は，原論文の公開ページで確認した．引用番号は本文の初出順である．文献[3]は本研究の一次資料で，集計時点・保存設定・検証記録を固定している．

8 付録

8.1 出典と再現性

8.1.1 元実験の保存設定

results/shared_five_models_full_20261010T041019864060Z/experiment_config.json
設定 SHA-256：5c9232f76cc6758b52983fe90ec0757ba2ffe2c4972884a25736f09edd45f22a
保存 schema：2.1．ハーネス commit：9c1833eba6020369247358c04e462e0dc1982705．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.2 元実験の保存設定

results/shared_three_models_full_20261008T103231611899Z/experiment_config.json
設定 SHA-256：a4cd6ab1126e8927aa3a76c4fcf7392026007215d0388d8b6f73c3bba84691ec
保存 schema：2.0．ハーネス commit：9c6f952b41ac661bb42bb1ffe4d3f37282260658．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.3 元実験の保存設定

results/shared_two_models_seed0_9_full_20261012T100658266051Z/experiment_config.json
設定 SHA-256：dd6b694be0b0c03b3bc33ecc13c69872104a5dba2b66706389b8163a618b0a9b
保存 schema：2.1．ハーネス commit：7ccef09db9bff16785b08f2e7f1ff542cf64b849．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.4 固定集計と公開範囲

固定集計時点（UTC）：2026-10-15T15:20:18.335286+00:00
主出典：docs/presentation_sources/20261016T_reachable_rescues/results_snapshot.json
B4 追加実験：independent_4_full_20261020T185811381595Z．固定出典：docs/analysis/independent_4_completed_20261022/．runner_experiment_config.json，runner_manifest.json，summary.csv，pairwise.csv，sanity_report.json，source_manifest.json を参照．
全分母：docs/analysis/reachable_rescues_20261016/core/repair_summary.csv
追加消費：同ディレクトリの cost_by_cap_and_stratum.csv と third_round_summary.csv
片側救済全履歴：discordant_cases.csv と discordant_transitions.csv
検証：core/sanity_report.json，sanity_report.json，validation_report.json
公開資料には生成コード・prompt・API 応答・生例外文・raw.jsonl・秘密情報を含めない．今回の資料作成は固定公開集計の読み取りと文書化であり，追加のモデル要求や生成コード再実行は行わない．

8.2 指標の読み方と提出前確認

8.2.1 集計単位

初期組はモデル×タスク×seed の 1,000 組，条件記録は各組 5 条件の 5,000 記録，到達 round は現在の経路上の 9,249 round である．単位を混ぜて成功率の分母にしない．

8.2.2 退行 0 の意味

R/F/D は初期成功を保持し，修正中も成功時に停止する．退行 0 はこの設計を反映しており，自由な修正を続けても正しさが保たれる保証ではない．

8.2.3 静的変更の意味

import/API やゲート名の変更は観察された文字列上の事実であり，その変更単独の因果的効果や意味的正しさを認定したものではない．

8.2.4 コストの意味

共有初期を除く入力＋出力 tokens と生成要求時間を集計した．再構成経路の計算値で，評価時間・全工程時間・金銭費用とは異なる．

8.2.5 提出前の確認

原本の書式と題目の正式承認，指導教員による内容・参考文献書式，Word での再ページ割付，剽窃チェックと類似レポート，WebClass 提出要領を確認する．卒業論文 PDF は 10MB 以下を目安とし，超過時は指定された Proself 経由で提出する．