卒　業　論　文

量子 LLM 支援プログラミングにおける
失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真

指導教員　横山 哲郎

2027 年 1 月

南山大学 理工学部 電子情報学科

要約

LLM による量子回路コード生成では，API の誤用や回路構築の失敗に加え，実行できても期待した出力を返さない失敗が生じる．本研究では，Qiskit を用いたコードの初期失敗を修正介入がどの程度救済し，どの対象を救済するかを分析した．自己見直し R，実行結果提示 F，説明・原因分析を促す自己デバッグ D を，同じ初期コードから比較した．生成前注意事項 P は独立生成として扱った．
対象は 5 モデル，10 タスク，seed 0〜19 である．モデル・タスク・seed の組合せを初期組と呼び，1,000 初期組・5,000 条件記録を対象とする．検証済みの生成履歴の前半部分と，必要な部分追試による後半部分を組み合わせ，現行評価器の停止・修正規則に従って到達可能な生成履歴（以下，到達履歴）を採用した．本研究における最終評価水準（L3）は，指定入力の出力一致と所定の構造要件を含む成功基準である．初期失敗 545 組の救済は R96 組（17.6%），F183 組（33.6%），D180 組（33.0%）であった．F と D の共通救済は 140 組，F のみ 43 組，D のみ 40 組であり，救済数が近くても対象は異なった．片側救済 83 組の両条件 166 履歴・398 修正遷移を静的に確認した．
同じ初期コードを保持する独立再生成 B4 を追加し，初期失敗に対して最大 3 回，前回コードや診断を与えず再生成した．B4 は 217/545 組（39.8%）で成功し，最終成功は 672/1,000 組（67.2%）であった．追加 1,342 要求，995,815 tokens，追加 tokens／追加成功は 4,589.0 であった．最大生成回数が同じでも入力情報・seed 規則・実行時期が異なり，因果効果は断定しない．
未救済例への消費を含む追加 tokens／救済は R18,852.6，F9,333.8，D10,976.6 であった．3 回目の修正は F で 28 組，D で 33 組を追加救済した．これらは保存記録と部分追試を組み合わせた計算値であり，全件新実験の実測コストではない．結果は今回のモデル・タスクと指定入力での評価に限られ，介入の一般的優劣，因果効果，統計的有意差を主張しない．今後は介入選択・停止方策を事前固定し，別 seed・タスクで検証する必要がある．

目次

1 はじめに 5
1.1 研究背景 5
1.2 研究目的と研究課題 5
1.3 論文の構成と対象範囲 5
1.4 コード生成支援から失敗後の意思決定へ 5
1.5 初期失敗を基準とする研究の意義 6
1.6 用語と主張の範囲 6
2 関連研究 7
2.1 自己フィードバックによる修正 7
2.2 実行結果と自己デバッグ 7
2.3 量子回路コードで確認する対象 7
2.4 自己修正を評価する際の外部情報の役割 7
2.5 量子コード生成ベンチマークとの相違 7
2.6 反復生成と再生成対照の位置づけ 8
3 評価・実験方法 9
3.1 介入条件と評価指標 9
3.1.1 共有初期と五つの条件 9
3.1.2 独立再生成対照 B4 10
3.1.3 L3 と出力一致 10
3.1.4 救済・保持・独立生成の比較 10
3.1.5 量子状態・測定分布とコードの正しさ 10
3.1.6 段階評価を用いる理由と診断の情報量 11
3.1.7 出力距離・測定順序・構造要件の詳細 11
3.1.8 対応集合による指標の定義 12
3.2 実装と記録の検証 12
3.2.1 ハーネスの構成 12
3.2.2 失敗分類とモデル接続障害 12
3.2.3 到達履歴の再構成 13
3.2.4 集計の整合性と静的履歴分析 13
3.2.5 生成・評価・停止を結ぶ処理の流れ 13
3.2.6 履歴再構成における分岐と到達性 13
3.2.7 記録の検証と失敗の切り分け 14
3.2.8 静的履歴分析の観察単位 14
3.3 実験設定と出典 15
3.3.1 対象モデルと課題 15
3.3.2 生成条件と元実験の区別 15
3.3.3 追加コストと修正回数の集計方針 15
3.3.4 課題集合の役割と被覆範囲 15
3.3.5 生成設定を揃える意味と限界 16
3.3.6 固定出典と執筆時点の切り分け 16
4 結果 17
4.1 全体の結果と比較の前提 17
4.2 モデル別の結果 17
4.3 初期失敗類型別の結果 18
4.4 タスク・難度別の結果 18
4.5 成功対象の重なりと履歴分析 19
4.6 追加計算コストと停止回数 20
4.7 P の独立生成としての比較 20
5 考察 21
5.1 修正と独立再生成の比較から得られる知見 21
5.2 介入カタログの構成と適用範囲 21
5.3 資源制約と停止方策への含意 21
5.4 妥当性と限界 22
5.5 今後の検証計画 22
6 おわりに 23
6.1 研究成果 23
6.2 今後の課題 23
7 参考文献 24
8 付録 25

8.1 出典と再現性 25
8.1.1 5 モデル追加実験の保存設定 25
8.1.2 3 モデル本実験の保存設定 25
8.1.3 2 モデル補完実験の保存設定 25
8.1.4 固定集計と公開範囲 25
8.2 指標の読み方 26
8.2.1 集計単位 26
8.2.2 退行 0 の意味 26
8.2.3 静的変更の意味 26
8.2.4 コストの意味 26

1 はじめに

1.1 研究背景

量子回路をプログラムとして構築する際には，量子状態や測定分布に関する理解と，ソフトウェア API の正しい使用の両方が必要になる．LLM の生成コードを利用する場合も，構文上の正しさだけで有用性を判断できない．import が成功しても回路構築に失敗する場合があり，実行が完了しても期待した出力と一致しない場合がある．

生成を一度で終えず，前回コードを見直させたり，実行結果を提示したりする方法が考えられる．自己フィードバックによる反復改善の Self-Refine [1]と，コードの説明や実行結果を用いた Self-Debugging [2]は，こうした修正の背景となる．ただし，一般的なコード生成での知見が，量子回路コードの各種失敗に同じ形で当てはまるとは限らない．

実行結果には，存在しない API の使用を知らせる診断と，期待出力との不一致を知らせる診断が含まれる．両者では修正に必要な情報が異なる可能性がある．全体の最終成功率だけを比較すると，初期成功をそのまま保持した分と，修正によって救済した分が混在する．そこで本研究では，初期失敗を分母に固定して介入を比較する．

モデル・タスク・seed の組合せを初期組と呼ぶ．本研究では，最終評価水準 L3 の要件をすべて満たすことを「L3 成功」と呼ぶ．現行評価器の停止・修正規則に従って到達可能な生成履歴を，到達履歴と呼ぶ．

1.2 研究目的と研究課題

本研究の目的は，Qiskit 量子回路コードの初期失敗に対する修正介入と独立再生成の有効性を比較し，失敗類型やモデルに応じた対処方法を選択するための根拠を整理することである．第一の問いは，同じ初期失敗に対して修正介入 R/F/D と独立再生成 B4 がそれぞれどれだけ追加成功を得るかである．第二の問いは，救済数が近い介入が同じ失敗を救済しているかである．第三の問いは，未救済例も含む追加計算コストと修正回数が救済にどう対応するかである．

本研究の貢献は，共有初期コードを用いた修正介入と独立再生成の追加成功率の比較，初期失敗類型・モデル・タスク別の分母を伴う分析，F と D の片側救済全 83 組の履歴整理，および追加計算コストと 3 回目の寄与の記述である．介入の最適な選択方策を既に実証したとは主張しない．

1.3 論文の構成と対象範囲

第 2 章で関連研究を整理し，第 3 章で評価・実験方法として介入条件・評価指標・実装・実験設定を述べる．第 4 章で結果，第 5 章で考察，第 6 章で結論と今後の課題を述べる．第 7 章に参考文献，第 8 章に出典と指標の付録を置く．本稿は 2026-10-16 版の到達経路と 2026-10-22 固定の B4 追加実験 [3] に基づく草稿であり，今回の執筆では追加生成・生成コード実行を行っていない．

1.4 コード生成支援から失敗後の意思決定へ

自然言語からプログラムを生成できることと，そのプログラムを目的に沿って利用できることは同じではない．利用者は生成されたコードを読み，実行環境に接続し，結果を確認し，問題があれば次の操作を選ばなければならない．コード生成支援の実際の作業では，最初の出力の品質だけでなく，失敗を確認した後に何を入力し，どこで生成を止めるかが作業量を左右する．本研究はこの失敗後の意思決定に対象を絞る．

コード生成の機能的正しさを評価する HumanEval [4]や，自然言語から短い Python プログラムを生成する MBPP [5]は，生成したコードを実行し，機能を確認する評価の背景となる．ただし，本研究はこれらの課題をそのまま利用したベンチマークではない．対象を独自に定義した量子回路課題に限定し，初期失敗の後に行う修正と再生成を対応づけて調べる．課題集合や評価基準が異なるため，他のベンチマークにおける成功率との直接比較は行わない．

例えば，存在しない関数名を import して失敗した場合には，実行診断から変更箇所の候補を狭められる可能性がある．一方，コードは実行できるが量子状態が異なる場合には，単に例外が出ないように書き換えるだけでは不十分である．必要な情報や修正箇所が異なる以上，すべての失敗へ一つの指示を一律に適用することが適切かは実証的に確認すべき問題になる．この二つの例は介入の役割を説明するための想定例であり，特定の保存事例を新たに再現した結果ではない．

失敗後の操作には，既存コードを残して直す方法と，既存コードを捨てて生成し直す方法がある．修正には，前回の出力を再利用できる利点がある一方，誤った構造を引き継ぐ可能性もある．再生成には，既存の誤りから離れられる可能性がある一方，既に正しかった部分を再び作り直すことになる．これらは設計上考えられる性質であり，本研究が個別の心理過程やモデル内部の挙動を直接測定したという意味ではない．実際の比較では成功数と追加計算コストを観測して判断する．
本研究では，コード生成時または生成後の再試行時に，LLM へ与える情報や指示を変更する操作を介入と呼ぶ．生成前に注意事項を与える P と，生成後に修正を促す R/F/D を含む．一方，B4 は前回コードや診断，修正指示を与えず，同じ課題仕様から独立に再生成する対照条件である．モデルの重みを更新する学習ではなく，同じ課題を解く過程での入力の構成に着目する．したがって，結果の解釈にはモデル識別子だけでなく，プロンプト，評価器，停止条件，生成機会上限を含める必要がある．介入名だけを取り出して一般的な効力を論じることは避ける．

1.5 初期失敗を基準とする研究の意義

最終成功率のみを用いると，初期から正しかったコードの割合と，初期に誤っていたコードを修正できた割合が混在する．初期性能が高いモデルは修正対象が少なく，初期性能が低いモデルは修正対象が多い．この違いを考慮せずに最終成功数を比べると，介入が働いた範囲を読み取りにくい．本研究は各組の初期判定を保存し，その初期失敗集合に対して修正後の成功を数えることで，修正が必要だった対象に対する成績を明示する．
初期コードの共有は，比較の出発点を揃えるためにも必要である．別々の初期生成から R と F を始めた場合，R 側の初期失敗が軽く，F 側の初期失敗が重い可能性を排除できない．本研究ではモデル・タスク・seed で識別される初期組を基準に，R/F/D の最初のコードと判定を一致させる．この対応づけは比較の解釈を助けるが，後続生成の乱数や入力長，実行時期まで等しくするものではない．共有初期は比較の必要な条件の一つであり，単独で因果推論を成立させる条件ではない．
また，同じ数の失敗を救済したとしても，その集合が一致するとは限らない．二つの条件がそれぞれ多くを救済しても，片方だけが救済できる対象があれば，実行前にどちらを選ぶかという問題が残る．反対に，成功対象がほぼ重なるのであれば，追加計算コストや実装の簡単さを重視できる可能性がある．本研究では数と集合の両面を扱い，単一の順位表では捉えにくい介入間の関係を記述する．
本研究の実証的貢献は，選択方策の完成ではなく，選択方策を設計する前に必要な観測単位を整えた点にある．初期失敗，修正履歴，最終成功，追加計算コストを初期組へ結び付けることで，後から条件の選び方を検討するための根拠を残す．この段階の知見を，そのまま実運用における最適な規則へ置き換えない．記述的な結果を整理する段階と，方策を新しい対象で検証する段階を区別すること自体が，結果を過大解釈しないための研究設計である．

1.6 用語と主張の範囲

本稿の「成功」は L3 を満たすという操作的な意味で使用する．利用者のあらゆる意図を満たすことや，任意の量子入力に対して同じ算法を実装することを表す用語ではない．「失敗」はこの評価基準への未達を表し，モデルの一般的能力の欠如を意味しない．評価基準と用語を対応づけることにより，どの判断を機械的に検査し，どの判断を今後の検討に残しているかを区別する．
「救済」は，同じ初期失敗コードを R/F/D で修正し，最終的に L3 へ到達した場合に用いる．B4 の成功は，初期組を共有するものの失敗コード自体を修正しないため，「独立再生成による追加成功」とする．P では初期コードを共有しない独立 1 回生成の成績を，B との対応で記述する．これらは最終成功という同じ判定を利用していても，出力を得る手続きが異なる．
「コスト」は，ここでは主にモデル要求に記録された tokens と生成要求時間を指す．利用者の読解時間，電力，実行装置の償却，金銭単価は測定していない．追加 tokens が少ないという観測を，人間の総作業量が同じ割合だけ減ったという主張に置き換えない．同様に，「介入効果」という表現を用いる箇所でも，原則として対応づけた観測上の変化を指し，無作為化比較によって特定された因果効果とは区別する．

2 関連研究

2.1 自己フィードバックによる修正

Self-Refine [1] は，同じ LLM による生成，フィードバック，修正の反復を扱う．本研究の R は，前回コードと課題仕様を与えて自己点検を求める条件であり，外部評価の診断内容を与えない．自己点検だけで救済できる範囲を確認する比較条件として用いる．
原論文と本実装ではプロンプト構成，対象課題，出力制約，モデルが異なる．したがって本研究の R の結果を，原論文の手法全体の性能と同一視しない．先行研究は設計の背景であり，完全再現実験として扱わない．

2.2 実行結果と自己デバッグ

Self-Debugging [2] は，生成コードの説明や実行結果の検討を用いた自己デバッグを扱う．本研究では F を実行ベースの診断を用いる条件，D を同じ診断に加えて説明・原因分析・修正の順序を促す条件として実装した．D の追加指示と出力長の違いを含めて観測する．
D は説明と原因分析を修正版コード先頭のコメントに残す実装である．モデルが内部でどのように推論したかは測定していない．D で救済されたという事実だけから，説明が正しかった，あるいは説明そのものが成功原因だったとは判断できない．

2.3 量子回路コードで確認する対象

本研究は，回路を返す関数の存在，回路の構築と評価処理，指定入力の期待状態または分布，所定の構造要件を区別する．量子回路では，実行可能性と期待出力への適合は別の性質である．測定分布が一致しても，全入力で同じアルゴリズムを実装している保証にはならない．
本研究の位置づけは，選定した量子回路課題の中で介入の救済対象と消費を記述する実験的分析である．一般の量子プログラム全体への網羅的評価や，形式的な同値性証明は対象に含めない．その範囲を明確にしたうえで，成功例と失敗例を同じ分母で扱う．

2.4 自己修正を評価する際の外部情報の役割

自己修正という呼び方には，モデル自身の出力だけを見直す場合と，実行や採点から得た外部情報を使う場合が含まれ得る．本研究では両者を混ぜないため，R と F/D を分けた．R は課題仕様と前回コードに基づく自己点検であり，F/D では検証器が出力した情報が次の要求に入る．同じモデルを使っていても，入力として利用できる情報が変わるので，これらを同じ意味での自己修正と扱うことは適切でない．
Huang ら [6] は推論課題において，外部フィードバックのない自己修正の困難さを論じている．本研究では，自己点検により常に改善すると仮定しないための背景として参照する．同論文が本研究の量子コードや選定モデルで同じ結果を示したと主張するものではない．対象課題，モデル，評価指標の相違を残したまま，外部情報の有無を比較設計で明示するという問題意識に接続する．
外部情報がある場合にも，提示した情報が正しく対象の失敗を指していることが前提となる．評価器のビット順処理や判定条件が誤っていれば，正しい回路に不適切な修正を促す可能性がある．したがって，診断を利用する手法の評価では，診断の有無だけでなく，その診断を作った評価器の仕様と検証履歴を記録しなければならない．本研究が評価方針の修正と到達履歴の再構成を方法へ含めるのは，評価器を単なる受動的な採点装置と扱えないためである．
F と D の相違は説明・原因分析の指示にあるが，この差は入力文の長さや出力コメントにも関係する．そのため，最終成功数の差を説明行の存在だけへ帰属できない．説明が誤っていても偶然にコードが改善する場合や，説明が妥当でも実装が失敗する場合は概念的に区別できる．本研究が直接観測するのは要求と出力と評価の系列であり，内部推論の内容や説明の忠実性を測定する実験ではない．

2.5 量子コード生成ベンチマークとの相違

Qiskit HumanEval [7] は，Qiskit コード生成を評価するための課題群を提示している．量子 SDK を対象としたコード生成でも，生成物の実行と正しさを検証する専用の課題設計が必要になることを示す関連研究として位置づける．本研究の 10 タスクはこのベンチマークからの抽出と位置づけておら

ず，独自の課題仕様，期待出力，構造要件に基づく．名称が近い評価であっても，課題の出典と採点の定義を分離して記述する．
本研究では広範な量子 API の被覆率を最大化するのではなく，同じ初期失敗に複数の介入を適用し，その救済対象を対応づけることを優先した．そのため，課題数を増やした一般的なモデルランキングとは目的が異なる．課題の種類が少ないことは一般化の制約である一方，個々のタスク仕様や履歴を追いやすいという分析上の特徴がある．この特徴を利点だけとして述べず，被覆範囲の限定と合わせて示す．
量子 SDK のコードには，Python の文法と API 利用に関する正しさに加え，構築した回路が目的の状態や分布を生成するという正しさがある．SDK 上での実行可能性だけを検査した場合と，指定出力まで検査した場合では，成功集合が異なり得る．したがって，本研究の L3 成功率を他研究の実行成功率と同じものとして比較しない．比較に必要なのは，判定対象，入力範囲，測定方式，失敗時の扱いを明らかにすることである．

2.6 反復生成と再生成対照の位置づけ

同じ課題から複数候補を生成する方法は，単一候補では得られなかった成功を得るための比較対象になる．ただし，複数候補の中から成功したものを選ぶには，候補を評価する手続きも必要である．本研究の B4 は，生成回数だけを増やして採点を無視する条件ではなく，各候補を L3 で検査し，成功時に停止する対照である．比較対象は，評価を受ける機会を持った反復的なコード生成手順になる．
本研究の B4 は，既存の初期生成を共通に保持し，失敗した組だけ追加生成する．このため，課題ごとに初めから 4 個の独立候補を一括生成した一般的な設定と完全には一致しない．初期コードの出典，追加生成用の seed 規則，成功時停止という手続きが成績へ関係する．本稿では B4 という操作条件の名前で報告し，別の推定量や他研究の指標と無条件に同一視しない．
修正条件が単回生成より高い成績を得ても，それだけでは診断や前回コードの再利用が役立ったことの証拠にはならない．単に生成要求を追加したことによる機会の増加が含まれるためである．そこで，本研究では初回込み最大 4 回という上限を B4 と R/F/D で対応づける．これは比較を改善する一歩だが，同じ上限にしただけでは入力情報量や消費 tokens を揃えられない．比較で何を揃え，何を揃えていないかを明示する．

3 評価・実験方法

図 1 に実験の論理的な比較手順を示す．初期成功の保持と初期失敗への追加生成を分け，生成前介入 P は点線の独立経路で示す．保存済みの生成履歴と部分追試に基づく集計であり，全件を新たに生成した実験ではない．

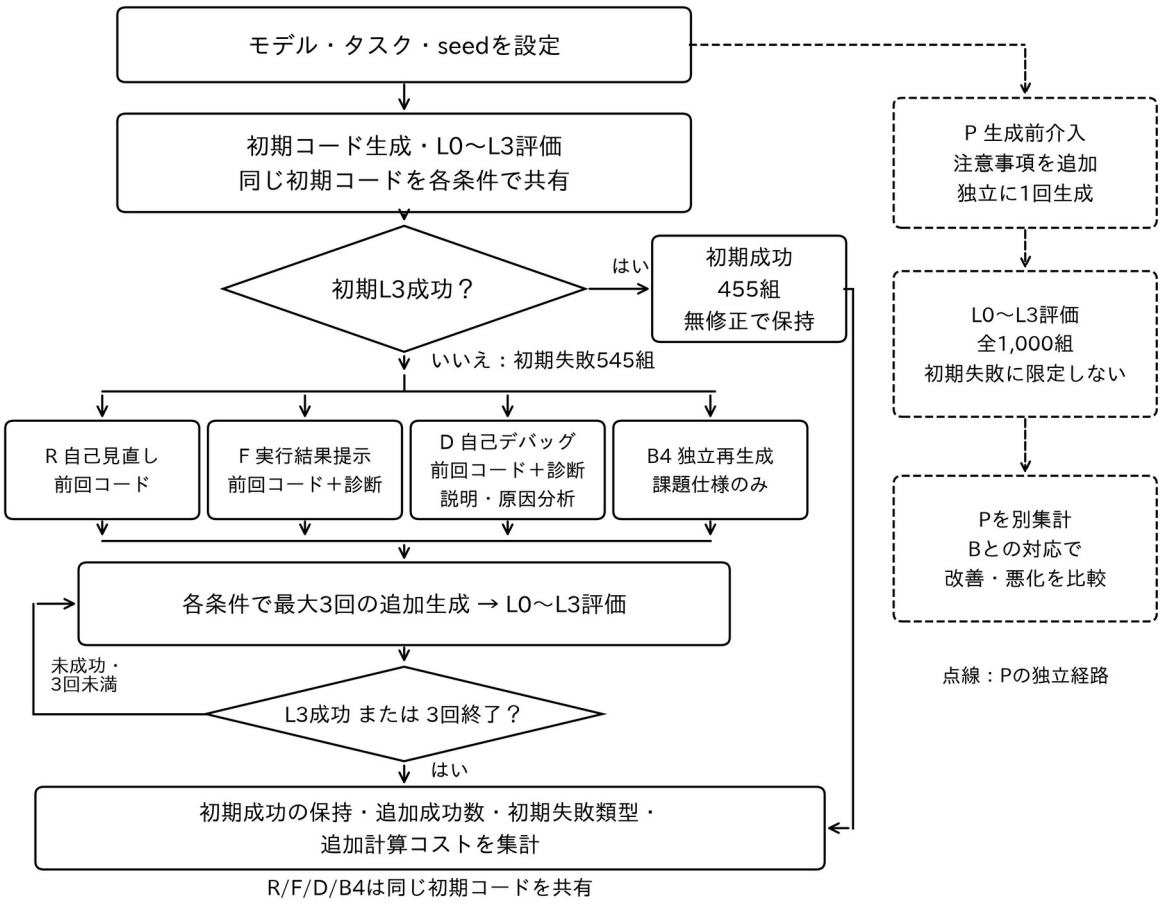


図1 共有初期コードを起点とする比較手順

3.1 介入条件と評価指標

3.1.1 共有初期と五つの条件

モデル・タスク・seed の組を初期組と呼ぶ．B は初期生成のみの条件である．R/F/D は B と同じ初期コードと判定を共有し，初期失敗に対して最大 3 回の修正を行う．成功した時点で停止し，以降の修正は行わない．この対応により，初期生成の違いを介入差と混同しにくくする．
R は自己見直し，F は実行結果提示，D は説明・原因分析を促す自己デバッグである．P は初回プロンプトに注意事項を追加して独立に生成する条件であり，同じコードを修正する条件ではない．P の対応比較は，B の初期失敗に対応して成功した場合と，B の初期成功に対応して失敗した場合を分ける．

表1 条件と修正時に与える情報

条件	入力・特徴	生成・停止
B	課題仕様から初期生成	1 回
R	前回コードと自己点検の指示	最大 3 修正・成功時停止
F	前回コードと実行ベースの診断	最大 3 修正・成功時停止
D	F の診断＋説明・原因分析	最大 3 修正・成功時停止
P	課題仕様＋生成前注意事項	独立生成 1 回
B4	前回コード・診断なしで再生成	初回込み最大 4 回・成功時停止

3.1.2 独立再生成対照 B4

B4 は初期 1 回を含む最大 4 回生成である．B と同じ初期コード・L3 判定を用い，初期成功 455 組は保持する．初期失敗 545 組のみ，前回コードと診断を与えず課題仕様から最大 3 回独立再生成し，L3 成功時に停止する．初期失敗からの成功は修正介入による救済と区別する．
5 モデル・10 タスク・base seed 0〜19 は従来と対応するが，追加生成は independent_4_v1 の専用 seed 規則を用いる．temperature 0.7，max_tokens 1,024，timeout 600 秒，並列 1，reasoning_effort none で実行した．上限が同じでも入力情報・実要求数・tokens・実行時期・診断文・出典 schema は等しくない．

3.1.3 L3 と出力一致

L0 は生成コードの読込み・import 等と必須インターフェースの要件，L1 は回路構築と評価処理の実行，L2 は指定入力に対する期待出力との一致を表す．L3 は L0，L1，L2 および structure_match がすべて真であることと定義する．構造要件には量子ビット数と測定・barrier を除く回路命令数の範囲を用いる．
測定分布の距離は全変動距離 $TVD(p,q) = (1/2)\Sigma x\ |p(x)-q(x)|$ とし，8,192 shots で得た分布と期待分布を比較する．状態ベクトルは大域位相を整合したユークリッド距離を用いる．各タスクで距離 0.05 未満を出力一致とする．測定・変換 seed は 42 に固定したが，有限 shots と指定入力に限られる．
本稿で用いる evaluation_policy_v4 は，測定先から量子ビット順への対応を反映する．タスクに構造制約が明示されていない項目を，一律の制約として追加しない．L3 は所定の検査を通過したことを意味し，全入力でのアルゴリズム同値性やプロンプトの全自然言語条件の充足を保証しない．

3.1.4 救済・保持・独立生成の比較

初期 L3 未達から最終 L3 成功に変化した初期組を救済と呼ぶ．救済率 = 救済組数／初期 L3 未達組数とする．初期失敗類型は介入前の B の分類に固定する．修正後の分類で分母を選別すると対象が変わるため，その方法は採用しない．
R/F/D の最終成功には初期成功の無修正保持が含まれる．成功時停止により退行 0 となる設計であり，退行 0 をモデルが常に正しさを維持できる証拠と解釈しない．P では独立生成による改善と悪化の両方を報告する．

3.1.5 量子状態・測定分布とコードの正しさ

本研究の出力評価を理解するには，回路が表す処理と，回路を実行して得られる観測結果を区別する必要がある．量子状態は基底状態に対する複素振幅の組として表され，計算基底での測定確率はその振幅の絶対値の二乗に対応する．したがって，同じ測定確率を持つ状態であっても，相対位相が異なる可能性がある．このことから，分布を検査するタスクと状態ベクトルを検査するタスクでは，確認できる正しさの範囲が異なる．
説明用の例として，二つの基底状態の振幅の符号だけが異なる状態を考える．計算基底で直ちに測定した分布は同じでも，後続の干渉を伴う処理では異なる結果になり得る．この例は評価原理を説明するためのもので，保存コードを新たに実行して得た観測ではない．分布の一致だけから位相まで含めた状態の同一性を結論しないことが，本研究の評価範囲を正しく読むために必要となる．
一方，状態ベクトルの比較では，すべての振幅へ同じ位相を掛ける大域位相を区別しないようにする．本評価器では，実際の状態と期待状態の内積から位相差を求め，その差を整合した後の距離を計

算する．単純な複素ベクトルの成分比較では，物理的に区別しない大域位相によって距離が大きくなる場合があるためである．ただし，相対位相の違いを大域位相の整合で打ち消すことはできない．
さらに，指定入力で出力状態が一致していても，回路全体が任意入力で同じ変換を行うとは限らない．ある一つの入力に対して同じ出力を返す二つの回路が，別の入力では異なる出力を返すことはあり得る．本研究の状態評価はタスクに指定された入力に対する評価であり，ユニタリ行列全体の同値性を証明する検査ではない．この区別は，QFT や IQFT など算法名を持つ課題を評価する際にとくに重要である．
構造条件は，出力検査だけでは捉えない課題上の制約を補うために用いる．例えば量子ビット数が仕様と異なる場合には，指定された実装要件を満たしていない．ただし，回路の命令数が範囲に収まることを検査しても，算法の意味を十分に特徴づけたことにはならない．構造検査は指定した必要条件の確認であり，出力検査と合わせて L3 を構成する．構造要件へ合格したことを形式検証の完了と表現しない．

3.1.6 段階評価を用いる理由と診断の情報量

段階評価では，どこで検査が止まったかにより，確認済みの性質が異なる．構文や import で止まったコードに対しては，回路の量子出力が正しいかどうかを観測できない．逆に，出力不一致まで進んだコードでは，少なくともコード読込みと回路の構築・評価処理が通過している．すべてを失敗の一語へまとめると，介入が利用できる手掛かりや，修正の到達点を区別しにくくなる．
L0 は構文・import などの読込みと，必須関数を利用できるインターフェースを確認する．関数名が書かれているだけでなく，呼び出し可能であることや，要求された呼出方法に適合することが必要になる．この段階では，回路を実際に構築できることまでは確定しない．L0 を通過したことを，量子コードとして正しいことと同一視しない．
L1 は回路構築と評価処理を実行できる段階である．build_circuit()が回路を返すことや，未束縛パラメータなど評価を妨げる条件がないことも，実装上の確認に関係する．ただし，評価処理を実行できることと，その結果が期待どおりであることは別である．L1 成功から L2 失敗へ進んだ場合には，単に例外を取り除く修正では不十分だった可能性がある．本稿では可能性の説明と個別の原因認定を区別する．
L2 は指定入力に対する期待出力と実測または計算された出力の距離を比較する．L3 はこの出力適合性に，所定の構造条件を加える．一つの最終判定へまとめる場合でも，各段階の情報を保持することで，実行不能から実行可能へ変わったが出力はまだ誤っているという途中の改善を記録できる．ただし，本研究の主要指標である救済では最終 L3 成功を要求するため，途中段階の改善を成功数に加算しない．
診断の情報量は失敗段階によって異なる．構文の位置や import 名は変更候補を直接示す場合がある一方，期待分布との不一致は多くのゲート操作や測定の取り方に関係し得る．この違いから診断が常に同じ難しさで利用できるとは仮定しない．また，失敗分類は最初に露見した問題を表す場合があり，コード内のすべての欠陥を一つずつ列挙したものではない．初期分類を因果的な根本原因の完全な記述として扱わない．

3.1.7 出力距離・測定順序・構造要件の詳細

測定分布の比較では，期待分布と観測分布のキーの和集合を取り，各ビット列の確率差の絶対値を合計して半分にする．出現しなかったビット列の観測確率は 0 として扱う．この定義により，期待していなかった出力へ確率が流れた場合も距離へ反映される．本評価では距離が 0.05 未満であることを出力一致とし，ちょうど境界値となる場合は成功へ含めない．
8,192 shots の観測分布には標本変動が含まれる．同じ理想回路でも有限回の測定から得た頻度は期待確率と完全には一致しないため，閾値を設けて比較する．測定 seed の固定は再実行時の変動を抑えるための設定であり，別の seed でも同じ合否になることを証明するものではない．本研究では複数の測定 seed に対する合否の安定性を新たに測定しておらず，閾値近傍の感度分析は今後の課題とする．
測定結果の文字列表現を比較する際には，量子ビットと古典ビットの対応を確認する必要がある．コードがどの量子ビットをどの古典ビットへ測定したかに応じて，結果キーを課題の量子ビット順へ戻さなければ，単なる表現上の並びの違いを量子出力の失敗と誤判定する可能性がある．evaluation_policy_v4 はこの対応を反映する評価方針であり，文字列を無条件に反転すればよいという規則ではない．

状態ベクトルを扱う場合には，測定によって一つの観測結果へ落とし込むのではなく，指定入力から得る複素振幅全体を比較する．現行評価器は対応する純粋状態評価の範囲を定め，非ユニタリ処理や古典操作を含む回路を無条件に同じ評価へ通すことを避けている．この実装上の制限を，量子プログラム一般に対してそのような操作が誤りであるという主張へ広げない．課題仕様と評価方式への適合の問題として扱う．
構造要件のうち回路命令数は，測定と barrier を除いて数える．評価用の読出し操作を追加したことだけで算法本体の命令数が増えたと判定しないためである．量子ビット数や命令数の範囲に加え，測定や古典ビットについて明示的なタスクメタデータがある場合に限り，その要件を適用する．未指定の条件を後から一律に導入すると，課題仕様を満たしていたコードを新たな理由で失敗にする可能性がある．

3.1.8 対応集合による指標の定義

初期組の集合を G とし，そのうち B の L3 判定が失敗だった部分集合を U とする．本研究では G の大きさが 1,000，U の大きさが 545 である．条件 c により U の中から最終成功へ到達した集合を S(c)と書けば，修正条件の救済率は S(c)の要素数を 545 で割った値となる．この表記は，条件間で同じ初期対象を比較することと，最終成功集合の全体を混同しないために導入する．
R/F/D では初期成功集合を無修正で保持するため，最終成功数は 455 と救済数の和である．例えば F の最終成功 638 組は，初期成功 455 組と救済 183 組を合わせた数になる．638 を 545 で割ると初期成功を分子へ含めた不適切な率になり，183 を 1,000 で割ると初期失敗に対する救済率ではなく全初期組に対する追加成功割合になる．同じ件数から複数の割合を計算できるため，指標名だけでなく分母を明示する．
F と D の比較では，S(F)と S(D)の共通部分，F 側だけ，D 側だけ，どちらにも含まれない部分へ U を分割する．この四分割は互いに排他的で，合計は 545 になる．両条件が同じ初期組に適用されているため，周辺の成功率だけでなく，個々の対象が一致しているかを調べられる．全体差が小さくても片側の成功が多数あるという結果を，この四分割が捉える．
P では B のコードを修正しないので，B で失敗だった対象に対応する P の成功と，B で成功だった対象に対応する P の失敗を別に数える．B4 では初期成功を保持し，初期失敗への追加候補を評価するため，失敗対象からの追加成功集合を S(B4)として対応づけられる．ただし，集合の記法が同じでも操作内容は同じではない．記号上の比較の便利さを理由に，修正と独立生成の違いを消さない．
層別分析では，モデル，タスク，初期失敗類型などで U を分割し，各層の分母と成功数を示す．全体率は層別成功数の合計を層別分母の合計で割った値であり，各層の率の単純平均とは一般に一致しない．少数の失敗しかない層で高い率が得られても，全体に同じ比率で寄与するとは限らない．本研究のカタログでは，率の大小だけで判断せず，対象数も一緒に読める形を基本とする．

3.2 実装と記録の検証

3.2.1 ハーネスの構成

実装は Python を中心とし，tasks/が課題仕様・期待値・構造条件を，harness/interventions/prompts.py が条件別の修正指示を保持する．harness/llm_clients.py がモデル要求を扱い，harness/experiment.py 等が初期共有と反復を管理する．harness/evaluator.py と harness/readout.py が回路と出力を検証する．これらの責務を分け，生成の失敗と評価の不具合を区別して追跡する．
評価対象コードは build_circuit()を定義し，QuantumCircuit を返すインターフェースを前提とする．測定分布と状態ベクトルのどちらを検査するかはタスク仕様で定める．実装環境の依存範囲は requirements.txt に保持し，過去の実験の実行環境を現在の環境から推定して埋めない．保存設定・ハーネス版・モデル digest は元実験 manifest を参照する．

3.2.2 失敗分類とモデル接続障害

構文，import，必須インターフェース，回路構築，出力不一致，量子ビット数などの分類を記録する．コード側の import_error や build_error は介入の対象となる実験結果である．一方，モデル API の接続エラーやタイムアウトは生成されたコードの品質と分けて検証する．
原因確認済みの初期失敗 1 組は，未定義変数 sim による NameError であり，実行時エラー（未定義変数）に分類した．API 接続障害には含めない．固定出典の検証状態を参照し，未解決の実行・評価問題を確定結果のように扱わない．

3.2.3 到達履歴の再構成

評価方針の修正は，停止する時点や次に与える診断文を変えることがある．保存コードを新しい評価で再採点するだけでは，新診断を受けて生成されるはずの後続コードを再現できない．そこで，検証済みの生成履歴の前半部分と，必要な部分追試による後半部分を接続した現行の到達履歴を主結果とする．
部分追試は 293 ケースで，部分追試で生成した後半履歴は 647 ラウンドである．分岐後に到達できない旧保存後半部分を現在の経路に流用しない．初期生成から全件を新評価で生成し直した実験とは区別する．現行の到達 round は 9,249 であり，5,000 条件記録とは集計単位が異なる．

3.2.4 集計の整合性と静的履歴分析

固定集計では全 5,000 条件の対応，欠落・重複・予定外記録，共有初期の一致，成功時停止，層別分母の合計，出典と到達コードの hash を検査した．固定 sanity report は成功しており，欠落・重複・予定外記録・共有初期不一致は 0 である．本稿の表は公開 CSV から取得し，旧値を転記して混在させない．
片側救済 83 組については両条件 166 履歴，398 修正遷移をコード文字列として静的確認した．import/API，回路構築・インターフェース，量子ゲート等のテキスト，測定・出力取得を複数該当可で注記した．生成コードを実行しない分析であり，変更の意味や因果的寄与は別の検証を要する．

3.2.5 生成・評価・停止を結ぶ処理の流れ

処理は，課題仕様とモデル設定の読込み，初期コードの生成，コードの抽出と評価，条件別の次要求の作成，停止判定，記録の保存という流れで構成する．重要なのは，生成要求を送った回数と，保存された条件記録数が同じではない点である．一つの条件記録は初期コードと複数の修正 round を含み得る．条件の最終結果だけを取り出しても，そこへ到達するためにどれだけの生成を行ったかは分からない．
共有初期コードは，B と R/F/D の出発点を揃えるための記録である．同じモデル・タスク・seed の組で初期コードが一致することに加え，初期判定や参照先が整合しているかを確認する．コード文字列が同じでも評価方針が異なれば停止判断が変わる可能性があるため，コードの hash だけでは十分でない．評価プロファイルと初期判定を合わせて確認する．
初期失敗だった場合，R/F/D では前回コードを条件別の指示へ組み込み，必要に応じて実行診断を追加する．修正コードを評価した後，L3 へ到達していれば停止する．失敗が続き，最大 3 回の修正へ達していなければ，その round のコードと判定から次の要求を作る．したがって，後続の要求は初期失敗分類だけではなく，途中の出力と評価へ依存する逐次的な手続きである．
この逐次性により，最終 round だけを比較すると，どの情報が与えられていたかや，どの失敗段階を経由したかを見落とす．本研究は round の順序，コード hash，評価分類，履歴の前半・後半の出典を保持して追跡する．最終成功率と履歴分析は代替関係ではなく，異なる粒度で同じ経路を説明するための分析となる．履歴の途中で失敗分類が変わった場合にも，初期類型別の分母は変更しない．

3.2.6 履歴再構成における分岐と到達性

評価器の修正を考える説明用の例として，保存時に失敗と判断されたコードが，新評価では成功になる場合を考える．この場合，新評価を使う手続きではその時点で停止するため，保存されていた次 round のコードは現在の手続きでは生成されない．後続コードを残して都合のよい最終判定を採用すると，成功時停止という設計と矛盾する．再採点後に成功へ変わることは，後続履歴をそのまま保持してよいことを意味しない．
逆に，保存時の成功が新評価では失敗になる場合，現行手続きならさらに修正すべきところで保存履歴が終了している可能性がある．その後のコードは保存されていないため，再採点だけでは補えない．また，成功・失敗の別が変わらなくても，診断文が変われば F/D の次の要求が変わる．診断が後続生成へ入る条件では，採点変更の影響を最終フラグだけに局限できない．
本研究の現在の主経路は，そのような分岐の影響を受けない保存済みの生成履歴の前半部分を利用し，必要な範囲に部分追試による後半部分を接続したものである．後半部分を接続する際には，直前のコードや判定，出典が対応することを確認する．接続先の根拠を失うと，異なる履歴の一部を寄せ

集めて一つの条件が実際に辿り得たように見せる危険がある．到達可能性の確認は，保存データを多く残すことより優先される．
部分追試 293 ケースという数と，部分追試で生成した後半履歴 647 ラウンドという数は単位が異なる．一つの追試ケースに複数 round が生じるため，両者の大小を記録の欠落や重複と解釈しない．同様に，現在の到達 round9,249 は，本体の 5,000 条件記録と対応するが同じ母数ではない．本研究ではどの単位の件数なのかをラベルと manifest へ残し，論文の率の分母に誤用しない．
この方法は，すべての過去生成を一つの条件へ完全に揃え直す操作ではない．保存済みの生成履歴の前半部分の生成時期や要求ログの完全性，元 schema の違いは残る．したがって，再構成した生成履歴の比較は現在採用した経路に関する記述として報告する．保存資産を利用して評価の整合性を回復したことと，全条件を同一時期に新生成した比較実験を行ったことを分けて扱う．

3.2.7 記録の検証と失敗の切り分け

記録検証では，予定されたモデル・タスク・seed・条件の組合せを先に定め，実際の記録と照合する．記録総数が予定件数と同じでも，一部が重複し別の一部が欠けている可能性がある．そのため，件数の一致に加えてキーの集合差と重複を検査する．予定外記録も別に数え，単に総件数へ足して完了率を高く見せない．
共有初期の検証では，同じ初期組に属する B と R/F/D の初期コードや評価が一致していることを確認する．成功時停止の検証では，成功した後に追加生成を行っていないか，最大修正回数を超えていないかを確認する．また，最終評価が実際の到達 round と一致するかを照合する．これらはモデルの成績とは独立したハーネスの整合性検査であり，失敗率が高いこと自体を検証不合格とするものではない．
生成コードのエラーと API 接続障害は異なる集計対象である．生成したコードの import が失敗した場合は，モデル出力が実行環境に適合しなかった結果として含める．一方，要求を送れなかった場合や応答が得られなかった場合には，その対象についてコード品質を観測できていない．両者を同じ失敗として合算すると，生成の可用性とコードの正しさを混同する．
失敗の分類では，原因を確認して接続障害と生成コードの誤りを区別する．本研究の初期失敗 1 組は，未定義変数 sim による NameError と確認し，実行時エラー（未定義変数）に分類した．B4 追加 round にも未定義変数による実行時エラーが 2 件あり，いずれもコード側の NameError である．このように，分類ラベル，例外の由来，最終集計へ含める根拠を分けることで，不明なものを都合よく成功または障害へ振り分けることを避ける．
公開用の検証資料には，出典ファイル名，保存設定，検証状態，hash，集計表を残す一方，生成コード全文や生の API 応答を無条件に含めない．再現性はすべての内部記録を公開することと同義ではない．どの公開集計から論文表を生成できるかを明確にし，詳細記録を参照する際の粒度を区別する．本稿に記載する hash は内容の同一性を確認するための識別子であり，コードの意味的な正しさを保証するものではない．

3.2.8 静的履歴分析の観察単位

片側救済集合を選ぶ際には，まず F/D の最終 L3 判定から集合を定義し，その集合に属する全 83 組を対象とした．都合のよい数例だけを抜き出すと，説明しやすい変更を過大に強調するおそれがあるため，片側集合全体の両条件を追う．ただし，この選択は F/D の不一致に焦点を当てる分析であり，共通成功や双方失敗を含む全 545 組の変更頻度を推定するための標本抽出ではない．
静的変更分類では，import/API，回路構築・インターフェース，量子ゲート等のテキスト，測定・出力取得を注記する．一つの遷移や履歴で複数領域に該当し得るため，カテゴリ件数の合計が対象組数を超えても矛盾ではない．互いに排他的な失敗類型の表と，重複可能な変更領域の表では，合計の読み方が異なることを明示する．
例えば，ある修正で import 文と回路の測定処理が同時に変わり，その後に成功したとしても，どちらの変更が必要だったかを静的差分だけでは分離できない．さらに，ゲート名の出現数が変わったことは，作用順序や引数の変化を十分に表すものではない．同じゲート名の数でも異なる回路になり得るため，文字列特徴を量子回路の意味そのものと解釈しない．
この分析の役割は，救済対象の不一致がどの初期類型に現れ，どのような文字列上の修正領域と同じ履歴に存在したかを，追跡可能な形で残すことである．意味的寄与を確かめるには，個別変更を分離した検証や，回路の作用に基づく別の分析が必要になる．本稿ではその作業を今後の課題とし，今回の静的確認だけで機構の解明が完了したとは主張しない．

3.3 実験設定と出典

3.3.1 対象モデルと課題

対象は Q4，G4，Q9，C7，G3 の 5 モデルである．正式なモデルタグは表 2 に示す．タグ中の数値を厳密なパラメータ数とみなさず，モデル識別子として扱う．各モデル 200 初期組であり，10 タスクと seed 0〜19 を含む．
タスクは Bell，GHZ，Deutsch–Jozsa constant/balanced，Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz の 10 種類である．各タスクは指定入力・期待値を持つ．タスク名が同じでも任意入力を網羅する評価ではない．ハーネスの難度分類を利用するが，普遍的な難しさを表す尺度として解釈しない．

表2 モデルの略号と識別子

略号	モデルタグ	初期組数
Q4	qwen3.5:4b	200
G4	gemma4:e4b-it-qat	200
Q9	qwen3.5:9b	200
C7	qwen2.5-coder:7b	200
G3	gemma3:4b	200

3.3.2 生成条件と元実験の区別

temperature は 0.7，1 要求の生成上限は 1,024 tokens，最大修正回数は 3 回である．保存設定では reasoning_effort は none，timeout_sec は 600，parallel_requests は 1 である．実際に生成された長さは可変であり，上限の同一性は消費量の同一性を意味しない．
元実験は，3 モデル seed 0〜9 の 1,500 条件記録，5 モデル seed 10〜19 の 2,500 条件記録，残り 2 モデル seed 0〜9 の 1,000 条件記録に分かれる．schema や診断文処理の差を保持したうえで，初期組と条件を対応づける．元実験 ID と保存設定の参照先は付録（8.1 節）に示す．
旧 120 件は 2 モデル，seed 0〜2，2 条件，L2 終了の既報であり，現行の L3 による 5,000 条件記録へ合算しない．旧評価，保存コードの再採点，部分追試を三つの独立した主結果として並べない．本稿は 2026-10-16 版の固定スナップショット [3] を唯一の主集計とする．

3.3.3 追加コストと修正回数の集計方針

追加計算コストは共有初期生成を除き，失敗した修正への消費を含めた入力＋出力 tokens の合計である．tokens／救済は総追加 tokens を救済組数で割る．要求時間は保存された elapsed_sec の合計であり，評価時間や全工程の所要時間ではない．
保存済みの生成履歴の前半部分の過去の記録値と，後半履歴の実測値を分離して保持する．合計は再構成した経路に対する計算値である．金銭単価を測定していないため，金銭費用の削減とは呼ばない．修正上限別の集計も同じ最大 3 修正の観測履歴を区切ったものであり，上限ごとに独立実験した結果ではない．

3.3.4 課題集合の役割と被覆範囲

Bell と GHZ は，多量子ビット間の相関を持つ状態の生成と測定を扱う課題として含める．これらが本ハーネスで易に分類されていても，生成コードが常に正しいとは限らない．API や測定方法の誤りがあれば，算法自体の説明が短い課題でも実行や出力の失敗が起こり得る．難度ラベルは人間にとっての普遍的な難しさやモデルにとっての実際の難しさを測定した尺度ではない．
Deutsch–Jozsa の constant と balanced は，課題条件に応じた期待出力を区別する二つのタスクとして数える．同じ算法名の下でも，条件が異なれば生成コードや評価対象が異なる．したがって，10 タスクという集計では二つを別タスクとして扱う．Bernstein–Vazirani と Grover もそれぞれ指定された対象に対する課題であり，任意の秘密列や任意の探索空間へ一般化した評価ではない．
QFT と IQFT は状態ベクトルを比較する課題として含まれる．分布評価だけでは見えにくい位相の違いを指定入力に対して確認するが，変換全体の同値性検査ではない．QPE は指定した位相推定設定に対する測定分布を確認する．Ansatz も指定された構成と出力を持つ課題であり，任意の変分回路を設

計する能力を網羅的に評価しているわけではない．算法名の広い意味と本課題の狭い実装仕様を区別する．
課題集合には，分布と状態の評価方式，量子ビット数，構造制約，使用する回路要素の違いが含まれる．そのため，タスク別成績は単一の難度順へ還元できない．成功率の差には，初期生成でどの種類の誤りが多かったか，出力検査が何を要求するか，修正プロンプトがどの情報を与えるかなど複数の要素が重なる．この分解を十分に行わない段階では，低い救済率を特定の量子算法への理解不足だけで説明しない．

3.3.5 生成設定を揃える意味と限界

同じ temperature を使うことは，各要求のサンプリング設定を揃えるための条件である．しかし，異なるモデルで同じ数値を指定しても，出力の多様性や正解確率が等しくなるとは限らない．モデルの学習内容，語彙，量子化，推論実装などが異なるからである．本研究では temperature の値を設定情報として報告し，モデル間の確率的な挙動が同一であるとは仮定しない．
1,024 tokens という生成上限は，要求ごとの最大出力量を揃える．ただし，実際の出力長は条件と対象に応じて変わる．D では説明・原因分析をコメントとして出力するため，同じ上限内でコード以外の記述が占める割合も変わり得る．このことは比較の条件に含まれるが，今回の集計だけから，出力が長いことが成功を妨げたか，説明が有効だったかを分離して断定することはできない．
timeout と並列要求数は，要求をどのように実行するかの運用条件である．逐次実行であっても，サーバの他の負荷やモデルのロード状態が常に等しいとは限らない．要求時間の比較にはその影響が入り得るため，tokens と時間を同じ意味のコストとして扱わない．時間は保存された要求の経過値であり，評価や待機のすべてを含む工程時間として再解釈しない．
seed の指定は，どの生成をどの初期組へ対応づけるかを再現するための設定として保持する．同じ seed 番号で異なるモデルを呼び出しても，同じ意味の出力候補が得られるわけではない．B4 の追加生成には専用規則があるため，R/F/D と同じ番号を使った同一乱数条件の比較とも呼ばない．本研究の対応は，モデル・タスク・base seed で識別した同じ初期問題を起点とする対応である．

3.3.6 固定出典と執筆時点の切り分け

実験レポートが継続更新されている環境では，執筆日が新しいことと，本文で採用する結果が新しく生成されたことは区別しなければならない．本稿の主結果は 2026-10-16 版の固定到達履歴に基づき，B4 は 2026-10-22 固定の完了集計を加える．今回の本文拡充により，新しいモデル要求や生成コード評価を実行したわけではない．既存結果を説明する文章を増やしても，データの実験時点は変わらない．
固定出典を採用する理由は，本文，表，図，考察が同じ集合と判定から導かれるようにするためである．執筆途中で自動更新レポートの数値だけを転記すると，過去の評価値と現行の到達履歴が混ざる可能性がある．本研究では結果表の出典と hash を記録し，本文の数値をそこへ照合する．集計処理を変更した場合には，元の固定ファイルを上書きするのではなく，変更理由と別の出典を明示する．
公開集計には，実験 ID，保存設定，記録の完備性，集計上の単位を残す．一方，モデルの生出力や例外の全文を本文へ大量に掲載することが，本研究の説明力を直接高めるとは限らない．本文では検証した性質と残る制約を言語化し，詳細な追跡は manifest と CSV へ接続する．数値の根拠を追えることと，読者が分析上の意味を理解できることを両立させる構成とする．

4 結果

4.1 全体の結果と比較の前提

1,000 初期組のうち，初期 L3 成功は 455 組，失敗は 545 組であった．表 3 に，この同じ失敗集合に対する R/F/D の救済と B4 の追加成功を示す．F と D はいずれも初期失敗の約 3 分の 1 を救済し，自己見直し R より救済数が多かった．一方，独立再生成 B4 は 217 組が追加成功し，今回の対象では修正条件を上回った．P は初期コードを共有しないため，後の節で別に扱う．
図 2 は同じ初期失敗 545 組を分母として追加成功率を比較したものである．R/F/D は修正による救済，B4 は独立再生成による追加成功として区別する．
救済率と最終成功率では分母と分子が異なる．例えば F の救済率 33.6%は初期失敗 545 組中 183 組の成功を表し，最終成功率 63.8%は初期成功 455 組の保持を加えた 638/1,000 組を表す．表の追加成功数に初期成功を含めないことで，修正・再生成が新たに成功へ導いた範囲を明確にする．退行 0 は初期成功を保持し，成功時に停止する設計による．
B4 実験は全 1,000 組の記録が揃い，欠落・重複・予定外記録 0，sanity 検証成功であった．追加 round では未定義変数による実行時エラーが 2 件あり，いずれもコード側の NameError であり，API 接続障害とは区別した．R/F/D は保存履歴と部分追試を接続した再構成結果であり，B4 は別途実施した追加実験である．最大生成機会は初回込み 4 回で揃うが，入力情報・seed 規則・実行時期・出典 schema は一致しない．

表3 初期失敗 545 組からの追加成功

条件	追加成功	率	最終成功／1,000
R	96	17.6%	551
F	183	33.6%	638
D	180	33.0%	635
B4	217	39.8%	672

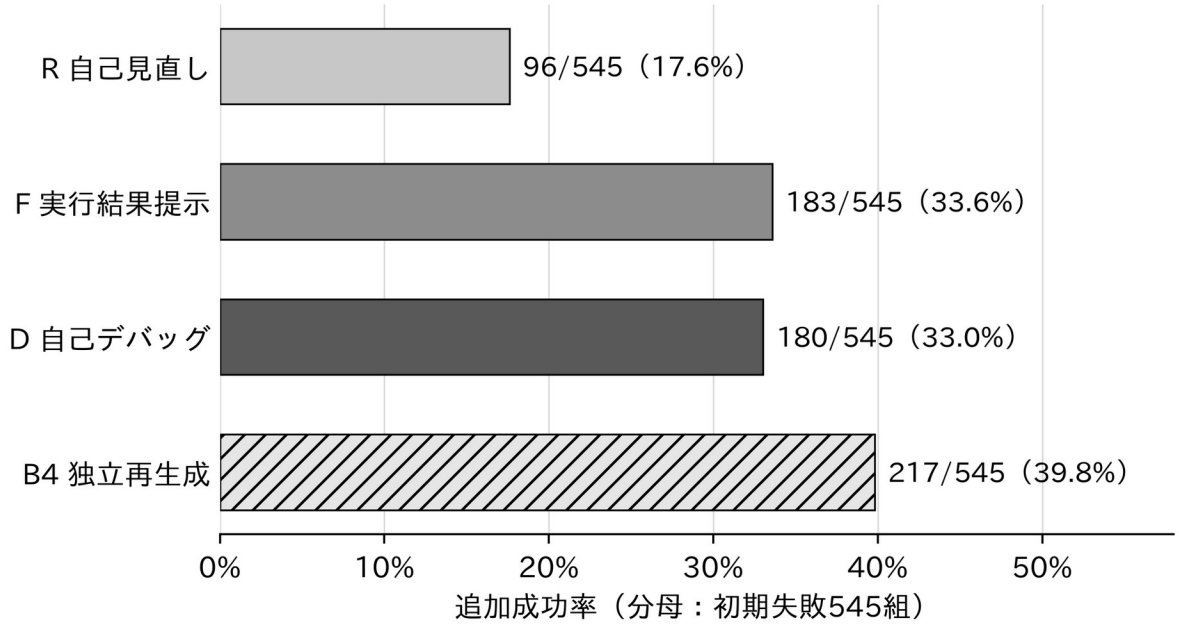


図2 初期失敗 545 組に対する条件別の追加成功率

4.2 モデル別の結果

表 4 は，モデルごとの初期失敗数と追加成功数を示す．G4 では F が 48 組，D が 38 組を救済した一方，Q4 では F78 組，D90 組と大小が逆転した．全体で F が 3 組多いという結果は，すべてのモデルで F が多いことを意味しない．C7 では F/D の救済件数が同じだが，成功した初期組まで一致するとは限らない．

B4 は G4・C7・Q9 で各修正条件より多く追加成功した一方，Q4 では F/D の救済数を下回った．修正と再生成の成績の関係もモデルで異なる．この違いから，最大の全体率を持つ条件だけで各モデルの適用範囲を代表させることは適切でない．ただし，モデルタグ以外の学習内容や量子化などを分離した実験ではないため，特定のモデル特性が差を生んだとは断定しない．
モデル間では初期失敗の大きさと構成が異なる．特に G3 の 190 組は全体分母 545 組の大きな部分を占めるが，このモデルを除いて全体率を再定義することはしない．全体率は表の成功数の合計を失敗数の合計で割った値であり，各モデル率の単純平均ではない．全モデルの数値は表へ集約し，本文では条件間の関係が変わる点を中心に解釈する．

表4 モデル別の追加成功数

対象	分母	R	F	D	B4
Q4	162	31	78	90	66
G4	62	30	48	38	51
Q9	66	15	33	28	37
C7	65	15	23	23	47
G3	190	5	1	1	16

4.3 初期失敗類型別の結果

表 5 では，失敗類型を介入前の B で固定している．import 失敗では D の救済数が F より多く，回路構築失敗では F が D を上回った．F/D の率は，import 失敗で 21.4%／26.6%，回路構築失敗で 60.3%／54.0%である．初期類型により条件間の関係が異なることは，介入カタログへ対象類型と分母を記載する根拠になる．ただし，類型はモデル・タスクと関連するため，類型だけによる選択規則の有効性は未検証である．
出力不一致では，B4 の追加成功 46 組が R/F/D を上回った．この分類は出力を評価する段階まで進んだことを表すが，量子算法の論理だけが誤っていたと認定するものではない．測定や出力取得の処理も判定へ関係する．また，構文・import・構築という分類は検査で露見した段階を示すもので，コード内のすべての欠陥を網羅した原因一覧ではない．
表の「実行時（未定義変数）」は，初期失敗 1 組の原因を確認し，未定義変数 sim による NameError として分類したものである．保存データの分類キーや件数は変更していない．IF 不適合 11 組，量子ビット数不適合 3 組，実行時エラー 1 組は少数例であり，率だけで一般的な選択規則を導かない．途中の修正で別の類型へ移った組も，初期類型の分母に留める．

表5 初期失敗類型別の追加成功数

対象	分母	R	F	D	B4
import 失敗	271	24	58	72	67
回路構築失敗	126	32	76	68	77
構文誤り	68	21	25	21	24
出力不一致	65	16	24	18	46
IF 不適合	11	1	0	1	2
量子ビット数	3	2	0	0	0
実行時（未定義変数）	1	0	0	0	1

4.4 タスク・難度別の結果

全 10 タスクの分母と追加成功数は表 6 にまとめる．Bell や GHZ では F/D が近い一方，Grover では F が D より多く，QFT では両者の救済数が一致した．この一致は個々の成功対象の一致を保証しない．QPE は初期失敗 94 組に対し F13 組，D11 組の救済であり，初期失敗が多いことと，その失敗を修正しやすいことは別の性質である．
難度別の F/D の救済は，易 22/69 組・25/69 組，中 79/225 組・79/225 組，難 82/251 組・76/251 組であった．難度はハーネスの事前区分であり，普遍的な難しさの尺度ではない．難の中には分布評価と状態評価の課題が混在するため，区分間の差を一つの認知的難度へ帰属しない．

各タスクの初期組数は同じでも失敗数は異なるため，全体率には失敗の多いタスクが大きく寄与する．実際の適用先でタスク構成が違う場合，合算率をそのまま期待成功率として用いることはできない．モデル×タスク，元実験，seed 別の内訳は固定 CSV に保持し，個別の数値の反復列挙に代える．

表6 タスク別の追加成功数

対象	分母	R	F	D	B4
Bell	34	2	10	12	13
GHZ	35	9	12	13	14
DJ constant	42	6	12	16	16
DJ balanced	48	7	25	24	19
BV	62	13	19	24	31
Grover	73	14	23	15	36
QFT	67	21	34	34	30
IQFT	50	3	17	15	22
QPE	94	10	13	11	12
Ansatz	40	11	18	16	24

4.5 成功対象の重なりと履歴分析

表 7 に F/D の対応を示す．共通救済 140 組に対し，F のみ 43 組，D のみ 40 組であり，片側救済は合計 83 組であった．全体差が 3 組であっても，成功した対象の入れ替わりはそれより大きい．初期 import 失敗では F のみ 8 組・D のみ 22 組，回路構築失敗では 19 組・11 組となり，周辺の成功率だけでは分からない対象の違いが認められた．

図 3 はこの対応を件数に比例する帯で示したものである．共通救済と片側のみの救済を，双方未救済の集合と合わせて比較できる．

片側 83 組の両条件 166 履歴・398 修正遷移を静的に確認した．救済側の履歴で import/API に関係する変更は F のみ集合の 28 組・D のみ集合の 34 組，回路構築・IF は 24 組・32 組，量子ゲート等のテキストは 38 組・32 組，測定・出力取得は 11 組・16 組に認められた．これらは重複可能な変更領域の注記である．初期失敗の排他的な分類とは異なり，合計を 83 組へ合わせる集計ではない．

B4 と F の共通成功は 131 組，B4 のみ 86 組，F のみ 52 組であった．B4 と D では共通 120 組，B4 のみ 97 組，D のみ 60 組だった．B4 の総成功数が多くても，修正条件の成功集合を包含しない．三条件のすべてで成功した対象は 101 組，いずれも成功しなかった対象は 255 組であり，少なくとも一条件で成功した集合は 290 組となる．詳細な八分割は固定 overlap.csv へ残した．

F/D の和集合 223 組や，B4 を含む和集合 290 組は，結果を見て定まる事後的な集合である．実行前の選択方策の成功数とは扱わない．また，複数箇所が同時に変更されるため，静的差分から成功原因を分離できない．本分析は対象の不一致と履歴の追跡可能性を示すものであり，量子論理の訂正や説明指示の因果的効果を証明するものではない．

表7 F/D の救済対象（初期失敗 545 組）

共通	F のみ	D のみ	双方未救済
140	43	40	322

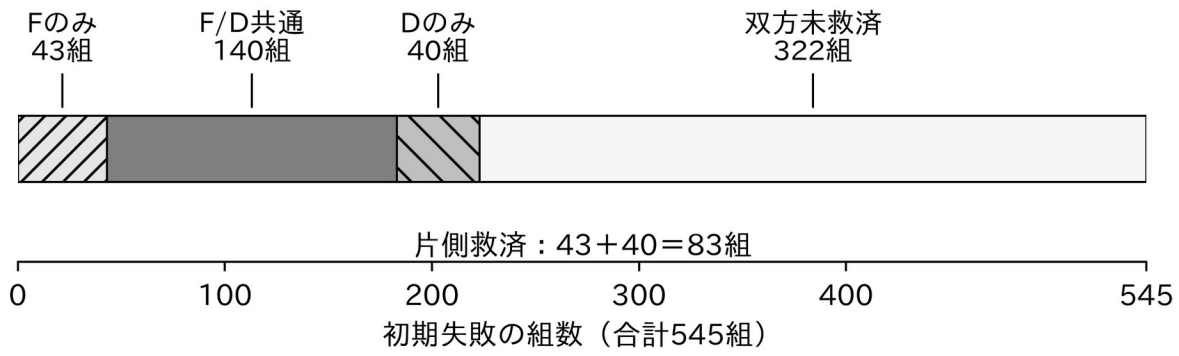


図3 F と D の救済対象の重なり（初期失敗 545 組を排他的な 4 集合に分割）

4.6 追加計算コストと停止回数

表 8 では，共有初期生成を除いた追加要求数・総 tokens・追加成功あたり tokens を比較する．未成功例への消費も含めるのは，実行前にはどの対象が成功するか分からず，失敗した要求も負担するためである．成功履歴だけを抽出した平均と，本指標は異なる．B4 の総追加 995,815 tokens は 1,342 要求で生じたものである．

修正条件の総追加 tokens は，R1,809,845，F1,708,086，D1,975,782 であった．このうち未救済例への消費は，R1,618,684，F1,374,240，D1,605,388 tokens を占めた．F/D には保存済みの生成履歴の前半部分と追試による後半部分が混在し，内訳は固定 CSV に残している．前回コードや診断の有無で入力長も変わるため，表の差を同一条件での診断削除による節約量と解釈しない．要求時間は保存された生成要求の経過時間であり，評価・全工程時間・金銭費用とは区別する．

表 9 に 3 回目の追加救済と消費を示す．F では 2 回後に未救済だった 390 組から 28 組，D では 398 組から 33 組が追加救済された．2 回で打ち切ると，3 回までに救済した集合のうち F15.3%，D18.3%を失う．ここで，残存対象に対する成功率と，最終救済に対する損失率では分母が異なる．

後半 round にはそれ以前に失敗し続けた対象だけが残り，初期の同じ集合へ各 round を独立に適用した実験ではない．この比較は同じ観測履歴の打切り計算であり，上限別に独立実験した結果ではない．停止回数の一般的な最適値は確定せず，得られる成功と未成功への追加計算コストを合わせて方策を検討する材料とする．

表8 共有初期を除く追加計算コスト（未成功への消費を含む）

条件	追加要求	追加 tokens	tokens／追加成功
R	1501	1,809,845	18,852.6
F	1368	1,708,086	9,333.8
D	1380	1,975,782	10,976.6
B4	1342	995,815	4,589.0

表9 3 回目の追加救済と消費

条件	追加／未救済	追加 tokens	要求秒	2 回で失う割合
R	19/468	559,141	24,812.3	19.8%
F	28/390	491,676	21,765.5	15.3%
D	33/398	588,970	28,117.5	18.3%

4.7 P の独立生成としての比較

P では，B の初期失敗に対応する成功 124/545 組（22.8%）と，初期成功に対応する失敗 106/455 組（23.3%）があり，最終成功は 473/1,000 組であった．B との差 18 組は改善と悪化の差引きであり，同じコードを修正した結果ではない．初期成功を保持する R/F/D/B4 と同じ分解で解釈しない．

P の 1,000 独立生成の消費は 764,083 tokens である．これは共有初期を除く追加計算コストを示す表 8 とは集計範囲が異なる．生成前注意事項を含めるという操作の成績として保持し，修正介入の救済率や資源効率と無条件に順位づけない．

5 考察

5.1 修正と独立再生成の比較から得られる知見

本対象では F と D が R より多くを救済したが，B4 はさらに多くの初期失敗を追加成功へ導いた．このため，修正条件を単回生成だけと比べて，診断や前回コードの再利用が成功差の原因だったと結論することはできない．生成機会を増やすこと自体を対照に含める必要がある．一方，B4 と修正条件には片側だけの成功が残り，最大の全体率を持つ条件が他条件を完全に置き換えるともいえない．
前回コードを再利用する修正には，既に正しかった部分を残すという設計上の意図がある．同時に，誤った構造を引き継ぐ可能性や，入力が長くなる影響も考えられる．これらは観測差を説明する仮説であり，今回分離して検証した機構ではない．独立再生成の追加成功が多かったという事実と，その理由を説明する候補を区別する必要がある．
F と D はどちらも診断を使うが，D には説明・原因分析の指示とコメント出力が加わる．結果の差を説明行の存在だけに帰属できず，説明が妥当だったことや内部推論に忠実だったことも直接測定していない．成功数だけでなく対象が入れ替わった点は，介入の入力情報と対象の失敗構成を合わせて比較すべきことを示す．
共有初期により出発点を揃えても，追加の入力情報，seed 規則，出典時期は完全には一致しない．したがって，本研究の到達点は対象集合内の成績と被覆範囲の記述である．診断提示の因果効果，一般的なモデル順位，未知タスクでの最適介入を確定した結果とは区別する．

5.2 介入カタログの構成と適用範囲

介入カタログには，失敗名と推奨条件だけでなく，対象モデル・課題・評価方式，初期失敗の定義，利用する入力情報，生成・停止条件，成功数と分母，未成功を含む追加計算コスト，検証状態と出典を記載する．同じ import 失敗でも，SDK の版や利用可能な API が違えば本研究の結果をそのまま適用できない．適用範囲を追跡できることがカタログの基本となる．
import 失敗と回路構築失敗では F/D の大小が異なった．カタログでは，この観測を表 5 の分母付き結果へ結び付け，診断が示す API 名や操作箇所，前回コードをどこまで残すかを確認項目とする．ただし，診断は潜在的な欠陥のすべてを示すものではない．「この集合では D が多かった」という観測と，「今後は必ず D を選ぶ」という方策の有効性を混同しない．
出力不一致の項目には，分布評価か状態評価か，指定入力，距離閾値，構造要件を含める．出力が違うというラベルだけで，量子算法の論理，測定順序，出力取得の問題を一括して原因認定しない．IF 不適合など少数類型は件数をそのまま残すが，高率や低率だけから未知の対象への選択規則を導かない．
B4 は修正と別の操作として登録し，課題仕様から再生成すること，前回コード・診断を渡さないこと，専用 seed と成功時停止を明示する．単に「再生成」とだけ書くと，一括候補生成や任意回数の再試行と区別できない．同じ操作名でも予算や停止が異なれば，成功集合と消費は変わり得る．
成功率・追加計算コスト・対象の被覆は，必ずしも同じ条件を最良としない．カタログはこれらを比較する根拠を提供する形式であり，今回実証済みの自動選択器ではない．F/D の和集合を利用するにも，事前選択の規則か両条件を実行する手順が必要である．その追加計算コストと停止を含む評価は，今後の方策検証として扱う．

5.3 資源制約と停止方策への含意

要求回数の上限を揃える比較と，tokens 予算を揃える比較は異なる．前回コードや診断を含む条件は入力が長くなり得るため，同じ回数の要求を許しても資源配分は一致しない．本研究は生成機会の上限を対応づけた比較であり，同じ tokens 予算下の最適方策を直接測定したものではない．
未成功例への消費を含めることで，成功した履歴だけを観察する場合には見えない負担を記録できた．ただし，未成功への消費が大きいことから，その対象を事前に識別して無料で除外できるとはいえない．停止方策には，実行前または途中で利用可能な特徴を用いる必要があり，最終結果を見た後の対象選別と区別する．
3 回目の寄与は，救済を失う割合と追加計算コストを同時に検討する材料になる．しかし，最初から短い上限を課す実験では出力や利用者の行動が変わり得る．失敗類型が変わらない場合の停止や，残予算に応じた停止を評価するには，その規則の下で到達可能な逐次経路を実際に生成する必要がある．保存履歴を都合よく貼り合わせて方策の成績を確定しない．

実運用の目的が待機時間，tokens，成功数のどれを重視するかでも選択は変わる．本研究は利用者の読解時間，電力，金銭単価，評価を含む全工程時間を測定していない．記録上の tokens 差を総作業量や金銭費用の同率の削減と解釈せず，測定した資源の範囲に限定して報告する．

5.4 妥当性と限界

内的妥当性に関して，共有初期は初回生成の違いを抑えるが，入力長や指示，実行時期などの交絡は残る．初期性能が異なるモデルで残る失敗の構成も同じではない．R/F/D には保存済みの生成履歴の前半部分と追試による後半部分が混在するため，一つの同時実験だったと表現しない．また，成功時停止後の品質変化は観測しておらず，退行 0 を自由な編集を続けても正しさを保つ保証と扱わない．
構成概念妥当性に関して，L3 は指定入力の出力と構造要件への適合である．任意入力の同値性，保守性，読みやすさ，実機での品質など，実用上の性質すべてを表す指標ではない．命令数の範囲も意味的な正しさを完全には特徴づけない．評価範囲を拡張する場合，保存コードの再採点と，変更後の診断による後続生成を区別する必要がある．
静的履歴分析は文字列上の変更領域を観察するもので，量子変換の意味的差を測定していない．ゲート名の増減から量子論理の訂正を認定できず，複数同時変更の寄与も分離できない．片側 83 組を全件確認したことは，その集合内で都合のよい事例だけを選ばなかったことを意味するが，全 545 組の変更頻度を推定する無作為標本ではない．
外的妥当性に関して，5 モデル・10 タスクの build_circuit()生成は量子開発全体を代表しない．複数ファイル，大規模回路，ツール検索，実機ノイズなどは対象外である．タグ中の数値からパラメータ数や量子化の効果を分離して論じず，モデル・課題・生成上限・実行環境を含む観測として解釈する．有限 shots と測定 seed への依存も残る．
統計的解釈に関して，同じ初期組の複数条件，同じタスクの複数 seed には依存がある．条件記録や round を独立標本として数えない．本研究は件数，率，集合，消費の探索的な記述であり，有意差を検定していないことを「差がないと証明した」と言い換えない．多くの層別集計から選んだ規則を同じデータで評価すると楽観的になるため，探索と検証の集合を分ける必要がある．

5.5 今後の検証計画

第一に，介入選択に使う特徴を初期失敗分類やモデル，出力評価方式など実行前に得られる情報へ限定し，規則を事前固定する．候補規則を作る集合と検証する集合を分け，新しい seed・タスクで成功数と総追加計算コストを測定する．事後的な和集合を方策の成績とする比較から進むための計画である．
第二に，要求数上限だけでなく，入力と出力を含む tokens 予算を揃えた比較を行う．失敗要求，再送，評価時間の扱いを先に定め，結果を見て有利な予算だけを主結果に選ばない．F/D の比較では診断を合わせ，説明・原因分析の指示，出力コメント，入力長と生成上限を明示し，何を変えた実験なのかを限定する．
第三に，固定回数，失敗分類の停滞，残予算などに基づく停止規則を比較する．各規則で到達履歴を生成し，停止で失った成功と節約した消費を同じ対象で測定する．保存履歴の打切り計算は設計の材料に用いるが，実際の方策検証の代わりにはしない．
第四に，測定 seed，距離閾値，入力集合，生成上限を変え，成功集合と条件間の対応の安定性を確認する．評価変更が停止や診断に及ぶ範囲を監査し，再採点の感度分析と新評価下の生成実験を区別する．これらは未実施の計画であり，今回の原稿修正で新たな実験を行ったものではない．

6 おわりに

6.1 研究成果

本研究は，量子回路コードの初期失敗に対する介入を，同じ初期コードからの救済数，成功対象，追加計算コストで比較した．初期失敗 545 組に対し R96 組，F183 組，D180 組を救済した．F/D の全体差は 3 組だが，片側だけが救済した 83 組があり，全体率の近さと成功集合の同一性は異なった．全片側履歴を静的に追跡した一方，変更の意味的寄与の分離は今後に残した．
独立再生成 B4 は 217 組が追加成功し，F/D だけが成功する対象も残った．この結果から，介入カタログには修正だけでなく独立再生成を含め，初期失敗の分母，入力情報，停止条件，未成功を含む消費を併記する必要がある．本稿は新しい介入アルゴリズムの有効性を確定した研究ではなく，方策を検証する前提となる適用範囲を整理した実証研究である．

6.2 今後の課題

次の段階では，実行前に利用できる特徴による選択と停止を事前固定し，別の seed・タスクで検証する．要求数と tokens 予算，出典時期，評価範囲を明示し，事後的な成功集合と実際に使える方策を区別する．L3 が指定入力に限定されることや，共有初期・タスクの依存を保ったまま，比較の範囲を広げる必要がある．
カタログの役割は，一つの条件を常に推奨することではなく，何を対象に，何を与え，どこで止め，どの検査を通過したかを追跡できる形にすることである．成功例だけでなく未成功対象とその消費を残し，観測結果と未検証の方策を区別して更新することが，量子 LLM 支援プログラミングの次の実証へつながる．

7 参考文献

[1] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback，arXiv:2303.17651v2（2023）．https://arxiv.org/abs/2303.17651v2
[2] X. Chen，M. Lin，N. Schärli，D. Zhou: Teaching Large Language Models to Self-Debug，arXiv:2304.05128v2（2023）．https://arxiv.org/abs/2304.05128v2
[3] 伊藤悠真：現行救済経路の固定発表出典（2026-10-16 版）．本リポジトリ docs/presentation_sources/20261016T_reachable_rescues/，results_snapshot.json，source_manifest.json および対応 CSV．B4 追加実験（2026-10-22 固定）：docs/analysis/independent_4_completed_20261022/の保存設定・manifest・sanity・集計 CSV.
[4] M. Chen et al.：Evaluating Large Language Models Trained on Code，arXiv:2107.03374v2（2021）．https://arxiv.org/abs/2107.03374v2
[5] J. Austin et al.：Program Synthesis with Large Language Models，arXiv:2108.07732（2021）．https://arxiv.org/abs/2108.07732
[6] J. Huang et al.：Large Language Models Cannot Self-Correct Reasoning Yet，arXiv:2310.01798（初版 2023，v2 は 2024）．https://arxiv.org/abs/2310.01798
[7] S. Vishwakarma et al.：Qiskit HumanEval: An Evaluation Benchmark For Quantum Code Generative Models，arXiv:2406.14712（2024）．https://arxiv.org/abs/2406.14712
文献[1]，[2]，[4]〜[7]の書誌情報と本文で参照した主張の範囲は，原論文の公開ページで確認した．引用番号は本文の初出順である．文献[3]は本研究の一次資料で，集計時点・保存設定・検証記録を固定している．

8 付録

8.1 出典と再現性

8.1.1 5 モデル追加実験の保存設定

results/shared_five_models_full_20261010T041019864060Z/experiment_config.json
設定 SHA-256：5c9232f76cc6758b52983fe90ec0757ba2ffe2c4972884a25736f09edd45f22a
保存 schema：2.1．ハーネス commit：9c1833eba6020369247358c04e462e0dc1982705．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.2 3 モデル本実験の保存設定

results/shared_three_models_full_20261008T103231611899Z/experiment_config.json
設定 SHA-256：a4cd6ab1126e8927aa3a76c4fcf7392026007215d0388d8b6f73c3bba84691ec
保存 schema：2.0．ハーネス commit：9c6f952b41ac661bb42bb1ffe4d3f37282260658．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.3 2 モデル補完実験の保存設定

results/shared_two_models_seed0_9_full_20261012T100658266051Z/experiment_config.json
設定 SHA-256：dd6b694be0b0c03b3bc33ecc13c69872104a5dba2b66706389b8163a618b0a9b
保存 schema：2.1．ハーネス commit：7ccef09db9bff16785b08f2e7f1ff542cf64b849．モデル digest とプロンプト関数 hash は元 manifest に保持．

8.1.4 固定集計と公開範囲

固定集計時点（UTC）：2026-10-15T15:20:18.335286+00:00
主出典：docs/presentation_sources/20261016T_reachable_rescues/results_snapshot.json
B4 追加実験：independent_4_full_20261020T185811381595Z．固定出典：docs/analysis/independent_4_completed_20261022/．runner_experiment_config.json，runner_manifest.json，summary.csv，pairwise.csv，sanity_report.json，source_manifest.json を参照．
全分母：docs/analysis/reachable_rescues_20261016/core/repair_summary.csv
追加計算コスト：同ディレクトリの cost_by_cap_and_stratum.csv と third_round_summary.csv
片側救済全履歴：discordant_cases.csv と discordant_transitions.csv
検証：core/sanity_report.json，sanity_report.json，validation_report.json
公開資料には生成コード・prompt・API 応答・生例外文・raw.jsonl・秘密情報を含めない．今回の資料作成は固定公開集計の読み取りと文書化であり，追加のモデル要求や生成コード再実行は行わない．

8.2 指標の読み方

8.2.1 集計単位

初期組はモデル×タスク×seed の 1,000 組，条件記録は各組 5 条件の 5,000 記録，到達 round は現在の経路上の 9,249 round である．単位を混ぜて成功率の分母にしない．

8.2.2 退行 0 の意味

R/F/D は初期成功を保持し，修正中も成功時に停止する．退行 0 はこの設計を反映しており，自由な修正を続けても正しさが保たれる保証ではない．

8.2.3 静的変更の意味

import/API やゲート名の変更は観察された文字列上の事実であり，その変更単独の因果的効果や意味的正しさを認定したものではない．

8.2.4 コストの意味

共有初期を除く入力＋出力 tokens と生成要求時間を集計した．再構成した生成履歴の計算値で，評価時間・全工程時間・金銭費用とは異なる．