量子 LLM 支援プログラミングにおける 失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真　　指導教員：横山 哲郎

1 はじめに

大規模言語モデル（LLM）の発展に伴いコード生成が進み，HumanEval［1］や MBPP［2］で性能が評価されている．一方，生成コードには構文・意味的誤りや，存在しない API を用いるハルシネーションが生じ得る．量子プログラミングは量子ビットの重ね合わせ・量子もつれと確率的な測定を扱うため，Python として実行できても期待する量子状態・測定分布を得られるとは限らない．段階的な正しさの検証が必要である．

本研究は，Qiskit コードの初期失敗に対する修正介入の救済率と救済対象の違いを明らかにし，失敗類型に応じた介入カタログの根拠を整理することを目的とする．

2 評価の枠組み

現行評価器では，L0 は構文・import を含むコード読込みと必須関数への適合，L1 は回路構築と評価処理の実行，L2 は指定入力での期待出力との一致，主 L3 は L0〜L2 と構造要件への適合とする．関数名・戻り値・出力形式などのインターフェース適合性と，量子的な出力一致を区別する．

構造要件は量子ビット数や，測定・barrier を除く命令数の範囲などである．主 L3 は限定された基準であり，全入力のアルゴリズム同値性を保証しない．測定分布は 8,192 shots の全変動距離，状態ベクトルは大域位相を整合した距離を用い，0.05 未満を一致とする．測定先は量子ビット順に戻す．救済率は「初期失敗から最終主 L3 成功となった組数／初期主 L3 失敗組数」とし，失敗類型は介入前で固定する．

3 関連研究・準備

Self-Refine［3］は自己フィードバックと反復修正，Self-Debugging［4］はコード説明や実行結果を用いる．推論課題では，外部フィードバックのない自己修正の限界も報告されている［5］．Qiskit は Python で量子回路を構築する基盤であり，Qiskit HumanEval［6］はそのコード生成を評価する．本研究では独自の 10 タスクに修正条件を実装し，先行研究の完全再現とは位置づけない．

4 実験方法

5 モデル・10 タスク・seed 0〜19 の 1,000 初期組を対象に，5 条件，計 5,000 条件記録を分析した．モデル略号は Q4：qwen3.5:4b, G4：gemma4:e4b-it-qat, Q9：qwen3.5:9b，C7：qwen2.5-coder:7b，G3：gemma3:4b である．

タスクは Bell，GHZ，Deutsch − Jozsa（constant/balanced），Bernstein − Vazirani，Grover，QFT，IQFT，QPE，Ansatz とした．temperature は 0.7，1 要求の生成上限は 1,024 tokens である．

B は初期生成，R は自己見直し，F はエラー等の実行結果提示，D は説明・原因分析を促す自己デバッグ，P は生成前注意事項である．R/F/D は B と同じ初期コード・判定から最大 3 回修正し，成功時に停止する．P は別プロンプトによる独立生成である．

検証済み保存記録と部分追試を反映した到達可能な経路を集計した［7］．全件を新規生成・再実行した結果ではない．追加の B4 は同じ初期コードを保持し，初期失敗だけ課題仕様から最大 3 回独立再生成する．前回コード・診断を与えず，専用 seed 規則と成功時停止を用いる．

5 結果

初期成功は 455 組，失敗は 545 組であった．救済は R が 96/545 組（17.6%），F が 183/545 組（33.6%），D が 180/545 組（33.0%）であった．全体率は初期失敗 545 組を分母とする合算値である．

表 1　モデル別の成功件数（分母は初期失敗）

モデル	分母	R	F	D	B4
G3	190	5	1	1	16
G4	62	30	48	38	51
C7	65	15	23	23	47
Q4	162	31	78	90	66
Q9	66	15	33	28	37

表 1 は各モデル 200 初期組のうち失敗した組を分母とする．G4 と Q4 では F と D の大小が入れ替わる．

表 2　初期失敗類型別の成功件数

初期失敗	分母	R	F	D	B4
回路構築	126	32	76	68	77
import	271	24	58	72	67
IF 不適合	11	1	0	1	2
量子ビット数	3	2	0	0	0
構文	68	21	25	21	24
実行時	1	0	0	0	1
出力不一致	65	16	24	18	46

表 2 の import 失敗は F 58/271 組（21.4%），D 72/271 組（26.6%），回路構築失敗は F 76/126 組（60.3%），D 68/126 組（54.0%）であった．IF はインターフェースを表す．「実行時」の 1 組は未定義変数 sim による NameError で，実行時エラー（未定義変数）に分類した．少数分母の率は参考値とする．

表 3　F と D の救済対象（初期失敗 545 組）

共通	F のみ	D のみ	双方未救済
140	43	40	322

F と D の全体の救済数は 3 組差だが，表 3 の片側のみ救済した 83 組では対象が異なる．import 失敗は F のみ 8 組・D のみ 22 組，回路構築失敗は 19 組・11 組であった．83 組すべての両条件 166 履歴・398 修正遷移を静的に確認した．複数箇所が同時に変わるため，変更内容から救済原因は分離できない．少なくとも一方が救済した 223/545 組（40.9%）は事後的な集合であり，実行前の選択方策の成功率ではない．

B4 の追加実験［7］は 1,000 組を完了し，欠落・重複・予定外 0，sanity 検証成功であった．初期失敗から 217/545 組（39.8%）が成功し，最終成功は 672/1,000 組（67.2%）だった．F より 34 組，D より 37 組多い．B4 と F の共通成功は 131 組，B4 のみ 86 組，F のみ 52 組だった．

共有初期を除き未成功例も含む追加 tokens ／追加成功は B4 4,589.0，R 18,852.6，F 9,333.8，D 10,976.6 だった．B4 は追加 1,342 要求・995,815 tokens，R/F/D は保存記録と部分追試の再構成値である．金銭費用ではない．

6 考察

F と D の救済率が近くても救済対象は一致せず，初期失敗類型・モデルによって大小が変わった．介入カタログには全体率だけでなく，適用対象，失敗分母，追加消費を併記する必要がある．ただし，失敗類型はモデル・タスクと関連しており，この結果だけで介入選択規則を確定できない．

B4 と R/F/D は初回込み最大 4 回だが，成功時停止により実要求数は異なる．入力情報・tokens・seed 規則・実行時期・出典 schema に差があり，診断提示の因果効果は断定しない．成功時停止，初期コード・タスク・seed の依存，元実験の診断文差もあり，5,000 条件を独立標本として統計的有意差や一般的優劣を主張しない．主 L3 の入力範囲，有限 shots，生成長上限も限界である．

7 おわりに

初期失敗 545 組に対し，F は 33.6%，D は 33.0% を救済したが，片側のみ救済した 83 組の内訳は異なった．B4 は 39.8%で成功し，再生成対照を含めた検討の必要性を示した．カタログには修正介入に加えて独立再生成も候補として記録する．介入選択・停止方策を事前固定し，別 seed・タスクでも検証する．

参考文献

［1］M. Chen et al.：Evaluating Large Language Models Trained on Code，arXiv:2107.03374（2021）．

［2］J. Austin et al.：Program Synthesis with Large Language Models，arXiv:2108.07732（2021）．

［3］A. Madaan et al.：Self-Refine: Iterative Refinement with Self-Feedback，arXiv:2303.17651（2023）．

［4］X. Chen et al.：Teaching Large Language Models to Self-Debug，arXiv:2304.05128（2023）．

［5］J. Huang et al.：Large Language Models Cannot Self-Correct Reasoning Yet，arXiv:2310.01798（2023）．

［6］S. Vishwakarma et al.：Qiskit HumanEval: An Evaluation Benchmark For Quantum Code Generative Models，arXiv:2406.14712（2024）．

［7］現行到達経路（2026-10-16 版）と B4 追加実験（2026-10-22 固定）の集計・保存設定・出典 hash．本原稿 README に出典と検証記録を示す．