

量子 LLM 支援プログラミングにおける 失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真

指導教員：横山 哲郎

1 はじめに

大規模言語モデル (Large Language Model: LLM) を中心とした生成 AI 技術が発展し [1], コード生成でも実行テストによる機能的正しさの評価が進められている. HumanEval[2] や MBPP[3] は, 生成コードをテストケースで検証するベンチマークである. 一方, 生成コードには構文誤り, 実行時誤り, 仕様への不適合, 出力の誤りが生じ得る.

量子プログラミングでは, コードが実行できても, 期待する量子状態や測定分布が得られるとは限らない. 本研究では Qiskit コードを対象に, 実行ベース検証と自己修正を組み合わせ, 失敗類型ごとの改善, 限界, 退行を分析する. 指定 API や出力形式への適合と, 量子計算として期待出力を返す成功を分け, 有効な介入を整理したカタログの構築を目指す. 本稿は中間発表時の予備結果を保持し, その後の実験環境整備と本実験の途中経過を報告する.

2 評価の枠組み

中間発表では, L0 を構文, L1 を実行可能性とインターフェース, L2 を出力一致, L3 を構造の妥当性として説明した. その後, 評価ハーンネスの実装に合わせて指標を整理した. 現行 L0 は生成コードの実行・import と必須関数の存在・呼出形式, L1 は回路構築後のシミュレーションまたは状態評価, L2 は期待出力との一致を表す. 構造の適合は独立した `structure_match` で判定し, 総合成功を

$$L3 = L0 \wedge L1 \wedge L2 \wedge \text{structure_match} \quad (1)$$

と定義する. 現行 L3 は構造だけの指標ではなく, 旧結果と各段階の通過率を直接合算しない.

生成コードには, 引数なしの `build_circuit` から `QuantumCircuit` を返す形式を求める. 測定分布は 8,192 shots で評価し, 全変動距離, または大域位相を整合した状態ベクトル距離が 0.05 未満なら L2 成功とする. 構造判定は各タスクに定義した量子ビット数やゲート数等の要件に限る.

失敗を構文, import, インターフェース不適合, 回路構築, 量子ビット数, ビット順序, 出力不一致, 未分類エラーに分ける. API 接続・timeout 障害は生成コードの不正解と区別する. baseline が L2 失敗で介入後に成功した場合を救出, baseline 成功から失敗への変化を退行として扱う. インターフェースへの適合による改善と回路出力の改善を切り分けるため, 最終成功率だけでなく round ごとの失敗類型も確認する.

3 関連研究・準備

Self-Refine は, 同じ LLM がフィードバックと反復修正を行う手法である [4]. 一方, 外部フィードバックを用いない推論の自己修正には, 改善が得られない, または性能が低下する場合が報告されている [5]. 後者は推論課題を対象としており, 量子コードや実行結果を使う介入すべての無効性を示すものではない.

Qiskit は量子回路の記述・実行を支援するフレームワークである [6]. GHZ 状態のように, 複数の量子ビットの相関が測定分布に現れる課題では, 実行成功だけでなく期待する分布や状態との照合が必要となる. 量子コード生成のベンチマークとして Qiskit HumanEval も提案されている [7]. 本研究は独自の 10 タスクと評価器を用い, 同ベンチマークそのもののスコアは報告しない.

前回からの準備として, SF3 上に Ollama と 3 モデルを用意し, SSH トンネル経由の API 利用を確認した. 生成, 評価, 集計, sanity check, 検証を自動化し, 完了・検証成功時に設定と公開用集計を GitHub へ自動 commit / push する実験ハーンネスを構築した. 生データと秘密情報は公開せず, 途中レポートを 5 分ごとに更新し, 定期通知で現在のモデル・タスク・条件・件数を確認できる. また, スタイルファイルを AI で確認し, その形式で原稿を作成・更新した.

4 実験方法

4.1 中間発表時の予備実験

中間発表原稿に記載した予備実験は, `qwen2.5-coder:7b` と `gemma3:4b` の 2 モデルを対象とする. Bell, GHZ, Deutsch-Jozsa, Bernstein-Vazirani, Grover, QFT, 逆 QFT, QPE, ansatz 等の 10 タスクについて, seed 0-2 で baseline と Self-Refine を比較し, 計 120 件を収集した. 当時の設定では最大 3 回修正し, L2 達成時に停止した. 以下の既報値は提示された中間発表原稿によるもので, 現行ハーンネスでの再評価値ではない.

4.2 その後の比較実験と本実験

対象を `qwen3.5:4b` (Q4), `gemma4:e4b-it-qat` (G4), `qwen3.5:9b` (Q9) へ変更した. 介入は baseline (B), 自己見直し (R), 実行結果フィードバック (F), 自己デバッグ (D), 生成前注意事項 (P) の 5 条件に拡張した. B と修正型 3 条件は, 同じモデル・タスク・base seed の初期コードと評価を共有する. P は異なる初期プロンプトから独立に生成するため, 生成後の修正と区別する. 修正は最大 3 回で, 現行 L3 達成時に停止する.

2 タスク・2 seed で各 60 件の簡易実験を 2 回行った後, 10 タスク・10 seed (0-9)・5 条件の本実験を開始した. 3 モデルを含め計 1,500 件を予定する. temperature は 0.7, 生成上限は 1 要求 1,024 tokens, `reasoning_effort` は none, timeout は 600 秒で, 要求は逐次送信する.

新しい本実験では, 接続障害時に 5, 10, 20, 30, 30 秒待って最大 5 回再送し, プロンプト・temperature・seed を維持する. seed を外すのは非対応の明示時のみとする. 回復しない接続障害と timeout は記録して停止し, 障害が後続の大量の失敗記録へ波及することを防ぐ. 再試行回数を各 round に保存し, 回復方針が異なる旧結果と新結果は合算しない.

表 1: 中間発表時の L2 成功数 (提示原稿の既報)

モデル	baseline	Self-Refine
qwen2.5-coder:7b	23/30	24/30
gemma3:4b	0/30	0/30
全体	23/60	24/60

5 結果

5.1 中間発表時の既報

表 1 に中間発表時の L2 成功数を示す。Qwen では 23/30 件から 24/30 件へ 1 件増加し、Gemma では両条件とも 0/30 件であった。当時の原稿では QFT の成功率が 67%から 100%へ改善した一方、QPE では修正後に構文・実行段階の通過率が低下する例を報告した。主な失敗は import, 回路構築, 出力不一致であった。

5.2 5 条件の簡易実験

その後の 2 回の簡易実験は、各 60 件の記録と sanity check・自動検証に成功し、API 障害は 0 件であった。各モデル・条件の分母は 4 件である。両実験とも Q4 の B は 1/4 件、R は 2/4 件、F と D は 4/4 件で、F と D は初回失敗 3 件をすべて救出した。G4 の B と修正型条件は 4/4 件で、初回失敗がなく救出率は評価できない。Q9 の B は 3/4 件、F は実験 1 で 4/4 件、実験 2 で 3/4 件であった。P は両実験とも 3 モデル合計 0/12 件だった。少数標本かつ同一 seed 集合の反復であり、一般的なモデルの優劣は主張しない。

5.3 本実験の停止と再実行

旧本実験は 1,500 件を記録したが、接続障害を含む記録 738 件、未分類の評価エラーを含む記録 8 件があり、検証段階で停止した。L2 成功 376 件、失敗 1,124 件には接続不能の影響があり、コード生成能力の比較にそのまま用いない。元の記録を保持し、接続回復対策を適用した新しい本実験を 2026 年 10 月 8 日 19:32 (日本時間) に開始した。

同日 19:42 の固定集計では 19/1,500 件 (1.3%) を記録し、L2 成功 9 件、失敗 10 件であった。接続・timeout 障害、未分類エラー、重複・予定外記録は各 0 件であった。記録はすべて Q4 で、他モデルは未記録である。残り 1,481 件と全件の検証があるため、この結果は暫定であり、モデル間の優劣や介入の効果を確定しない。

6 考察

既報では Self-Refine の総成功数の増加は 1 件にとどまったが、この差だけでは救出と退行の件数を分離できない。その後の簡易実験では Q4 の F と D による救出を確認したものの、モデル、タスク、seed、評価定義が異なるため、中間発表時の改善率と直接比較しない。また、G4 の初期成功例では修正を行わないため、最終成功率の高さを修正能力の証拠とはしない。

import 等のインターフェース・実行上の問題と、測定分布・状態の不一致を分け、どの失敗類型がどの介入で回復するかを調べる必要がある。実行結果の提示と出力形式への適合の効果を完全に分離した因果分析はまだ行っておらず、介入カタログは今後の分析成果として整理する。

現時点では標本数が少なく、シミュレータ seed も固定していないため、モデル seed だけで完全な再現性は保証できない。生成

長の上限、共有サーバ負荷、接続障害も結果に影響する。新しい本実験の接続障害 0 件は記録済み 19 件の範囲の観測であり、障害を完全に解消した証拠ではない。条件ごとの時間・tokens には共有初期生成が含まれるため、単純合計は重複計上となる。

7 おわりに

中間発表で報告した 2 モデル・単一修正介入の予備検証から、SF3 上の 3 モデル・5 条件の比較と自動実験運用へ進んだ。接続障害を切り分け、対策後の本実験を実行している。今後は全件の検証後、モデル・難度・失敗類型別の成功、救出、退行と追加生成コストを分析し、適用条件と限界を明記した介入カタログを作成する。

参考文献

- [1] T. B. Brown et al.: Language Models are Few-Shot Learners, NeurIPS, Vol. 33 (2020).
- [2] M. Chen et al.: Evaluating Large Language Models Trained on Code, arXiv:2107.03374 (2021).
- [3] J. Austin et al.: Program Synthesis with Large Language Models, arXiv:2108.07732 (2021).
- [4] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback, NeurIPS, Vol. 36 (2023).
- [5] J. Huang et al.: Large Language Models Cannot Self-Correct Reasoning Yet, ICLR (2024).
- [6] A. Javadi-Abhari et al.: Quantum computing with Qiskit, arXiv:2405.08810 (2024).
- [7] S. Vishwakarma et al.: Qiskit HumanEval: An Evaluation Benchmark for Quantum Code Generative Models, IEEE QCE, Vol. 1, pp. 1169–1176 (2024).