量子回路コード生成 × LLM

量子 LLM 支援プログラミングにおける失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真

指導教員：横山 哲郎

中間発表 仮版 | 6 分・本編 8 枚 | 2026 年 10 月 16 日

背景と目的：一度の生成で終わらせない

量子回路コード生成で起きる失敗

- import や回路構築で止まる
- 実行できても期待する出力と異なる
- 量子ビット数などの構造条件を満たさない

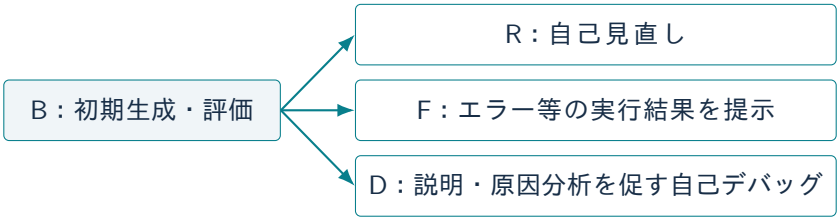
調べたいこと

- どれだけ初期失敗を救済できるか
- 同じ数を救済しても対象は同じか
- 追加修正の消費と救済は見合うか

初期コードを共有して、修正の与え方による違いを比較する。

先行研究：Self-Refine（Madaan et al., 2023）、Self-Debugging（Chen et al., 2023）。
本研究の条件はハーネス内の実装であり、先行研究の完全再現ではない。

実験設計：同じ初期コードから 3 条件へ分岐



5 モデル × **10** タスク × **seed 0〜19 = 1,000** 初期組

- 修正は最大 3 回。主判定に合格した時点で停止する。
- 生成上限 1,024 tokens ／要求、temperature 0.7。
- P：生成前注意事項による独立生成。修正型 3 条件と分けて扱う。

各初期組 5 条件、計 5,000 条件記録。モデル・タスクの一覧は補足 A。

出典：固定集計 20261016T_reachable_rescues / repair_summary.csv / source_manifest.json・各保存設定

評価：初期失敗 545 組を救済率の分母にする

L3：指定入力と構造条件への合格

1. import・必須関数の要件
2. 回路構築と評価処理の実行
3. 指定入力に対する期待出力との一致
4. 量子ビット数・回路命令数の範囲

初期 1,000 組の内訳

455 初期成功

545 初期失敗

救済率

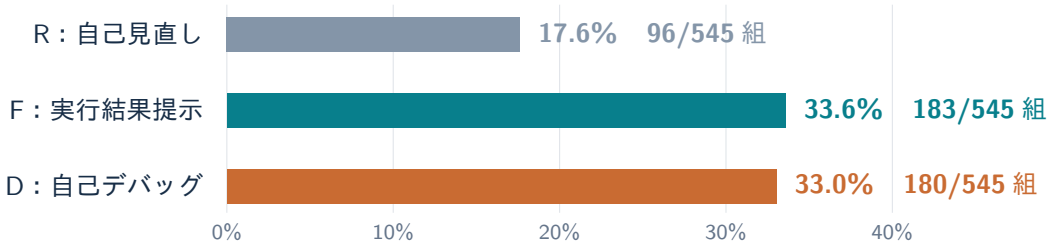
$$\frac{\text{初期失敗から最終 L3 成功}}{\text{初期失敗 545 組}}$$

「全入力で正しい」「全指示を守る」ことまで保証する判定ではない。

現行結果は保存コードの再評価と部分追試 293 ケースを組み合わせた経路。
全件を新評価器で初回生成からやり直した実験ではない。

出典：固定集計 20261016T_reachable_rescues / results_snapshot.json / 評価・追試の仕様照合記録（補足 B）

結果 1：F と D は、初期失敗の約 3 分の 1 を救済



F と D の救済数の差は 3 組。救済率だけでは違いが見えにくい。

分母は共通の初期失敗 545 組。全体率は合算値であり、モデル率の単純平均ではない。
指定モデル・タスク・seed での観測値。一般的な優劣や統計的有意差は主張しない。

出典：固定集計 20261016T_reachable_rescues / repair_summary.csv（pooled / overall）

結果 2：救済数が近くても、救済対象は異なる

	D で救済	D で未救済
F で救済	**140**	**43**
F で未救済	**40**	322

同じ初期失敗 545 組を対応づけた比較。

F のみ・D のみを合わせて

83 組

両条件の 166 履歴・398 修正遷移を確認。

複数箇所が同時に変わるため、変更箇所だけで成功原因は確定できない。

介入の評価には、救済数に加えて「何を救済したか」が必要。

両条件の結果を見て選んだ 223 組を、実行前の選択方策の成功数とは扱わない。

出典：固定集計 20261016T_reachable_rescues / fd_overlap_summary.csv / discordant_transitions.csv

結果 3：追加消費と 3 回目の救済を併せて見る

救済 1 組あたりの追加 tokens

R：自己見直し	18,852.6
F：実行結果提示	**9,333.8**
D：自己デバッグ	10,976.6

共有初期生成を除き、未救済例の消費も含む。
保存記録＋部分追試の再構成計算値。

3 回目の修正による追加救済

	追加救済	全救済中の割合
R	19 組	19.8%
F	28 組	15.3%
D	33 組	18.3%

同じ履歴を 2 回で区切ると失われる救済。
上限別の独立実験ではない。

修正を増やすと救済も増える。停止回数は追加消費との両面で考える。

金銭費用は未測定。実測の費用削減や一般的な最適回数は主張しない。

出典：固定集計 20261016T_reachable_rescues / cost_by_cap_and_stratum.csv / third_round_summary.csv

まとめと今後の課題

今回の対象で観測できたこと

- 初期失敗 545 組に対し、F は 183 組、D は 180 組を救済。
- 全体の救済数が近くても、片側のみ救済する対象が 83 組。
- 3 回目の追加救済と、未救済例を含む追加消費を定量化。

結果の範囲　指定入力・構造要件での成功。共有初期や出典間の差を含む記述的比較。

次の研究課題　介入の選択方法と停止回数を事前に決め、別 seed・タスクで検証する。

「どれだけ救済できるか」から、「どの失敗に何を使うか」へ。

補足 A：モデル別結果と対象タスク

モデル識別子	初期失敗	R 救済	F 救済	D 救済
qwen3.5:4b	162	31	78	90
gemma4:e4b-it-qat	62	30	48	38
qwen3.5:9b	66	15	33	28
qwen2.5-coder:7b	65	15	23	23
gemma3:4b	190	5	1	1

各モデル 200 初期組。救済率はモデルごとの初期失敗を分母に計算する。
10 タスク：Bell、GHZ、Deutsch–Jozsa（constant/balanced）、Bernstein–Vazirani、
Grover、QFT、IQFT、QPE、Ansatz。モデルのタグを厳密なパラメータ数とは扱わない。

初期失敗類型による違い：　import 失敗 271 組で F 58・D 72、回路構築失敗 126 組で F 76・D 68。
類型とモデル・タスクの構成は関連するため、介入選択の一般則にはしない。

出典：固定集計 20261016T_reachable_rescues / repair_summary.csv（pooled / model, baseline_error）

補足 B：検証状況と評価が保証する範囲

- 保存 5,000 記録・9,517 round を再評価。欠落・重複・基盤障害は 0。
- 影響する 293 ケースを部分追試。新規生成 647 回、API 障害 0。
- 原本 hash、共有初期、入力連鎖、成功時停止、生成設定を照合。
- 主判定合格・厳格な補助判定失敗が保存 round に 1 件。
  固定入力では正しいが、全入力で同じ変換になるとは限らない。
- 測定禁止など全プロンプト条件の遵守は保証しない。
  主判定合格・補助適用外の測定入りコードも仕様照合に記録済み。

定義した **L3** の結果として報告する。補助判定を混ぜて成功の定義を変えない。

有限 shots・測定乱数・生成長上限・サーバ負荷への依存が残る。
元 3 実験の設定・診断文差があり、独立標本や因果効果の証拠とは扱わない。

出典：docs/analysis/reevaluation_followup_20261015/ の README、
specification_review.md、partial_rerun_sanity_report.json。全件新規生成ではない。

補足 C：P の位置づけ・出典・先行研究

P：生成前注意事項による独立生成

初期失敗 545 組に対応する成功 124 組、初期成功 455 組に対応する失敗 106 組。
最終成功は 473/1,000 組。同じ初期コードの修正とは分けて解釈する。

固定した結果の出典

`docs/presentation_sources/20261016T_reachable_rescues/`
`results_snapshot.json`、`repair_summary.csv`、`fd_overlap_summary.csv`、
`third_round_summary.csv`、`source_manifest.json`、sanity/validation report。

元 3 実験：3 モデル・seed 0〜9（1,500 条件）、5 モデル・seed 10〜19（2,500 条件）、
残り 2 モデル・seed 0〜9（1,000 条件）。旧 120 件は合算しない。

先行研究

Madaan et al., Self-Refine: Iterative Refinement with Self-Feedback, arXiv:2303.17651, 2023.
Chen et al., Teaching Large Language Models to Self-Debug, arXiv:2304.05128, 2023.