Qiskit 量子回路コードの初期失敗に対する修正介入の救済率と救済対象の分析

著者名（要確認）

所属（要確認）

1　背景と目的

LLM による量子回路コード生成では，import や回路構築の失敗に加え，実行可能でも指定した量子状態・測定分布を返さない場合がある．本研究の主題は，**介入によって初期失敗コードをどれだけ救済できるか**である．実行結果を与えること，自己見直し，自己デバッグで救済率と救済対象がどう異なるかを調べる．失敗類型・モデル・タスクに依存する適用範囲を記述し，介入カタログの根拠を整える．

Self-Refine[1] と Self-Debugging[2] を背景に，本ハーネス内で修正条件を実装した．先行研究の完全再現ではない．課題仕様に沿った合理的な評価を共通手続きとして用い，介入による救済を主要指標とする．

2　方法

2.1　対象と介入

5 モデル・10 タスク・seed 0–19 の 1,000 初期組を対象とし，各組 5 条件，計 5,000 条件記録を対応づける．Q4 は `qwen3.5:4b`，G4 は `gemma4:e4b-it-qat`，Q9 は `qwen3.5:9b`，C7 は `qwen2.5-coder:7b`，G3 は `gemma3:4b` を表す．タグをモデル識別子として使い，数値を厳密なパラメータ数とはみなさない．

タスクは Bell，GHZ，Deutsch–Jozsa（constant/balanced），Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz．temperature 0.7，1 要求の生成上限 1,024 tokens，修正は最大 3 回とする．B は初期生成，R は自己見直し，F はエラー等の実行結果提示，D は説明・原因分析を促す自己デバッグ，P は生成前注意事項である．B と R/F/D は同じ初期コードと判定を共有し，成功時に停止する．P は別プロンプトによる独立生成である．

2.2　救済の定義と検証範囲

L0 は import・必須関数の要件，L1 は回路構築と評価処理の実行，L2 は指定入力に対する期待出力との一致，主 L3 はこれらと構造要件への適合とする．構造要件は量子ビット数と測定以外の回路命令数の範囲であり，全入力のアルゴリズム同値性を保証しない．測定分布は 8,192 shots の全変動距離，状態ベクトルは大域位相を整合した距離を用い，0.05 未満を出力一致とする．測定先を量子ビット順に戻す `evaluation_policy_v4` を採用した．救済率は

$$\frac{\text{初期失敗から最終主 L3 成功となった組数}}{\text{初期主 L3 失敗組数}}$$

と定義する．失敗類型は介入前の B で固定し，修正後の分類で対象を選別しない．

2.3　出典と到達経路

元の保存設定は 3 モデル・seed 0–9（1,500 条件記録），5 モデル・seed 10–19（2,500），残り 2 モデル・seed 0–9（1,000）である．各設定・実験 ID・schema・診断文処理差を固定 manifest に保持する [3]．現在の主経路は検証済み保存 prefix と必要な新 suffix の組合せで，停止判断やフィードバックに影響する部分追試 293 ケースを反映する．分岐後に到達できない旧保存 suffix は除外する．全件を新評価で初回生成からやり直した実験ではない．

今回行ったのは保存済み結果の分析のみであり，追加生成や生成コードの再実行はない．5,000 条件の対応，欠落・重複，成功時停止，共有初期，出典 hash と到達コード hash を確認した．旧結果・保存コード再採点・部分追試は経路の由来であり，三つの独立した主結果として比較しない．旧 120 件は 2 モデル・seed 0–2・2 条件・L2 終了の既報で，再検証・合算しない．

表 1: モデル別の救済件数／率（分母は初期失敗）

区分	分母	R	F	D
G3	190	5 (2.6%)	1 (0.5%)	1 (0.5%)
G4	62	30 (48.4%)	48 (77.4%)	38 (61.3%)
C7	65	15 (23.1%)	23 (35.4%)	23 (35.4%)
Q4	162	31 (19.1%)	78 (48.1%)	90 (55.6%)
Q9	66	15 (22.7%)	33 (50.0%)	28 (42.4%)

表 2: 初期失敗類型別の救済件数

区分	分母	R	F	D
回路構築	126	32	76	68
import	271	24	58	72
IF 不適合	11	1	0	1
量子ビット数	3	2	0	0
構文	68	21	25	21
保存分類 unknown	1	0	0	0
出力不一致	65	16	24	18

3　主要結果：初期失敗の救済

1,000 初期組中，初期成功 455 組，初期失敗 545 組だった．R は 96/545 組（17.6%），F は 183/545 組（33.6%），D は 180/545 組（33.0%）を救済した．R/F/D の最終成功はそれぞれ 551，638，635 組であり，初期成功 455 組の無修正保持を含む．修正型の退行 0 は成功時停止の設計と合わせて解釈する．全体率は 545 組を分母にした合算値で，モデル率の単純平均ではない．

3.1　モデル・初期失敗類型別

表 1 では G4 で F 48/62 組，D 38/62 組，Q4 で F 78/162 組，D 90/162 組と大小が入れ替わる．C7 は両条件 23/65 組で，G3 はともに 1/190 組だった．各モデル 200 初期組のうち失敗した組だけが修正対象であり，異なる失敗分母を併記した．G3 の 190 失敗組も全体分母に含まれる．

表 3: F/D の救済対象（初期失敗 545 組）

共通	F のみ	D のみ	双方未救済
140	43	40	322

表 4: 修正追加コスト（未救済への消費も含む）

条件	保存 10^3tok	新 10^3tok	tok/救済	秒/救済
R	1809.8	0.0	18,852.6	911.1
F	1213.9	494.1	9,333.8	444.2
D	1408.7	567.1	10,976.6	553.6

表 5: 3 回目の追加救済・消費と 2 回打切り時の損失

条件	追加/未救済	千 tok	要求時間 h	失う割合
R	19/468	559.1	6.89	19.8%
F	28/390	491.7	6.05	15.3%
D	33/398	589.0	7.81	18.3%

表 2 では import 失敗に対して F 58/271 組（21.4%），D 72/271 組（26.6%），回路構築失敗に対して F 76/126 組（60.3%），D 68/126 組（54.0%）だった．出力不一致は F 24/65 組，D 18/65 組．類型の構成はモデル・タスクと関連するため，これだけで選択規則を確定しない．保存分類 unknown の 1 組は原因確認記録を出典に持つ生成コード側の失敗で，API 障害を意味しない．少数分母の率は参考値とする．

タスク別では F/D は Bell 10/34･12/34，GHZ 12/35･13/35，QFT 34/67･34/67，QPE 13/94･11/94 だった．難度別の F/D は易 22/69・25/69，中 79/225・79/225，難 82/251・76/251．難度はハーネスの分類であり普遍的尺度ではない．全 10 タスク，モデル×タスク，初期失敗類型，元実験， seed ブロックの分母と件数を固定 CSV に残す．

3.2 救済する対象の違いと 83 組の履歴

表 3 の共通救済は 140 組，F のみ 43 組，D のみ 40 組，双方未救済 322 組だった．少なくとも一方が救済した 223/545 組（40.9%）は，結果を見て選んだ集合であり，実行前の選択方策の成功率ではない．旧分析の片側各 42 組とは混同しない．

現行の片側救済 83 組すべてについて両条件 166 履歴･398 修正遷移を静的確認した．import 失敗は F のみ 8 組･D のみ 22 組，回路構築失敗は 19 組･11 組だった．救済側の到達履歴で import/API に関係する変更行は F のみ 28/83 組，D のみ 34/83 組，回路構築・インターフェース関係は 24/83 組・32/83 組，量子ゲート等のテキスト変更は 38/83 組・32/83 組，測定・出力取得関係は 11/83 組・16/83 組に認められた（重複可）．全 83 組を除外なく確認した結果である．

公開遷移 CSV には前後 round，コード hash，保存 prefix/新 suffix の由来，失敗分類の移動，既知 API・ゲート名の出現数変化を記録した．例えば import/API や回路構築の修正と成功が同じ遷移に現れても，複数箇所が同時に変わるため救済原因を分離できない．静的変更分類は観察事実の注記であり，量子論理の訂正や因果的効果の証明ではない．失敗側の履歴・該当なしの例も CSV に含める．

3.3 P は独立生成として比較

P は B の初期失敗に対応する成功 124/545 組（22.8%）の一方，初期成功に対応する失敗 106/455 組（23.3%）があり，最終成功 473/1,000 組だった．B との差 18 組は改善と悪化の双方を含む．同一コードを修正する R/F/D の救済と同じ作用とは解釈しない．

4 救済コストと 3 回目の寄与

表 4 は共有初期生成を除いた追加修正コストである．未救済例への消費も含む総入力＋出力 tokens を救済数で割った．保存 prefix の過去の記録値と，新 suffix の部分追試時の実測値を分離した．F の総追加 tokens は 1,708,086，D は 1,975,782，R は 1,809,845 だった．未救済への消費は F 1,374,240，D 1,605,388，R 1,618,684 tokens を占める．

要求時間は保存された生成要求の `elapsed_sec` の和で，評価時間や全工程時間ではない．経路の合計は再構成した計算値であり，全件新実験の実測コスト，実測の費用削減とは呼ばない．出典間の負荷・待機・再送処理差があり，金銭費用は未測定である．P の 1,000 独立生成のコストは固定 CSV で別扱いとする．

F の round 別救済は 112，43，28 組，D は 108，39，33 組，R は 57，20，19 組だった．表 5 の 3 回目では，F は 2 回後未救済 390 組から 28 組（7.2%），D は 398 組から 33 組（8.3%）を追加救済した．2 回で区切れば F の 155/183 組，D の 147/180 組を保持する一方，3 回で救済できたうち 15.3%，18.3%を失う．3 回目の消費には最後まで失敗した例も含めた．

この比較は同じ最大 3 修正の観測履歴を区切った結果であり，上限別に独立実験した結果ではない．上限 2/3 のどちらかが一般的に最適とは断定しない．救済を失う割合と追加消費を並べ，対象タスクでの判断材料とする．

5 考察・限界と次のアクション

本対象では F と D が R より多くの初期失敗を救済した．F と D の全体差は 3 組だが，片側救済 83 組が示すように救済対象は異なり，モデル・初期失敗類型で大小が変わる．この観測から一般的な介入の優劣や運用規則を確定しない．

共有初期，同一タスク・seed の依存，元実験の schema・診断文差があり，5,000 条件を独立標本と扱わない．因果効果や統計的有意差は主張しない．指定入力・構造要件に限定した主 L3，有限 shots と未固定の測定乱数，生成上限 1,024 tokens，モデル digest・量子化とサーバ負荷も限界である．保存 prefix には完全な要求ログがない出典もある．静的差分だけでは複数変更の意味的寄与を分離できない．

次は介入選択・停止方策を事前固定し，別 seed・タスクで検証する計画を立てる．意味的変更の人手確認，測定乱数・生成長・負荷への感度も検討する．今回の作業で新しい実験は行っていない．原稿・抄録・固定出典・検証結果を共有用に整えた段階であり，投稿は別途の指示による．

参考文献

[1] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback, arXiv:2303.17651 (2023).

[2] X. Chen et al.: Teaching Large Language Models to Self-Debug, arXiv:2304.05128 (2023).

[3] 現行到達経路の固定集計･保存設定･出典 hash（2026-10-16 版）: 両原稿 README から固定出典の results_snapshot.json と source_manifest.json を参照．全対応記録，83 組の全履歴，コストと 3 回目の集計，sanity/validation report を収録．