量子 LLM 支援プログラミングにおける 失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真　指導教員：横山 哲郎

南山大学 理工学部 電子情報学科

1　背景と目的

LLM による量子回路コード生成では，import や回路構築の失敗に加え，実行可能でも指定した量子状態・測定分布を返さない場合がある．本研究の主題は，**介入によって初期失敗コードをどれだけ救済できるか**である．実行結果を与えること，自己見直し，自己デバッグで救済率と救済対象がどう異なるかを調べる．失敗類型・モデル・タスクに依存する適用範囲を記述し，介入カタログの根拠を整える．

Self-Refine[1] と Self-Debugging[2] を背景に，本ハーネス内で修正条件を実装した．先行研究の完全再現ではない．課題仕様に沿った合理的な評価を共通手続きとして用い，介入による救済を主要指標とする．

2　方法

2.1　対象と介入

5 モデル・10 タスク・seed 0–19 の 1,000 初期組を対象とし，各組 5 条件，計 5,000 条件記録を対応づける．Q4 は `qwen3.5:4b`，G4 は `gemma4:e4b-it-qat`，Q9 は `qwen3.5:9b`，C7 は `qwen2.5-coder:7b`，G3 は `gemma3:4b` を表す．タグをモデル識別子として使い，数値を厳密なパラメータ数とはみなさない．

タスクは Bell，GHZ，Deutsch–Jozsa（constant/balanced），Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz．temperature 0.7，1 要求の生成上限 1,024 tokens，修正は最大 3 回とする．B は初期生成，R は自己見直し，F はエラー等の実行結果提示，D は説明・原因分析を促す自己デバッグ，P は生成前注意事項である．B と R/F/D は同じ初期コードと判定を共有し，成功時に停止する．P は別プロンプトによる独立 1 回生成である．追加対照の B4 は同じ初期コードを保持し，初期失敗組だけ課題仕様から最大 3 回独立再生成する．前回コード・診断は与えず，専用の seed 規則と成功時停止を用いる．初回込み最大 4 回の生成機会を R/F/D と☒える．

2.2　救済の定義と検証範囲

L0 は構文・import を含むコード読込みと必須関数の要件，L1 は回路構築と評価処理の実行，L2 は指定入力に対する期待出力との一致，L3 はこれらと構造要件，共通 system の回路内測定禁止への適合とする．L3 の要件をすべて満たすことを「L3 成功」と呼ぶ．構造要件は量子ビット数と測定・barrier 以外の回路命令数の範囲であり，全入力のアルゴリズム同値性を保証しない．測定分布は 8,192 shots の全変動距離，状態ベクトルは大域位相を整合した距離を用い，0.05 未満を出力一致とする．測定・transpile の seed は 42 に固定する．測定先の対応を反映する旧 v4 に，回路内測定の明示検査を追加した．原課題より強い厳格評価は主結果へ含めない．救済率は

$$\frac{\text{初期失敗から最終 L3 成功となった組数}}{\text{初期 L3 未達組数}}$$

と定義する．失敗類型は介入前の B で固定し，修正後の分類で対象を選別しない．

表 1: モデル別の初期失敗数と追加成功数

区分	分母	R	F	D	B4
G3	190	5	1	1	16
G4	62	30	48	38	51
C7	65	15	23	23	46
Q4	162	31	78	89	66
Q9	66	15	33	28	37

表 2: 初期失敗類型別の追加成功数

区分	分母	R	F	D	B4
回路構築	126	32	76	68	77
import	271	24	58	72	66
IF 不適合	11	1	0	1	2
量子ビット数	3	2	0	0	0
構文	68	21	25	21	24
実行時（未定義変数）	1	0	0	0	1
出力不一致	65	16	24	17	46

2.3　出典と到達経路

元の保存設定は 3 モデル・seed 0–9（1,500 条件記録），5 モデル・seed 10–19（2,500），残り 2 モデル・seed 0–9（1,000）である．各設定・実験 ID・schema・診断文処理差を固定 manifest に保持する [3]．現在の主経路は検証済み保存 prefix と必要な新 suffix の組合せで，停止判断やフィードバックに影響する部分追試 293 ケースを反映する．分岐後に到達できない旧保存 suffix は除外する．旧評価の測定禁止漏れを補い，B4 の 1 経路を元のモデル digest・設定・seed 規則で継続し，追加 1 要求・408 tokens で成功した．全件を新評価で初回生成からやり直した実験ではない．

5,000 条件の対応・欠落・重複・成功時停止・共有初期と出典 hash を確認した．旧 120 件は 2 モデル・seed 0–2・2 条件・L2 終了の既報で，主結果へ合算しない．

3　主要結果：初期失敗の救済

1,000 初期組中，初期成功 455 組，初期失敗 545 組だった．R は 96/545 組（17.6%），F は 183/545 組（33.6%），D は 179/545 組（32.8%）を救済した．R/F/D の最終成功はそれぞれ 551，638，634 組であり，初期成功 455 組の無修正保持を含む．修正型の退行 0 は成功時停止の設計と合わせて解釈する．全体率は 545 組を分母にした合算値で，モデル率の単純平均ではない．

表 1・2 の追加成功は R/F/D では修正による救済，B4 では独立再生成による成功を指す．

表 3: F/D の救済対象（初期失敗 545 組）

共通	F のみ	D のみ	双方未救済
139	44	40	322

表 4: 修正追加コスト（未救済への消費も含む）

条件	保存 10^3tok	新 10^3tok	tok/救済	秒/救済
R	1809.8	0.0	18,852.6	911.1
F	1213.9	494.1	9,333.8	444.2
D	1408.7	567.1	11,037.9	556.7

表 5: 3 回目の追加救済・消費と 2 回打切り時の損失

条件	追加/未救済	千 tok	要求時間 h	失う割合
R	19/468	559.1	6.89	19.8%
F	28/390	491.7	6.05	15.3%
D	32/398	589.0	7.81	17.9%

3.1 モデル・初期失敗類型別

表 1 では G4 は F，Q4 は D の救済数が多く，関係はモデルで異なる．初期失敗数を分母として併記する．

表 2 では import 失敗に対して F 58/271 組（21.4%），D 72/271 組（26.6%），回路構築失敗に対して F 76/126 組（60.3%），D 68/126 組（54.0%）だった．出力不一致は F 24/65 組，D 17/65 組．類型の構成はモデル・タスクと関連するため，これだけで選択規則を確定しない．表の実行時失敗 1 組は，原因確認により未定義変数 sim による NameError と判明し，実行時エラー（未定義変数）に分類したものである．少数分母の率は参考値とする．

タスク・難度・元実験・seed 別の分母・件数も固定 CSV に残す．

3.2 救済する対象の違いと 84 組の履歴

表 3 の共通救済は 139 組，F のみ 44 組，D のみ 40 組，双方未救済 322 組だった．少なくとも一方が救済した 223/545 組（40.9%）は，結果を見て選んだ集合であり，実行前の選択方策の成功率ではない．

片側救済 84 組すべての両条件 168 履歴・404 修正遷移を静的確認した．import 失敗は F のみ 8 組・D のみ 22 組，回路構築失敗は 19 組・11 組だった．公開 CSV に前後 round・コード hash・保存 prefix/新 suffix の由来・分類変化・既知 API/ゲート名の出現数変化を残した．失敗側の履歴も含む．複数箇所が同時に変わるため，静的差分から救済原因や量子論理の訂正を確定できない．

3.3 P は独立生成として比較

P は B の初期失敗に対応する成功 124/545 組（22.8%）の一方，初期成功に対応する失敗 106/455 組（23.3%）があり，最終成功 473/1,000 組だった．B との差 18 組は改善と悪化の双方を含む．同一コードを修正する R/F/D の救済と同じ作用とは解釈しない．

3.4 独立再生成対照 B4 の完了結果

B4 追加実験 [4] は 1,000 組を完了し，欠落・重複・予定外 0，sanity 検証成功だった．初期失敗から 216/545 組（39.6%）が成功し，最終成功 671/1,000 組（67.1%）となった．F より 33 組，D より 37 組多い．B4 と F の共通成功は 130 組，B4 のみ 86 組，F のみ 53 組だった．初期失敗類型別では回路構築 77/126 組，import 66/271 組，出力不一致 46/65 組が成功した．

共有初期生成を除き未成功への消費も含む追加要求は 1,343 回，996,223 tokens，追加 tokens ／追加成功は 4,612.1 だった．R/F/D は保存経路の再構成値であり，B4 とは入力情報・tokens・seed 規則・実行時期・出典 schema・診断文が異なる．同じ上限回数でも実要求数は異なり，診断提示の因果効果や一般的優劣は断定しない．B4 は既存の 5,000 条件へ混ぜず，同じ 1,000 初期組に対する追加対照として扱う．

4 救済コストと 3 回目の寄与

表 4 は共有初期生成を除いた追加修正コストである．未救済例への消費も含む総入力＋出力 tokens を救済数で割った．保存 prefix の過去の記録値と，新 suffix の部分追試時の実測値を分離した．F の総追加 tokens は 1,708,086，D は 1,975,782，R は 1,809,845 だった．

要求時間は生成要求の `elapsed_sec` の和で，評価・全工程時間ではない．再構成経路の計算値であり，全件新実験の実測コストではない．負荷・再送処理差があり，金銭費用は未測定である．

F の round 別救済は 112，43，28 組，D は 108，39，32 組，R は 57，20，19 組だった．表 5 の 3 回目では，F は 2 回後未救済 390 組から 28 組（7.2%），D は 398 組から 32 組（8.0%）を追加救済した．2 回で区切れば F の 155/183 組，D の 147/179 組を保持する一方，3 回で救済できたうち 15.3%，17.9%を失う．3 回目の消費には最後まで失敗した例も含めた．

同じ観測履歴の打切り比較であり，上限別独立実験や一般的な最適上限を示すものではない．

5 考察・限界と次のアクション

本対象では F と D が R より多くの初期失敗を救済した．F と D の全体差は 4 組だが，片側救済 84 組が示すように救済対象は異なり，モデル・初期失敗類型で大小が変わる．この観測から一般的な介入の優劣や運用規則を確定しない．

共有初期，同一タスク・seed の依存，元実験の schema・診断文差があり，5,000 条件を独立標本と扱わない．因果効果や統計的有意差は主張しない．指定入力・構造要件に限定した L3，有限 shots と測定 seed への依存，生成上限 1,024 tokens，モデル digest・量子化とサーバ負荷も限界である．保存 prefix には完全な要求ログがない出典もある．静的差分だけでは複数変更の意味的寄与を分離できない．

B4 の追加成功を踏まえ，カタログには独立再生成も候補として記録する．次は介入選択・停止方策を事前固定し，別 seed・タスクで検証する計画を立てる．意味的変更の人手確認，測定乱数・生成長・負荷への感度も検討する．

参考文献

[1] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback, arXiv:2303.17651 (2023).

[2] X. Chen et al.: Teaching Large Language Models to Self-Debug, arXiv:2304.05128 (2023).

[3] 現行到達経路の固定集計・保存設定・出典 hash（2026-11-04 修正版）:本原稿 README から固定出典を参照（公開リポジトリ: `https://github.com/yuuma-ito/2026_ito_qLLM-ver3`）. 全対応記録，84 組の全履歴，コストと 3 回目の集計，sanity/validation report を収録.

[4] 独立再生成 B4 完了集計（2026-11-04 修正版）:同リポジトリの docs/analysis/measurement_ban_corrected_20261104/. 保存設定・検証済み集計を収録.