Qiskit 量子回路コード生成における 失敗類型と修正介入の実証比較

著者名（要確認）

所属（要確認）

1 はじめに

大規模言語モデル（LLM）が生成する量子回路コードは，実行できても期待する量子状態や測定分布を返すとは限らない．Qiskit コードを対象に，実行ベース検証と自己修正を組み合わせ，どの失敗類型をどの介入が回復し，どこで退行が生じるかを調べる．目的は，適用条件と限界を明示した介入カタログの構築である．本稿では検証済み 3 モデル本実験を主分析とし，完了した 5 モデル追加実験と 2 モデル補完実験を出典別に示し，5 モデル・seed 0–19 の統合結果を記述的に報告する．

2 評価の枠組みと関連研究

Self-Refine は自己フィードバックによる反復修正 [1]，Self-Debugging はコードの説明等を用いた自己デバッグ [2] を検討している．本研究の条件はハーネス内の実装であり，先行研究の完全な再現ではない．量子コードの実行可否と出力・構造への適合を分けて評価する．

L0〜L3 は独立した点数ではなく，段階的な到達水準として扱う．L0 は実行・import と必須関数の要件を満たす段階，L1 はさらに回路構築と評価処理を実行できる段階とする．L2 達成は，L0 および L1 を満たしたうえで期待出力と許容誤差内で一致した場合，L3 達成はさらにタスクに定義された構造要件を満たした場合を意味する．各達成率は全件を分母とし，前段階を含む累積的な割合である．構造適合は `structure_match` にも保存し，総合達成を

$$L3 = L0 \wedge L1 \wedge L2 \wedge \text{structure_match} \tag{1}$$

とする．旧中間発表の「L3 ＝構造」と区別する．引数なしの `build_circuit` から `QuantumCircuit` を返す形式を求める．測定分布は 8,192 shots による全変動距離，状態ベクトルは大域位相を整合した距離で評価し，0.05 未満を L2 成功とする．構造判定は量子ビット数や指定ゲート数等，タスクに定義した範囲に限る．

baseline の L2 失敗から介入後の L2 成功への変化を救出，baseline 成功から最終失敗への変化を退行とする．救出率の分母は対応する baseline 失敗数である．修正途中の評価段階低下は最終 L2 退行とは別に扱う．API 接続・timeout 障害は生成コードの評価失敗と区別する．

3 実験方法

主分析は Q4 ＝ `qwen3.5:4b`，G4 ＝ `gemma4:e4b-it-qat`，Q9 ＝ `qwen3.5:9b` の 3 モデル，10 タスク，seed 0–9，5 条件で 1,500 件．追加分析はこの 3 モデルに C7 と G3 を加え，seed 10–19 で 2,500 件とする．補完分析は C7・G3 の seed 0–9 で 1,000 件とし，統合は各モデル seed 0–19 の 5,000 件とする．Ollama のタグをモデル名として用い，タグの数値を厳密なパラメータ数とはみなさない．モデル digest・量子化情報は保存済み automation report を参照する．

タスクは Bell，GHZ，Deutsch–Jozsa の constant と balanced，Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz の 10 種類．ハーネスの易・中・難分類は普遍的な難度尺度ではない．SF3 上の Ollama を SSH トンネル経由で利用し，temperature 0.7，生成上限 1 要求 1,024 tokens，`reasoning_effort=none`，timeout 600 秒，逐次要求とする．修正上限は 3 回．接続障害時は設定と seed を維持して最大 5 回再送し，回復しない障害は記録して停止する．

条件は baseline（B：初回生成），`self_refine`（R：自己見直し），`execution_feedback`（F：エラーや実行結果を提示），`self_debugging`（D：説明・原因分析・修正），`preventive_spec`（P：生成前注意事項）の 5 種類．B と R・F・D は同一モデル・タスク・base seed の初期コードと評価を共有する．初期または修正後の L3 成功で停止し，修正 round の seed は base seed に round 番号を加える．P は別プロンプトから 1 回独立生成する．1 レコードはモデル・タスク・seed・条件の最終評価と履歴で，round を別件数に数えない．

4 結果

4.1 出典と全件検証

固定集計は 2026 年 10 月 13 日 14:45:33 JST の出典スナップショットによる．主分析は 3 モデル本実験（seed 0–9），追加分析は 5 モデル本実験（seed 10–19）とする．保存設定，実験 ID，検証レポートの対応は末尾の出典 [3] と README に記録した．各実験はモデル構成・seed 集合と実行時ハーネス版が異なる．出典別の結果を保持し，診断文の処理差を明記した記述的な統合結果を別表に示す．

主分析は 1,500/1,500 件，追加分析は 2,500/2,500 件を記録した．両者とも欠落・重複・予定外記録，条件の対応欠落，共有初期評価の不一致は 0 件で，sanity check と automation report は成功した．固定集計の API 障害を含む記録，保存 CSV の timeout は 0 件，最終失敗分類の未分類は 0 件である．コードの評価失敗は実験結果として含める．L2 成功は主分析 839 件（55.9%），追加分析 1,242 件（49.7%）で，失敗はそれぞれ 661 件，1,258 件である．モデル構成が違うため，総率の差を性能の増減とは解釈しない．

4.2 既報との区別

中間発表時の 120 件は 2 モデル・10 タスク・seed 0–2・2 条件で，L2 達成時に修正を終了した既報である．Qwen2.5-Coder の L2 成功は B で 23/30，R で 24/30，Gemma3 は両条件 0/30 だった．この既報は参照原稿による値で，今回生データから再検証していない．現行 L3 終了の本実験や追加分析と合算しない．各 60 件の簡易実験 2 回は予備検証，API 障害 738 件を含む旧本実験は除外資料とし，途中値は全件集計で置き換えた．

4.3 主分析：3 モデル・seed 0–9

表 1 の各モデル・条件は 100 件であり，成功件数は百分率の数値とも一致する．表の L2 と L3 成功件数はすべて一致した．Q4 は B の 15 件から F で 56 件，D で 57 件へ増加し，G4 は 65 件

表 1: 主分析の L2 成功件数（各セル 100 件）

モデル	B	R	F	D	P
Q4	15	33	56	57	11
G4	65	82	87	88	32
Q9	59	73	76	80	25
合計	139	188	219	225	68

表 2: 追加分析の L2 成功件数（各セル 100 件）

モデル	B	R	F	D	P
Q4	20	34	53	61	14
G4	68	85	96	88	31
Q9	57	71	81	78	33
C7	66	74	78	77	66
G3	1	1	1	1	7
合計	212	265	309	305	151

から 87 件，88 件，Q9 は 59 件から 76 件，80 件となった．修正型条件の最終成功数には，初期 L3 成功により修正しなかった例を含む．

4.4 追加分析：5 モデル・seed 10–19

C7 を `qwen2.5-coder:7b`，G3 を `gemma3:4b` と略記する．表 2 も各モデル・条件 100 件で，L2 と L3 件数が一致する．Q4 では D が 61 件，G4 では F が 96 件，Q9 では F が 81 件となった．観測最多の修正条件はモデルと seed 集合によって変わる．C7 は B の 66 件から F で 78 件，D で 77 件，G3 は B と修正型 3 条件が各 1 件だった．

4.5 失敗類型と介入効果

最終失敗は主分析では import 188 件，構文 116 件，回路構築 98 件，インターフェース 76 件，出力不一致 183 件であった．追加分析は import 580 件，構文 121 件，回路構築 202 件，インターフェース 49 件，出力不一致 304 件，量子ビット数不一致 2 件である．これらは全条件の最終失敗分類であり，表 3 の baseline 失敗分類・分母とは異なる．失敗段階と原因も別の分類軸として扱う．

主分析の baseline 失敗は 161/300 件．失敗類型別の救出件数を表 3 に示す．R は 49/161（30.4%），F は 80/161（49.7%），D は 86/161（53.4%）を救出した．import と回路構築では D，インターフェース不適合では F で救出件数が観測最多だった．構文では R と F が同数，出力不一致では D が最多だった．モデル別・難度別の層別検討が必要で，この集計だけで最適介入や因果効果を確定しない．

主分析の P は baseline 失敗から 22/161 件を救出した一方，baseline 成功 139 件中 93 件が失敗に変わった．R・F・D の最終 L2 退行は各 0 件であるが，修正過程の評価段階低下はカタログ定義で R 11 件，F 15 件，D 15 件あり，最終成功率とは区別する．P は別プロンプトの独立生成であり，同一コードの修正効果と解釈しない．

追加分析の古いカタログは途中集計の分母 137 件だったが，全 2,500 件から再生成済みである．今回，3 種類のカタログを再計算値と照合し，4 介入の分母が baseline L2 失敗 288 件と一致することを確認した．R・F・D はそれぞれ 53・97・93 件を救出した．旧固定資料は当時の状態として保持し，本稿は修正後の検証済み出典を用いる．

表 3: 主分析の baseline 失敗類型別救出件数

失敗類型	分母	R	F	D
import	48	11	24	29
回路構築	28	4	16	17
インターフェース	21	8	14	13
構文	33	12	12	10
出力不一致	31	14	14	17
合計	161	49	80	86

表 4: 統合集計の L2・L3 成功件数（各セル 200 件）

モデル	B	R	F	D	P
Q4	35	67	109	118	25
G4	133	167	183	176	63
Q9	116	144	157	158	58
C7	132	148	158	155	129
G3	2	2	2	2	18
合計	418	528	609	609	293

4.6 補完実験と seed 0–19 の統合集計

2 モデル補完実験（seed 0–9）は 1,000 件を記録し，L2・L3 成功 376 件，失敗 624 件だった．QPE seed 2 の自己デバッグ最終 round に残った 1 件は，状態ベクトルを保存せず Result から取得した生成コード側の誤用である．保存済み例外を根拠に exec / interface_mismatch へ読み込み時に再分類し，生データ・生成コード・評価値は保持した．全件の sanity・automation 再検証が成功し，API 障害・timeout・未分類エラーは 0 件となった．

検証済み 3 実験の 1,500 + 2,500 + 1,000 件を統合し，5 モデル× 10 タスク× 20 seed × 5 条件＝ 5,000 件を得た．各モデル 1,000 件，各モデル・条件 200 件で，欠落・重複・予定外記録は 0 件．モデル digest，生成設定，プロンプト，評価環境の一致を確認した．ただし schema 2.0 と 2.1 の診断文処理差を含むため，単一手順の介入効果を示すものではない．出典別内訳を保持した混合手順の記述的集計として報告する．

全条件の L2・L3 成功は 2,457 件（49.14%）で一致した．B の初期 L3 成功 418 件は修正型の各条件で修正せず終了した．初期未達 582 件を分母とする L3 救出は R 110 件，F 191 件，D 191 件である．最終 L3 退行は修正型では 0 件だった．P は別プロンプトの独立生成で，救出 85 件と退行 210 件を分けて扱う．

import では D，構文と出力不一致では F の救出件数が観測最多だった．回路構築では F と D が同数である．モデル・難度・seed ブロックの構成と診断文の差が含まれるため，この表だけから最適介入や統計的有意差を断定しない．

難度別の L2 達成は易は 654/1000 件，中は 880/2000 件，難は 923/2000 件であった．難度区分は本ハーネスのタスク分類であり，普遍的な難度尺度ではない．

4.7 累積達成と到達段階の内訳

表 6 は L0〜L3 の累積達成件数，表 7 は最終到達段階の排他的内訳である．実験 1 は主分析，実験 2 は追加分析を表す．各達成率の分母は同じ行の全件数とし，L1 通過例のみを分母とする条件付き正答率とは区別する．排他的な 5 区分の合計は全件数に一致する．モデル・条件別の全表は README から参照できる固定

表 5: 統合 baseline 失敗類型別の L2 救出件数

失敗類型	分母	R	F	D
import	271	24	55	65
回路構築	106	24	57	57
インターフェース	32	8	14	13
構文	68	21	25	18
出力不一致	102	33	40	38
量子ビット数	3	0	0	0
合計	582	110	191	191

表 6: 水準別の累積達成件数

実験	条件	全件	L0	L1	L2	L3
1	B	300	218	170	139	139
1	R	300	239	207	188	188
1	F	300	256	244	219	219
1	D	300	262	244	225	225
1	P	300	213	157	68	68
2	B	500	322	268	212	212
2	R	500	343	303	265	265
2	F	500	371	350	309	309
2	D	500	373	349	305	305
2	P	500	339	278	151	151

CSV に保存した．本データでは L2 と L3 の件数が一致し，L2 のみ達成した例は 0 件だった．これは定義上の同一性や構造検証の十分性を示さない．

4.8 対応付きの段階移動と初期成功

表 8 は baseline から修正条件の最終評価への到達段階の移動を示す．上昇・維持・低下は順序カテゴリの比較であり，段階差を等間隔の点数として平均しない．部分改善は，上昇したもののL3 未達の例で，上昇件数の内数である．主分析では R・F・D の部分改善が 11・20・22 件，追加分析では 16・20・25 件あった．L3 救出だけではこの改善は見えない．baseline 段階別の 5 × 5 遷移表も固定 CSV に保存した．

主分析の baseline L3 成功 139 件と追加分析の 212 件は，R・F・D の各条件で修正せず終了した．修正対象はそれぞれ 161 件と 288 件である．L3 救出は主分析で R 49/161，F 80/161，D 86/161，追加分析で R 53/288，F 97/288，D 93/288 となった．段階低下は L3 成功からの退行に限らず，L1 から L0 未達への低下などを含む．本データでは修正型の最終 L3 退行は 0 件だが，段階低下は存在した．初期成功を含む全件達成率と，初期失敗を分母とする救出率は別の指標である．

P は別プロンプトの生成前介入であり，修正による移動とは分けて扱う．主分析の対応付き比較では上昇 47・維持 141・低下 112 件，追加分析では 96・266・138 件である．L3 救出は 22/161 件と 46/288 件，baseline L3 成功からの退行は 93/139 件と 107/212 件だった．P の改善例を同一コードの修正成功とは解釈しない．

4.9 構造検証の範囲

表 9 に保存時のタスク定義に基づく構造要件を示す．構造評価は量子ビット数と測定操作を除いた回路命令数の範囲を確認する．条件分岐などの意味や個々のゲート種・接続・深さ・最適性を完全に検証するものではない．本実験の 10 タスクでは古典ビット

表 7: 排他的な最終到達段階の件数

実験	条件	未達	L0 のみ	L1 まで	L2 まで	L3
1	B	82	48	31	0	139
1	R	61	32	19	0	188
1	F	44	12	25	0	219
1	D	38	18	19	0	225
1	P	87	56	89	0	68
2	B	178	54	56	0	212
2	R	157	40	38	0	265
2	F	129	21	41	0	309
2	D	127	24	44	0	305
2	P	161	61	127	0	151

表 8: 修正条件の最終到達段階の移動

実験	条件	上昇	維持	低下	部分改善
1	R	60	229	11	11
1	F	100	185	15	20
1	D	108	177	15	22
2	R	69	416	15	16
2	F	117	374	9	20
2	D	118	371	11	25

数・測定数・回路内測定の必須／禁止は未指定であり，独立した構造制約としては要求しない．分布評価時に評価用コピーへ測定を追加することと，生成回路の構造制約を区別する．L3 は利用可能な要件の範囲での総合達成を表す．タスク定義が実行時コミットと一致することを確認し，ファイル hash としきい値を固定出典に保存した．

5 考察と限界

実行結果を提示する F と原因分析を伴う D は，対象の初回失敗を回復する例を増やした．一方，修正型条件の初期コードは共有され，同じタスク・seed の条件は対応がある．1,500 件や 2,500 件をすべて独立標本とはみなせず，統計的有意差は検定していない．3 モデル主分析と 5 モデル追加分析では seed とモデル構成が異なり，成功率の単純差をモデル変更の因果効果とはみなさない．

評価は独自の 10 タスクと構造要件に限定され，Qiskit HumanEval そのもののスコアではない．ビット順序などを独立した原因として確定するには round 履歴の確認が必要であり，出力不一致をすべて量子論理の誤りとは断定しない．シミュレータ seed が固定されていないため，モデル seed のみで完全再現を保証できない．有限 shots，1,024 tokens 上限，共有サーバ負荷，モデル digest・量子化の違いも限界である．

時間・tokens は共有初期生成を各条件に含むので，条件間の単純合計は重複計上となる．金銭単価は未設定である．生成前の注意事項で成功が減る傾向は現在のプロンプトと対象タスクに限られ，生成前介入一般の無効性を示さない．少数例の観測最多から一般的な最適介入を断定しない．

6 次回までのアクション

追加カタログの分母照合と累積達成・段階移動の整理を完了した．補完実験の再分類・全件検証と，処理差を明記した 5,000 件の統合集計を完了した．さらに，モデル・難度別の救出と退行，成

表 9: タスク別の構造要件

タスク	量子ビット数	回路命令数の範囲
T1	2	2–5
T2	3	3–6
T3a	3	5–10
T3b	3	7–14
T4	4	7–16
T5	2	8–18
T6	3	1–50
T7	3	1–60
T8	4	8–80
T9	2	4–10

功 round，追加時間・tokens を整理し，失敗類型ごとの適用条件と限界をカタログ化する．測定乱数と短い生成上限の影響は，必要性と設定を検討したうえで別途追試を計画する．今回，追加生成や追試は行っていない．

発表準備では，背景，対応付き比較，成功数と救出・退行，限界の順で説明資料を整える．WiNF 原稿の著者・共著者・正式所属と投稿要領は投稿前に確認する．本資料は共有用下書きで，学会投稿は別途の指示で行う．

参考文献

[1] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback, arXiv:2303.17651 (2023).

[2] X. Chen et al.: Teaching Large Language Models to Self-Debug, arXiv:2304.05128 (2023).

[3] 固定集計：到達水準分析のスナップショット（README の出典リンク参照）（2026-10-13 05:45:33 UTC）．主分析：`shared_three_models_full_20261008T103231611899Z`．追加分析：`shared_five_models_full_20261010T041019864060Z`．補完分析：`shared_two_models_seed0_9_full_20261012T100658266051Z`．統合：`shared_five_models_pooled_seed0_19`．設定・CSV・検証報告・hash は README 参照．