

Qiskit 量子回路コード生成における モデルと修正介入の予備比較

著者名（要確認）

所属（要確認）

1 はじめに

大規模言語モデル（LLM）によるコード生成では、初回の出力が実行できても、目的に合う結果が得られるとは限らない。量子回路コードでは、ライブラリの利用方法に加え、量子状態、測定分布、量子ビットの順序を確認する必要がある。Qiskit ではビット 0 を整数表現の最下位ビットとして扱うなど、表示と数値表現の規約を区別する必要がある [3]。そのため、構文や import の成否だけでは生成品質を評価できない。

本研究では、3 種類のローカル LLM による Qiskit コード生成を対象に、初回生成、生成後の修正、生成前の注意事項追加を比較する。実行可能性、出力の正しさ、回路構造を分ける評価ハーネスを構築し、同一の初期コードに対する修正を比較する。本稿では、検証済みの小規模実験 2 回を予備結果として報告する。10 タスクを用いた本実験は進行中であり、途中記録からモデル全体の優劣を結論しない。

2 関連研究と比較の位置付け

Self-Refine は、同じ LLM によるフィードバックと反復修正を用いる手法である [1]。Self-Debugging では、コードの説明や実行結果を利用した自己デバッグが検討されている [2]。本研究はこれらを比較の背景とし、Qiskit コードにおける出力と構造の評価、および baseline 失敗例の救出に着目する。本稿の条件名はハーネス内の実装を指し、先行研究のプロンプトや実験設定を完全に再現したものではない。

単なる最終成功率に加え、初回失敗から成功への変化と、初回成功から失敗への変化を区別する。生成前介入は初期プロンプトが変わるため、同一コードを修正する条件とは区別して解釈する。

3 実験方法

3.1 モデル、タスク、生成設定

対象モデルは Ollama のタグで `qwen3.5:4b`、`gemma4:e4b-it-qat`、`qwen3.5:9b` である。以後、表ではそれぞれ Q4、G4、Q9 と略記する。タグの数値を厳密な総パラメータ数とはみなさず、保存したモデル digest と量子化情報も同定に利用する。環境は Python 3.12.3、Qiskit 2.5.2、Qiskit Aer 0.17.2、OpenAI SDK 3.26.0 である。共有 Ollama の OpenAI 互換 API へ生成要求を逐次送信した。

予備実験の対象は Bell 状態と Deutsch-Jozsa の constant oracle の 2 タスクである。seed は 0, 1 とし、3 モデル × 2 タスク × 2 seed × 5 条件で 1 回 60 レコードを記録した。同じ設定で 2 回実行した。両実験は同一 seed 集合を用いるため、独立した 8 seed の標本として合算しない。1 レコードはモデル・タスク・seed・条件ごとの最終評価と修正履歴であり、修正 round を別レコードとして数えない。

temperature は 0.7、生成上限は 1 要求につき 1,024 tokens、reasoning_effort は none、API timeout は 600 秒、最大修正回数は 3 である。SDK の自動再送は無効とした。ただしクライ

アントには、timeout 以外の初回要求エラーに対して seed を外した再要求を 1 回行う処理があるため、全要求で seed が適用される保証はない。

3.2 比較条件と対応関係

以下の 5 条件を比較する。

- (1) baseline (B) : 初回生成のみ。
- (2) self_refine (R) : モデル自身の見直しによる修正。
- (3) execution_feedback (F) : 評価器のエラーや実行結果を提示した修正。
- (4) self_debugging (D) : 説明・原因分析・修正の手順による自己デバッグ。
- (5) preventive_spec (P) : 生成前に共通の注意事項を加え、1 回のみ生成。

baseline と修正型 3 条件は、同じモデル・タスク・base seed の初期コードと初期評価を共有する。初期評価または修正後評価が後述の L3 成功となれば終了し、それ以外は最大 3 回修正する。修正 round の seed は base seed に round 番号を加えた値とする。初期 L3 成功例では修正要求を行わないため、修正条件の最終成功率には、修正を必要としなかった成功例も含まれる。

P は異なる初期プロンプトから独立に生成する。同じモデル・タスク・seed の baseline と対応付けるが、その差を生成後の修正能力の差とはみなさない。

3.3 段階評価と失敗分類

生成コードには、引数なしで呼び出せる `build_circuit` 関数から `QuantumCircuit` を返すインターフェースを求める。L0 はコードの実行・import と関数の存在・呼出形式、L1 は回路構築後のシミュレーションまたは状態評価、L2 は期待出力との一致を示す。さらに量子ビット数や指定されたゲート数などの構造要件を `structure_match` で判定し、これらをすべて満たす場合を L3 成功とする。修正終了の判定は L3、表に示す出力成功の指標は L2 である。

測定分布タスクは 8,192 shots で得た分布 p と期待分布 q の全変動距離

$$d_{TV}(p, q) = \frac{1}{2} \sum_x |p(x) - q(x)| \quad (1)$$

を用いる。状態ベクトルタスクでは、大域位相を整合させたベクトル間の距離を用いる。距離が 0.05 未満の場合を L2 成功とする。測定がない分布タスクでは、評価用コピーに測定を追加する。構造判定は各タスクで定義した要件の範囲に限られる。

失敗は構文、import、インターフェース、回路構築、量子ビット数、ビット順序、出力不一致等に分類する。API 障害は各 round の生成エラーと timeout も確認し、生成コードの不正解と区別する。baseline が L2 失敗、介入後が L2 成功なら救出とし、救出率の分母を対応する baseline 失敗例数とする。baseline が L2 成功、介入後が L2 失敗なら退行とする。

表 1: 予備実験の L2 成功件数（各セルの分母は 4）

実験	モデル	B	R	F	D	P
1	Q4	1	2	4	4	0
1	G4	4	4	4	4	0
1	Q9	3	4	4	4	0
2	Q4	1	2	4	4	0
2	G4	4	4	4	4	0
2	Q9	3	4	3	4	0

4 予備実験の結果

2 回とも予定 60 件を記録した。欠落・重複・予定外記録は 0 件で、共有初期生成の対応関係を含む sanity check と自動検証に成功した。API 障害を含む記録は 0 件であった。表 1 の各セルは、各モデル・条件における L2 成功件数／4 件を表す。略号は前節の定義に従う。

Q4 では両実験とも baseline 成功が 1/4 件であった。R は 2/4 件、F と D はそれぞれ 4/4 件となり、F と D によって baseline 失敗 3 件すべてが救出された。この対象集合では、実行結果の提示と自己デバッグによって期待出力へ到達する例を確認した。ただし、各条件 4 件の結果から一般的な有効性や統計的な有意差を主張しない。

G4 は両実験とも baseline が 4/4 件で、修正型条件も 4/4 件であった。baseline 失敗例がないため、この集合での救出率は評価できない。初期 L3 成功の場合は修正しないことから、最終成功件数の高さだけを修正能力の証拠とはしない。

Q9 は両実験とも baseline が 3/4 件であった。F は実験 1 で 4/4 件、実験 2 で 3/4 件となり、同一 seed 集合でも最終評価に差があった。生成と有限 shots による評価の両方に変動要因があるため、原因を特定するにはコードと round 履歴の確認が必要である。

P は両実験とも 3 モデル合計で 0/12 件となり、baseline 成功から失敗への退行が各実験で 8 件あった。この結果は現在の注意事項プロンプト、2 タスク、2 seed に限定される。生成前介入一般の無効性や、失敗原因を断定するものではない。

5 本実験の計画と途中経過

本実験は、易タスクの Bell と GHZ、中タスクの Deutsch–Jozsa (constant, balanced), Bernstein–Vazirani, Grover, 難タスクの QFT, IQFT, QPE, Ansatz の計 10 タスクを用いる。難度はハーンネス内の分類であり、普遍的な難度尺度ではない。3 モデル × 10 タスク × 10 seed (0–9) × 5 条件で 1,500 レコードを計画する。

2026 年 10 月 8 日 11:38（日本時間）の固定スナップショットでは 479/1,500 件を記録し、L2 成功 158 件、失敗 321 件、API 障害を含む記録 8 件であった。記録はすべて Q4 のものであり、他の 2 モデルは未記録である。逐次実行によりタスクごとの記録件数にも偏りがあるため、この途中集計を 3 モデルの比較結果として扱わない。全件の sanity check も未完了である。

完了後は、モデル・条件・難度別の L2 と L3 成功率、baseline 失敗類型別の救出、退行、成功 round、時間とトークン数を集計する。API 障害の対象には必要に応じて比較条件をそろえた別実験を行い、元結果と追試を分けて記録する。

6 考察と限界

予備実験では、Q4 の初回失敗例で F と D による救出を確認した。一方、初期成功例では修正を行わないため、最終成功率と baseline 失敗例の救出率を併記する必要がある。P で観測した成功率低下は、注意事項の長さ、出力形式、import、インターフェース、回路ロジックなどの失敗を分けた分析が必要である。

予備実験には難タスクが含まれず、各モデル・条件の標本数は 4 件に限られる。反復実験は同じ seed 集合を用い、修正型条件は同じ初期コードを共有するため、すべての記録を独立標本として扱えない。構造評価はタスクに定義された oracle の範囲に限られ、ゲート種や深さ等を完全には検証しない。

現行評価器はシミュレータ seed を固定しておらず、モデルへの seed 指定だけでは再評価を含む完全な再現性を保証しない。1,024 tokens の生成上限や共有サーバの負荷の影響もある。条件別コストには共有初期生成の値を含むため、単純合計は初期生成を重複計上する。金銭単価は未設定であり、金銭コストは未算出である。

7 おわりに

Qiskit 量子回路コード生成を、モデルと介入条件ごとに比較する評価ハーンネスと予備結果を示した。限定された対象で、初回失敗コードの修正による救出と、生成前の注意事項追加による退行を観測した。今後は本実験の完了・整合性確認・API 障害の切り分けを経て、タスク難度と追加生成コストを含む比較を行う。

参考文献

- [1] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback, arXiv:2303.17651 (2023).
- [2] X. Chen, M. Lin, N. Schärli, D. Zhou: Teaching Large Language Models to Self-Debug, arXiv:2304.05128 (2023).
- [3] IBM: Bit-ordering in the Qiskit SDK, <https://quantum.cloud.ibm.com/docs/en/guides/bit-ordering> (参照 2026-10-08).