Qiskit 量子回路コード生成における 失敗類型と修正介入の実証比較

著者名（要確認）

所属（要確認）

1 はじめに

大規模言語モデル（LLM）が生成する量子回路コードは，実行できても期待する量子状態や測定分布を返すとは限らない．Qiskit コードを対象に，実行ベース検証と自己修正を組み合わせ，どの失敗類型をどの介入が回復し，どこで退行が生じるかを調べる．目的は，適用条件と限界を明示した介入カタログの構築である．本稿では検証済み 3 モデル本実験を主分析とし，完了した 5 モデル追加実験と 2 モデル補完実験を出典別に示し，5 モデル・seed 0–19 の統合結果を記述的に報告する．さらに，介入間の救出対象，追加生成コスト，修正継続の交換関係と評価器の出力表現への感度を検討する．

2 評価の枠組みと関連研究

Self-Refine は自己フィードバックによる反復修正 [1]，Self-Debugging はコードの説明等を用いた自己デバッグ [2] を検討している．本研究の条件はハーネス内の実装であり，先行研究の完全な再現ではない．量子コードの実行可否と出力・構造への適合を分けて評価する．

L0〜L3 は独立した点数ではなく，段階的な到達水準として扱う．L0 は実行・import と必須関数の要件を満たす段階，L1 はさらに回路構築と評価処理を実行できる段階とする．L2 達成は，L0 および L1 を満たしたうえで期待出力と許容誤差内で一致した場合，L3 達成はさらにタスクに定義された構造要件を満たした場合を意味する．各達成率は全件を分母とし，前段階を含む累積的な割合である．構造適合は `structure_match` にも保存し，総合達成を

$$L3 = L0 \wedge L1 \wedge L2 \wedge \text{structure_match} \tag{1}$$

とする．旧中間発表の「L3 ＝構造」と区別する．引数なしの `build_circuit` から `QuantumCircuit` を返す形式を求める．測定分布は 8,192 shots による全変動距離，状態ベクトルは大域位相を整合した距離で評価し，0.05 未満を L2 成功とする．構造判定は量子ビット数と測定を除く回路命令数の範囲に限る．

baseline の L2 失敗から介入後の L2 成功への変化を救出，baseline 成功から最終失敗への変化を退行とする．救出率の分母は対応する baseline 失敗数である．修正途中の評価段階低下は最終 L2 退行とは別に扱う．API 接続・timeout 障害は生成コードの評価失敗と区別する．

3 実験方法

主分析は Q4 ＝ `qwen3.5:4b`，G4 ＝ `gemma4:e4b-it-qat`，Q9 ＝ `qwen3.5:9b` の 3 モデル，10 タスク，seed 0–9，5 条件で 1,500 件．追加分析はこの 3 モデルに C7 と G3 を加え，seed 10–19 で 2,500 件とする．補完分析は C7・G3 の seed 0–9 で 1,000 件とし，統合は各モデル seed 0–19 の 5,000 件とする．Ollama のタグをモデル名として用い，タグの数値を厳密なパラメータ数とはみなさない．モデル digest・量子化情報は保存済み automation report を参照する．

タスクは Bell，GHZ，Deutsch–Jozsa の constant と balanced，Bernstein–Vazirani，Grover，QFT，IQFT，QPE，Ansatz の 10 種類．ハーネスの易・中・難分類は普遍的な難度尺度ではない．SF3 上の Ollama を SSH トンネル経由で利用し，temperature 0.7，生成上限 1 要求 1,024 tokens，`reasoning_effort=none`，timeout 600 秒，逐次要求とする．修正上限は 3 回．接続障害時は設定と seed を維持して最大 5 回再送し，回復しない障害は記録して停止する．

条件は baseline（B：初回生成），`self_refine`（R：自己見直し），`execution_feedback`（F：エラーや実行結果を提示），`self_debugging`（D：説明・原因分析・修正），`preventive_spec`（P：生成前注意事項）の 5 種類．B と R・F・D は同一モデル・タスク・base seed の初期コードと評価を共有する．初期または修正後の L3 成功で停止し，修正 round の seed は base seed に round 番号を加える．P は別プロンプトから 1 回独立生成する．1 レコードはモデル・タスク・seed・条件の最終評価と履歴で，round を別件数に数えない．

4 結果

4.1 出典と全件検証

結果の固定集計は 2026 年 10 月 13 日 14:45:33 JST で，分析・実装状況は 10 月 14 日更新版の出典一覧 [4] による．主分析は 3 モデル本実験（seed 0–9），追加分析は 5 モデル本実験（seed 10–19）とする．保存設定，実験 ID，検証レポートの対応は末尾の出典 [3] と README に記録した．各実験はモデル構成・seed 集合と実行時ハーネス版が異なる．出典別の結果を保持し，診断文の処理差を明記した記述的な統合結果を別表に示す．

主分析は 1,500/1,500 件，追加分析は 2,500/2,500 件を記録した．両者とも欠落・重複・予定外記録，条件の対応欠落，共有初期評価の不一致は 0 件で，sanity check と automation report は成功した．固定集計の API 障害を含む記録，保存 CSV の timeout は 0 件，最終失敗分類の未分類は 0 件である．コードの評価失敗は実験結果として含める．L2 成功は主分析 839 件（55.9%），追加分析 1,242 件（49.7%）で，失敗はそれぞれ 661 件，1,258 件である．モデル構成が違うため，総率の差を性能の増減とは解釈しない．

4.2 既報との区別

中間発表時の 120 件は 2 モデル・10 タスク・seed 0–2・2 条件で，L2 達成時に修正を終了した既報である．Qwen2.5-Coder の L2 成功は B で 23/30，R で 24/30，Gemma3 は両条件 0/30 だった．この既報は参照原稿による値で，今回生データから再検証していない．現行 L3 終了の本実験や追加分析と合算しない．各 60 件の簡易実験 2 回は予備検証，API 障害 738 件を含む旧本実験は除外資料とし，途中値は全件集計で置き換えた．

表 1: 主分析の L2 成功件数（各セル 100 件）

モデル	B	R	F	D	P
Q4	15	33	56	57	11
G4	65	82	87	88	32
Q9	59	73	76	80	25
合計	139	188	219	225	68

表 2: 追加分析の L2 成功件数（各セル 100 件）

モデル	B	R	F	D	P
Q4	20	34	53	61	14
G4	68	85	96	88	31
Q9	57	71	81	78	33
C7	66	74	78	77	66
G3	1	1	1	1	7
合計	212	265	309	305	151

4.3 主分析：3 モデル・seed 0–9

表 1 の各モデル・条件は 100 件であり，成功件数は百分率の数値とも一致する．表の L2 と L3 成功件数はすべて一致した．Q4 は B の 15 件から F で 56 件，D で 57 件へ増加し，G4 は 65 件から 87 件，88 件，Q9 は 59 件から 76 件，80 件となった．修正型条件の最終成功数には，初期 L3 成功により修正しなかった例を含む．

4.4 追加分析：5 モデル・seed 10–19

C7 を `qwen2.5-coder:7b`，G3 を `gemma3:4b` と略記する．表 2 も各モデル・条件 100 件で，L2 と L3 件数が一致する．Q4 では D が 61 件，G4 では F が 96 件，Q9 では F が 81 件となった．観測最多の修正条件はモデルと seed 集合によって変わる．C7 は B の 66 件から F で 78 件，D で 77 件，G3 は B と修正型 3 条件が各 1 件だった．

4.5 失敗類型と介入効果

最終失敗は主分析では import 188 件，構文 116 件，回路構築 98 件，インターフェース 76 件，出力不一致 183 件であった．追加分析は import 580 件，構文 121 件，回路構築 202 件，インターフェース 49 件，出力不一致 304 件，量子ビット数不一致 2 件である．これらは全条件の最終失敗分類であり，表 3 の baseline 失敗分類・分母とは異なる．失敗段階と原因も別の分類軸として扱う．

主分析の baseline 失敗は 161/300 件．失敗類型別の救出件数を表 3 に示す．R は 49/161（30.4%），F は 80/161（49.7%），D は 86/161（53.4%）を救出した．import と回路構築では D，インターフェース不適合では F で救出件数が観測最多だった．構文では R と F が同数，出力不一致では D が最多だった．モデル別・難度別の層別検討が必要で，この集計だけで最適介入や因果効果を確定しない．

主分析の P は baseline 失敗から 22/161 件を救出した一方，baseline 成功 139 件中 93 件が失敗に変わった．R・F・D の最終 L2 退行は各 0 件であるが，修正過程の評価段階低下はカタログ定義で R 11 件，F 15 件，D 15 件あり，最終成功率とは区別する．P は別プロンプトの独立生成であり，同一コードの修正効果と解釈しない．

追加分析の baseline 失敗 288 件から，R・F・D は 53・97・93 件を救出した．全件から再生成したカタログ 3 種類の分母と集計値を照合した．

表 3: 主分析の baseline 失敗類型別救出件数

失敗類型	分母	R	F	D
import	48	11	24	29
回路構築	28	4	16	17
インターフェース	21	8	14	13
構文	33	12	12	10
出力不一致	31	14	14	17
合計	161	49	80	86

表 4: 統合集計の L2・L3 成功件数（各セル 200 件）

モデル	B	R	F	D	P
Q4	35	67	109	118	25
G4	133	167	183	176	63
Q9	116	144	157	158	58
C7	132	148	158	155	129
G3	2	2	2	2	18
合計	418	528	609	609	293

4.6 補完実験と seed 0–19 の統合集計

2 モデル補完実験（seed 0–9）は 1,000 件を記録し，L2・L3 成功 376 件，失敗 624 件だった．QPE seed 2 の自己デバッグ最終 round に残った 1 件は，状態ベクトルを保存せず Result から取得した生成コード側の誤用である．保存済み例外を根拠に exec / interface_mismatch へ読み込み時に再分類し，生データ・生成コード・評価値は保持した．全件の sanity・automation 再検証が成功し，API 障害・timeout・未分類エラーは 0 件となった．

検証済み 3 実験の 1,500 + 2,500 + 1,000 件を統合し，5 モデル× 10 タスク× 20 seed × 5 条件＝ 5,000 件を得た．各モデル 1,000 件，各モデル・条件 200 件で，欠落・重複・予定外記録は 0 件．モデル digest，生成設定，プロンプト，評価環境の一致を確認した．ただし schema 2.0 と 2.1 の診断文処理差を含むため，単一手順の介入効果を示すものではない．出典別内訳を保持した混合手順の記述的集計として報告する．

全条件の L2・L3 成功は 2,457 件（49.14%）で一致した．B の初期 L3 成功 418 件は修正型の各条件で修正せず終了した．初期未達 582 件を分母とする L3 救出は R 110 件，F 191 件，D 191 件である．最終 L3 退行は修正型では 0 件だった．P は別プロンプトの独立生成で，救出 85 件と退行 210 件を分けて扱う．

import では D，構文と出力不一致では F の救出件数が観測最多だった．回路構築では F と D が同数である．モデル・難度・seed ブロックの構成と診断文の差が含まれるため，この表だけから最適介入や統計的有意差を断定しない．

難度別の L2 達成は易は 654/1000 件，中は 880/2000 件，難は 923/2000 件であった．難度区分は本ハーネスのタスク分類であり，普遍的な難度尺度ではない．

4.7 到達段階と構造検証の範囲

L0〜L3 の累積達成と排他的な最終段階，baseline からの 5 × 5 遷移を固定 CSV に保存した．L2 と L3 の件数は一致し，L2 のみ達成は 0 件だったが，定義上の同一性を意味しない．統合の R・F・D で，段階上昇したものの L3 未達の部分改善は 38・49・51

表 5: 統合 baseline 失敗類型別の L2 救出件数

失敗類型	分母	R	F	D
import	271	24	55	65
回路構築	106	24	57	57
インターフェース	32	8	14	13
構文	68	21	25	18
出力不一致	102	33	40	38
量子ビット数	3	0	0	0
合計	582	110	191	191

表 6: 初期失敗類型別の F・D 救出の対応

類型	分母	共通	F のみ	D のみ	双方未達
import	271	47	8	18	198
回路構築	106	46	11	11	38
インターフェース	32	11	3	2	16
構文	68	16	9	2	41
出力不一致	102	29	11	9	53
量子ビット数	3	0	0	0	3
合計	582	149	42	42	349

件，最終段階の低下は 27・25・31 件である．段階は順序カテゴリであり，差を等間隔の点数として平均しない．

構造検証は量子ビット数と測定を除く回路命令数の範囲に限る．全 10 タスクで古典ビット数・測定数・測定の必須／禁止は未指定であり，ゲート種・接続・深さ・最適性や全入力での正しさを完全には検証しない．生成回路への構造要求と，評価用コピーへの測定追加を区別する．

4.8 F と D の対応付き救出と層別結果

F と D は各 191/582 件（32.8%）を救出したが，共通救出 149 件，F のみ 42 件，D のみ 42 件，双方未達 349 件だった．同じ総数でも救出対象は異なる．表 6 は初期失敗類型別の対応を示す．import では D のみ 18 件，構文では F のみ 9 件が観測された．保存済み履歴から，片方が成功する間にもう片方が同類型を繰り返す例や別類型へ移る例を確認した．分類の変化だけで具体的な修正原因は確定しない．モデル別では G4 が F 50/67・D 43/67，Q4 が F 74/165・D 83/165，G3 が双方 0/198 だった．易・中・難の救出は F 25/74・77/248・89/260，D 29/74・83/248・79/260．モデル・難度・seed ブロック・出典別の内訳を保存し，全体の観測最多を一律の介入選択規則にしない．

4.9 修正回数と追加生成コスト

共有初期生成を除いた round 1 以降の追加コストを集計した．未救出例の費用も含む追加 tokens ／救出は R 17,365.1，F 9,584.8，D 11,103.4，要求秒／救出は 841.6，464.8，574.8 だった．時間は保存された LLM 要求の経過時間で，評価処理の時間を含まない．未救出例が修正 tokens の 88.7%，82.0%，81.7%を占めたが，部分改善もあるため無価値とは断定しない．

保存済み履歴を上限 1・2・3 回で区切った累積救出は，R 65 → 90 → 110 件，F 119 → 166 → 191 件，D 114 → 167 → 191 件だった．上限変更の新規実験ではない．表 7 は 3 回目の限界救出と当該 round だけの追加コストを示す．分母は 2 回目まで未達で実際に 3 回目を行った組数である．F 25 件と D 24 件の 3 回目救出は，共通 3 組を除く 46 初期組である．round 1・2 が同じ失敗分類なら停止する候補は，F で 18/25 件，D で 15/24 件の救出を失う．初期から段階上昇した例だけ続ける候補も 19/25 件，21/24 件を失う．これらは同じ履歴を用いた探索的集計であり，運用上の停止方策は未検証である．

表 7: 修正 3 回目の救出と追加コスト

条件	実施組	新規救出	追加 tokens	要求時間（h）
R	492	20	584,463	7.17
F	416	25	528,848	6.70
D	415	24	619,981	8.35

4.10 出力表現への感度と評価器の更新

2026 年 10 月 14 日に LLM を使わない確認用回路 19 例を実行した．正しい QPE でも未使用古典ビット 3 個により出力が 1010 から 1010000 となり，旧比較では不一致になった．測定先から量子ビット順へ戻す比較では，正しい 10 例中，旧比較で失敗した 7 例が成功した．誤った 6 例は不合格を維持し，曖昧な測定 3 例は拒否した．少数の制御例であり，あらゆる誤回路への保証ではない．

保存済み分布 2,880 round 行中 619 行で，タスクの量子ビット数と出力幅が異なった．共有初期生成の重複を含み，部分測定や回路自体の誤りもあり得るため，619 行を独立生成数や表現だけによる失敗数とは扱わない．これらを一括して成功へ変更する根拠はない．

本番評価器へ `qubit_readout_v2` を採用し，未使用古典ビットを合算し，全量子ビットの一意な終端測定から分布を復元する仕様とした．部分測定・上書き・測定後の量子操作等は拒否し，新規 manifest に版と hash を記録する．**本稿の 5,000 件は旧評価器の保存判定であり，新版による再評価結果ではない．** 実装時の 257 テスト成功は処理の検証であり，本稿の成功率が新版でも維持されることを示さない．

5 考察と限界

実行結果を提示する F と原因分析を伴う D は，対象の初回失敗を回復する例を増やした．一方，修正型条件の初期コードは共有され，同じタスク・seed の条件は対応がある．1,500 件や 2,500 件をすべて独立標本とはみなせず，統計的有意差は検定していない．3 モデル主分析と 5 モデル追加分析では seed とモデル構成が異なり，成功率の単純差をモデル変更の因果効果とはみなさない．

評価は独自の 10 タスクと構造要件に限定され，Qiskit HumanEval そのもののスコアではない．ビット順序などを独立した原因として確定するには round 履歴の確認が必要であり，出力不一致をすべて量子論理の誤りとは断定しない．シミュレータ seed が固定されていないため，モデル seed のみで完全再現を保証できない．有限 shots，1,024 tokens 上限，共有サーバ負荷，モデル digest・量子化の違いも限界である．

条件別の全生成時間・tokens は共有初期生成を含むので，条件間の単純合計は重複計上となる．今回の修正追加分は初期生成を除外した．時間には接続回復待機も含まれ，採用記録に未解決 API 障害がないことは再試行なしを意味しない．金銭単価は未設定である．生成前の注意事項で成功が減る傾向は現在のプロンプトと対象タスクに限られ，生成前介入一般の無効性を示さない．少数例の観測最多から一般的な最適介入を断定しない．

6　次回までのアクション

全件検証，層別介入効果，F・D の救出例比較，追加コスト，修正上限と 3 回目継続候補の分析を完了した．次は新版評価器による比較を元判定と別に保存し，出力表現による失敗と量子論理の誤りを区別する．P の古典ビット数に関する注意事項と共通指示の整合を検討する．停止候補は別 seed・タスクでの検証を要する．測定乱数・生成上限の影響を含む追試は設定を検討し，今回追加生成・既存生成コードの再評価は行っていない．

発表準備では，背景，対応付き比較，成功数と救出・退行，限界の順で説明資料を整える．WiNF 原稿の著者・共著者・正式所属と投稿要領は投稿前に確認する．本資料は共有用下書きで，学会投稿は別途の指示で行う．

参考文献

[1] A. Madaan et al.: Self-Refine: Iterative Refinement with Self-Feedback, arXiv:2303.17651 (2023).

[2] X. Chen et al.: Teaching Large Language Models to Self-Debug, arXiv:2304.05128 (2023).

[3] 固定集計：到達水準分析のスナップショット（README の出典リンク参照）（2026-10-13 05:45:33 UTC）．主分析：`shared_three_models_full_20261008T103231611899Z`．追加分析：`shared_five_models_full_20261010T041019864060Z`．補完分析：`shared_two_models_seed0_9_full_20261012T100658266051Z`．統合：`shared_five_models_pooled_seed0_19`．設定・CSV・検証報告・hash は README 参照．

[4] 追加分析と評価器更新の固定出典一覧：`docs/winf2026/analysis_snapshot_20261014.json`．層別効果，F・D 救出，コスト，上限比較，継続候補，出力表現確認の CSV・manifest・検証報告と評価器仕様（2026-10-14）．