初期失敗コードを，どこまで救済できるか

量子 LLM 支援プログラミングにおける失敗類型と介入カタログの実証研究

2023TC011 伊藤 悠真　　指導教員：横山 哲郎
南山大学 理工学部 電子情報学科

救済率・救済対象・追加消費から，介入の候補を整理する

実行できても，期待した量子出力とは限らない

読込み

import ・構文

API や必須関数の要件

回路構築

回路を作れるか

構築・評価処理の実行

出力検証

期待出力か

指定状態・測定分布

研究の問い：どれだけ救済できるか／何を救済するか

失敗類型・モデル・追加消費を併記した介入カタログへ

同じ初期コードから，修正と再生成を比較する

初期生成 B

→	R 自己見直し	自分のコードを見直す
→	F 実行結果提示	エラー等の診断を提示
→	D 自己デバッグ	診断＋説明・原因分析
→	B4 独立再生成	前回コード・診断は渡さない

R/F/D/B4 ：初回込み最大 4 回・成功時停止／P は別プロンプトの独立 1 回生成

対象は 1,000 初期組. 出典を揃えて比較する

5 モデル × 10 タスク × seed 0 〜 19 ＝ 1,000 初期組

項目	設定・範囲
モデル	Q4 / G4 / Q9 / C7 / G3 （正式タグは補足）
タスク	Bell ・ GHZ ・ DJ 2 種・ BV ・ Grover ・ QFT ・ IQFT ・ QPE ・ Ansatz
生成設定	temperature 0.7 ／ 1 要求の生成上限 1,024 tokens
集計対象	B/R/F/D/P 計 5,000 条件 ＋ 同じ初期組への追加対照 B4

保存記録＋必要な部分追試 293 ケースを反映. 全件新生成の実験ではない

救済率の分母は，初期失敗 545 組

初期成功

455 組

無修正で保持

初期失敗

545 組

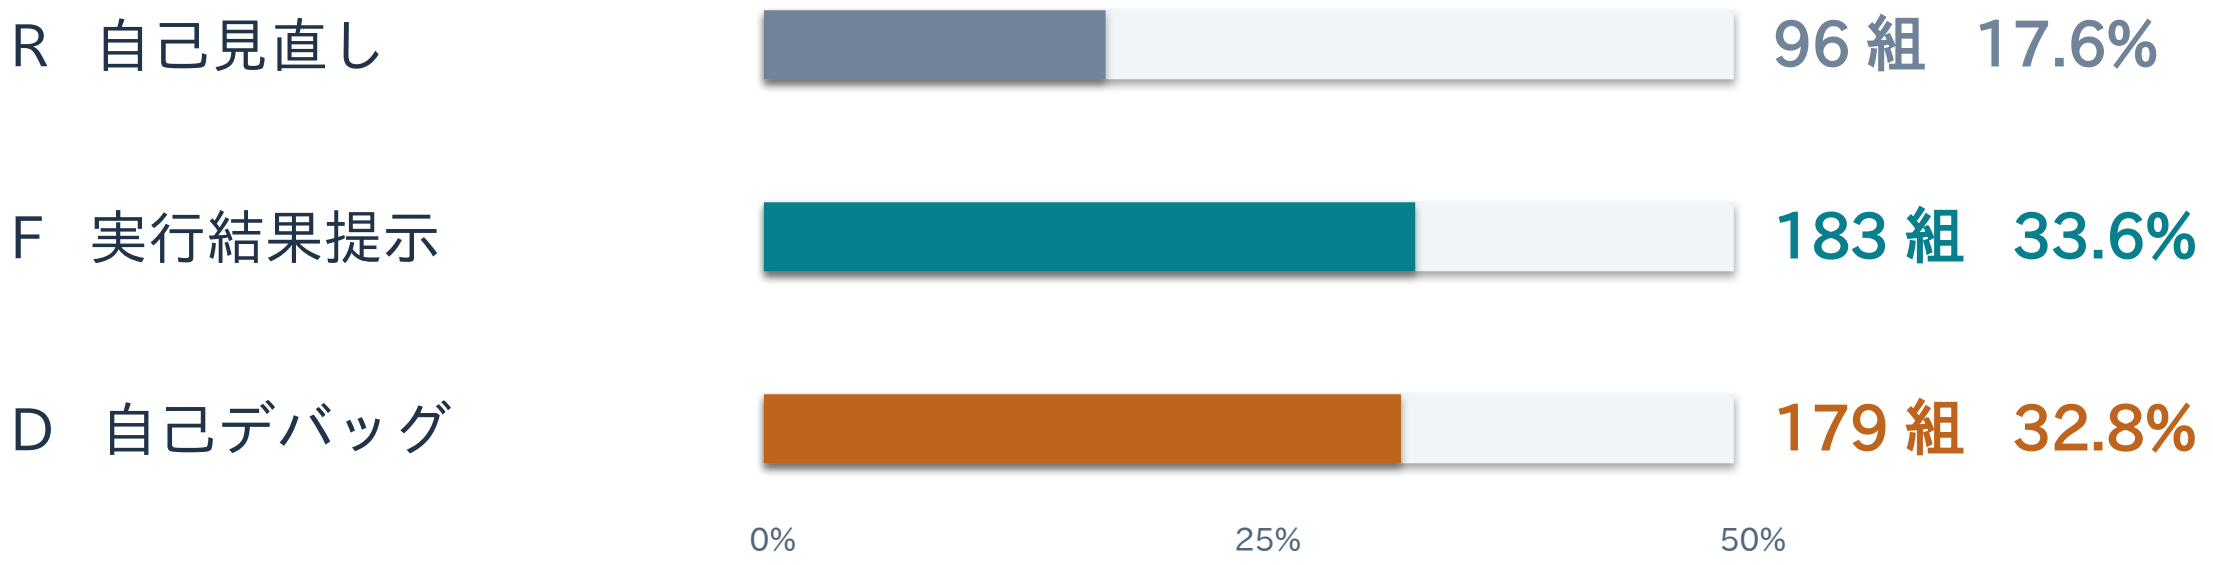
修正・再生成の対象

救済率 ＝ 初期失敗から修正で最終成功となった組数 ／ 545

L3 成功：読込み・構築・指定入力の出力一致 ＋ 所定の構造要件

L3 は全入力のアルゴリズム同値性を保証しない

F と D は初期失敗の約 3 分の 1 を救済



共通分母：初期失敗 545 組／初期成功 455 組の無修正保持は救済数に含めない

F と D の全体差は 4 組．同じ対象を救済しているか？

救済数が近くても，救済する対象は異なる

F のみ

44 組

初期失敗 545 組の内訳

F/D 共通

139 組

初期失敗 545 組の内訳

D のみ

40 組

初期失敗 545 組の内訳

片側救済 84 組：両条件 168 履歴・ 404 修正遷移を静的に確認

双方未救済 322 組／複数変更が同時に起きるため，救済原因は分離できない

和集合 223 組は事後的な集合．実行前の選択方策の成功率ではない

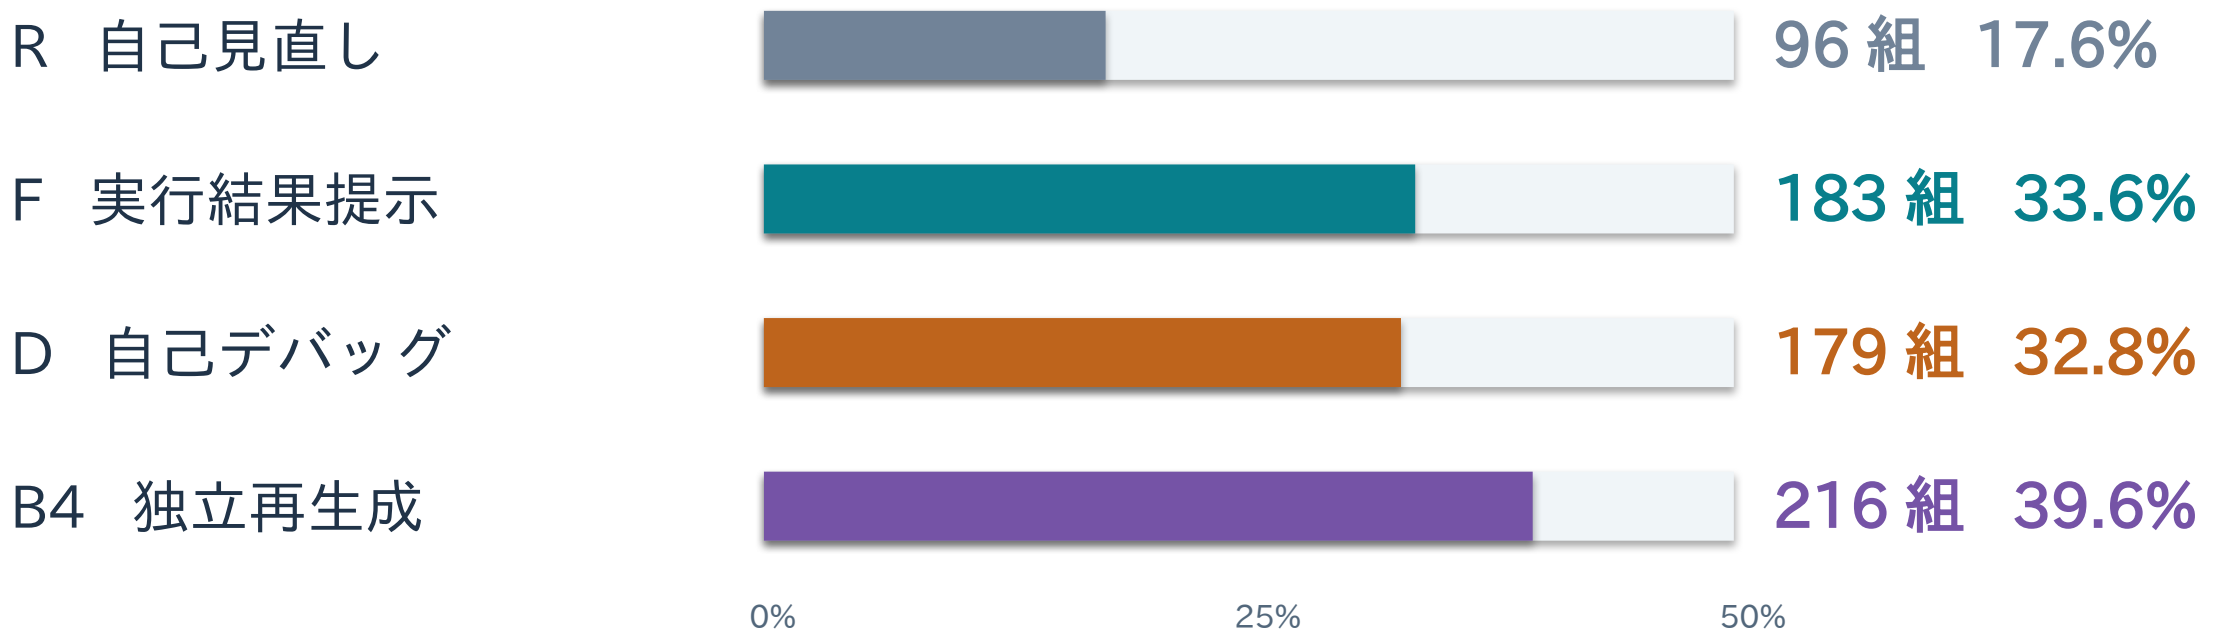
初期失敗類型によって，Ｆと Ｄ の関係が変わる

初期失敗類型	分母	R	F	D
import 失敗	271	24 (8.9%)	58 (21.4%)	72 (26.6%)
回路構築失敗	126	32 (25.4%)	76 (60.3%)	68 (54.0%)
出力不一致	65	16 (24.6%)	24 (36.9%)	17 (26.2%)

類型は介入前で固定／モデル・タスクの構成と関連する

カタログでは全体率だけでなく，対象類型と分母を示す

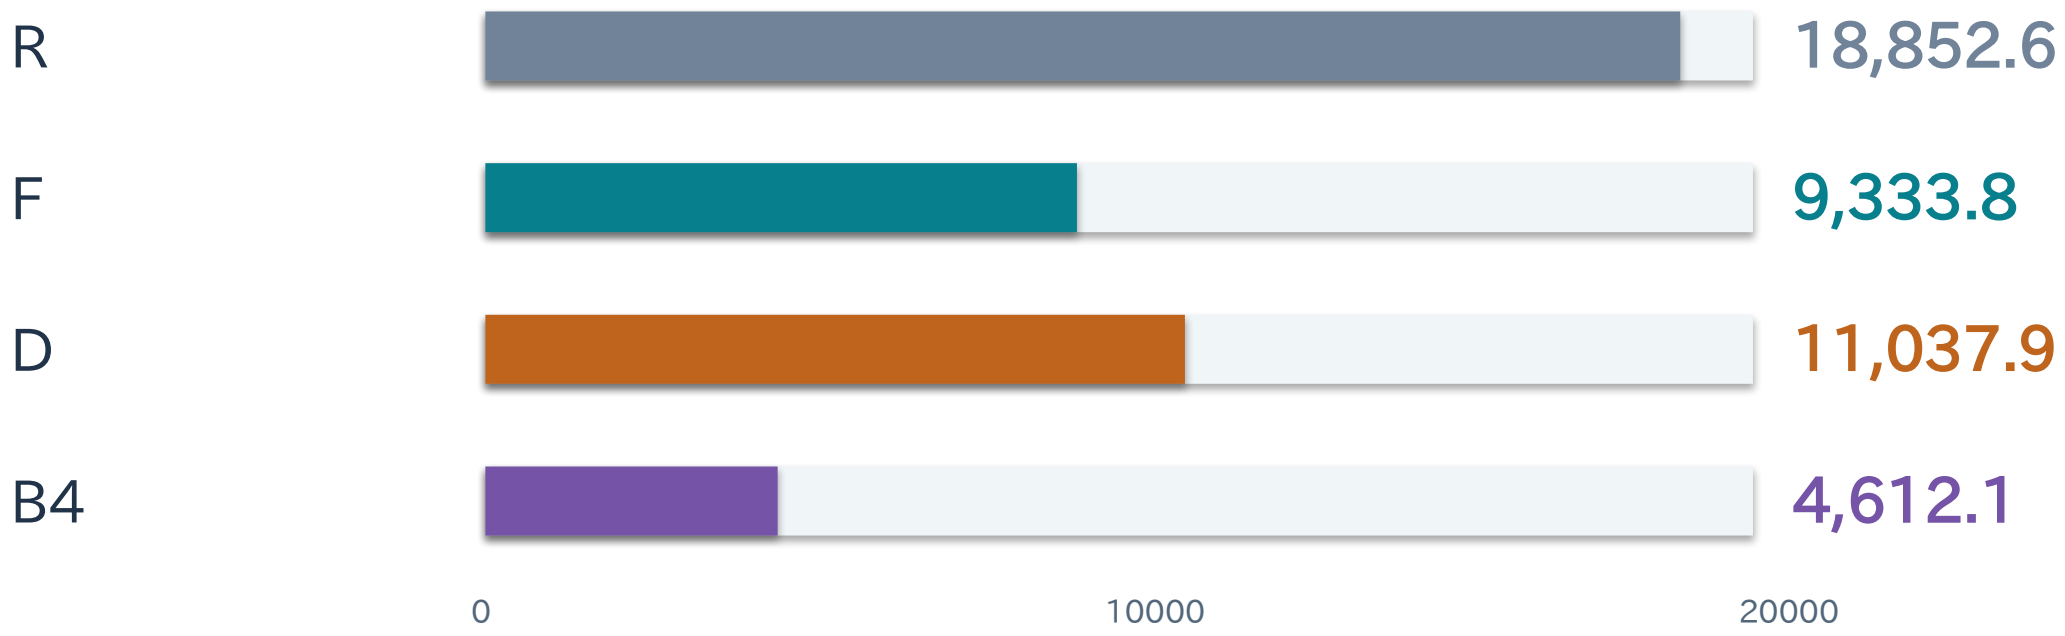
独立再生成 B4 では 216 組が追加成功した



B4 最終成功 671/1,000 組（67.1%）／欠落・重複・予定外 0， sanity 検証成功

同じ上限 4 回でも，入力情報・実要求数・出典・実行時期が異なる

追加消費を含めると，独立再生成も比較候補になる



指標：追加 tokens ／追加成功．共有初期を除き，未成功例への消費も含む

R/F/D は再構成経路の計算値．金銭費用・実測の費用削減ではない

3 回目にも救済がある．停止回数も検討対象

修正条件	1 回目	2 回目	3 回目	2 回打切りで失う救済
R	57 組	20 組	19 組	19.8%
F	112 組	43 組	28 組	15.3%
D	108 組	39 組	32 組	17.9%

失う割合の分母は「3 回までに救済した組数」．初期失敗数とは異なる

同じ観測履歴を打ち切った比較．上限別独立実験ではない

介入カタログには，適用範囲と限界を併記する

01	何に使うか	初期失敗類型・モデル・分母・成功対象
02	どれだけ使うか	未成功消費を含む tokens ・要求数・停止回数
03	どこまで分かるか	指定入力の L3 ・出典差・共有初期とタスク依存

次：選択・停止方策を事前固定し，別 seed ・タスクで検証する

救済率に加え，「何を救済するか」を比較する

1 **F 183 組・ D 179 組を救済**

全体率は近くても，片側救済 84 組の対象が異なる

2 **独立再生成 B4 は 216 組が追加成功**

修正と再生成を，入力情報・出典差も含めて比較する

3 **分母・対象・追加消費をカタログに記録**

選択・停止方策を固定して別条件で検証する

> **今回の対象での観測であり，一般的優劣・因果効果・統計的有意差は主張しない**

補足 A　モデル別の初期失敗と追加成功

略号／正式タグ	初期失敗	R	F	D	B4
G3 gemma3:4b	190	5	1	1	16
G4 gemma4:e4b-it-qat	62	30	48	38	51
C7 qwen2.5-coder:7b	65	15	23	23	46
Q4 qwen3.5:4b	162	31	78	89	66
Q9 qwen3.5:9b	66	15	33	28	37

モデルごとの失敗分母が異なる．モデル一般の優劣は断定しない

補足 B　B4 と F でも成功する対象は一致しない

共通成功	B4 のみ	F のみ	双方未成功
130	86	53	276

B4 と F の対応比較の分母：初期失敗 545 組

P は独立 1 回生成：初期失敗から成功 124 組,
初期成功に対応する失敗 106 組．最終成功 473/1,000 組.

事後的な和集合を，実行前に使える選択方策とみなさない

補足 C　評価範囲・経路・データ品質

項目	検証範囲と限界
L3	L0 ：コード読込み・必須関数／ L1 ：構築・評価／ L2 ：指定出力一致＋構造
出力の基準	分布： 8,192 shots の全変動距離／状態：位相整合した距離／ 0.05 未満
構造・乱数	回路内測定禁止・量子ビット数・命令数／測定・ transpile seed 42
到達経路	保存 prefix ＋必要な追試 suffix． 分岐後に到達しない旧 suffix を除外
比較の限界	共有初期・タスク・ seed 依存， schema ・診断文・実行時期の差
品質確認	B4 ：全 1,000 組，欠落・重複・予定外 0． コード側 NameError と API 障害を区別

旧 120 件は別設定の既報として保持し，主結果に合算しない

補足 D　参考文献と固定出典

[1] A. Madaan et al. Self-Refine: Iterative Refinement with Self-Feedback
arXiv:2303.17651 (2023).

[2] X. Chen et al. Teaching Large Language Models to Self-Debug
arXiv:2304.05128 (2023).

[3] 現行到達経路の固定集計（ 2026-11-04 修正版）
docs/analysis/measurement_ban_corrected_20261104/

[4] B4 追加実験の完了集計（ 2026-11-04 修正版）
docs/analysis/measurement_ban_corrected_20261104/

https://github.com/yuuma-ito/2026_ito_qLLM-ver3